Elementos de Matemática Aplicada

August 2024

1 Introducción

Representación numérica en computadoras. Sistema normalizado de punto flotante. Representación aproximada: errores de redondeo. Errores absoluto y relativo. Cota para el error en un sistema de punto flotante. Cifras significativas. Perdida de cifras significativas.

En una computadora, los números se representan usando el sistema binario. En este sistema un patrón de bits (una secuencia de ceros y unos) representa un numero.

Diariamente, utilizamos un sistema posicional de base 10 para representar los números, conocido como sistema decimal. En este sistema, los números se forman con diez caracteres distintos, conocidos como dígitos decimales: $0, 1, 2, 3, 4, 5,\ 6, 7, 8$ y 9. La cantidad que aporta un dígito específico al valor total del número depende de su posición. Si el dígito se encuentra en la posición n a la izquierda del punto decimal, su valor es 10^{n-1}, mientras que si está en la posición n a la derecha del punto decimal, su contribución es 10^{-n}.

Ejemplo: $a = 325,37 = 3.10^2 + 2.10^1 + 5.10^0 + 3.10^{-1} + 7.10^{-2}$

En general,

$$a = (-1)^s(a_n 10^n + a_{n-1}10^{n-1} + \ldots + a_1 10^1 + a_0 10^0 + a_{-1}10^{-1} + a_{-2}10^{-2} + \ldots)$$

donde s depende del signo del número ($s = 0$ si el número es positivo y $s = 1$ si es negativo).

De manera similar se puede escribir el en cualquier base $\beta \geq 2$:

$$a = (-1)^s(a_n\beta^n + a_{n-1}\beta^{n-1} + \ldots + a_1\beta^1 + a_0\beta^0 + a_{-1}\beta^{-1} + a_{-2}\beta^{-2} + \ldots),$$

donde los coeficientes $0 \geq a_i \geq \beta - 1$ son los dígitos. Como en el caso decimal, utilizamos la coma para separar la parte entera de la decimal (o fraccionaria). A este número lo escribimos como

$$a = (-1)^s(a_n a_{n-1}\beta^{n-1} \ldots a_1 a_0, a_{-1}a_{-2}\ldots).$$

Las computadoras y otros dispositivos electrónicos están diseñados para trabajar con datos binarios. Los algoritmos y las operaciones aritméticas se optimizan para operar eficientemente con números en formato binario. El uso de números binarios se debe a varias razones importantes, una es que es menos probable que se produzcan errores en la representación de los datos. Otra es la compatibilidad con la lógica digital: Todo el procesamiento en computadoras se basa en la lógica digital que opera con puertas lógicas (AND, OR, NOT, etc.), las cuales funcionan naturalmente en un sistema binario. En el almacenamiento de información, el uso del sistema binario permite que los datos se gestionen de manera más eficiente y se reduzcan los costos de almacenamiento.

Así, por ejemplo, $1101,01$ es la representación binaria del número 13.25 del sistema decimal, esto es, $(1101,01)_2 = (13,25)_10$, ya que,

$$1.2^3 + 1.2^2 + 0.2^1 + 1.2^0 + 0.2^{-1} + 1.2^{-2} = 13 + 0,25 = 13,25.$$

Veamos ahora como obtener la representación en la base 2 de un número en la base 10.

Tomamos $(13,25)_{10}$. Analizamos primero la parte entera, $(13)_{10}$.

$$13 = a_0 2^0 + a_1 2^1 + a_2 2^2 + \ldots =$$

(notar que en principio no sabemos cuantos dígitos vamos a tener en la base $\beta = 2$).

$$13 = a_0 + 2(a_1 + a_2 2^1 + a_3 2^2 \ldots) =$$

Por lo tanto, por el Algoritmo de la división a_0 es el resto de la división de 11 por 2, que solo puede ser 0 o 1. Es decir, $13 = 2.6 + 1$, con lo que podemos concluir que

$$a_0 = 1$$

y

$$6 = a_1 + a_2 2^1 + a_3 2^2 \ldots$$

De la misma manera,

$$6 = a_1 + 2(a_2 + a_3 2^1 \ldots),$$

y por lo tanto a_1 es el resto de dividir 6 por 2, es decir

$$a_1 = 0$$

y

$$3 = a_2 + a_3 2^1 \ldots$$

Volvemos a repetir el proceso, y tenemos que $a_2 = 1$ y $a_3 = 1$.

Etonces

$$(13)_{10} = (1101)_2.$$

Veamos ahora como calcular la parte decimal $(0,25)_{10}$ en la base 2.

$$0,25 = a_{-1} 2^{-1} + a_{-2} 2^{-2} + a_{-3} 2^{-3} + \ldots$$

Multiplicamos por 2 la igualdad anterior,

$$0,50 = a_{-1} + a_{-2} 2^{-1} + a_{-3} 2^{-2} + \ldots$$

Eontonces

$$a_{-1} = 0$$

y

$$0,5 = a_{-2} 2^{-1} + a_{-3} 2^{-2} \ldots$$

Vuelvo a multiplicar por 2,

$$1 = a_{-2} + a_{-3} 2^{-1} + \ldots$$

Entonces

$$a_{-2} = 1$$

y finalizamos el proceso porque la parte decimal es 0, ya que $a_{-3}, a_{-4}, \ldots = 0$.

Veamos otro ejemplo, hallar la representación en la base 2 de $(0.6)_{10}$.

1.1 Notación científica

La representación del sistema de números reales en una computadora basa su idea en la conocida notación científica. En esta notación el punto decimal se mueve dinámicamente a una posición conveniente y se utiliza el exponente de 10 para registrar la posición del punto decimal. En particular, todo número real no nulo puede ser escrito en forma única en la notación científica *normalizada*

$$x = (-1)^s 0, d_1 d_2 d_3 \ldots 10^e$$

Por ejemplo, $322,51 = 0,32251.10^3$ y $-0,002752 = -0,2752.10^{-2}$.

De manera análoga, todo número real no nulo puede representarse en forma única, respecto la base β, en la forma de *punto flotante* :

$$fl(x) = (-1)^s 0, d_1 d_2 \ldots d_k \beta^e$$

donde $0 \leq d_i \leq \beta - 1$ y $d_1 \neq 0$.

Llamamos *mantisa* a las dígitos que aparecen después de la coma en la representación de un número en notación científica. El número e es un número entero llamado *exponente* que indica la posición del punto correspondiente a la base β. Pero en todo dispositivo de cálculo, ya sea una computadora o una calculadora, el número de dígitos posibles para representar la mantisa es finito, digamos t dígitos en la base β, y el exponente puede variar sólo dentro de un rango finito

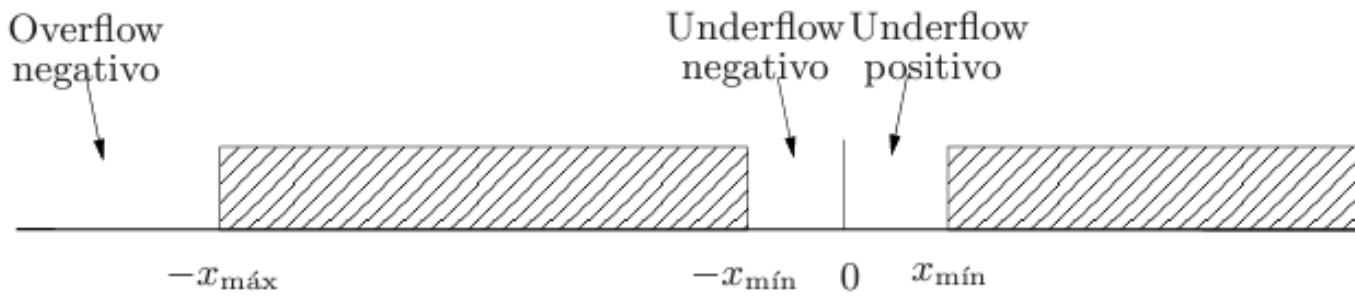

Figure 1: Números de punto flotante $F(\beta, t, L, U)$

$L \leq e \leq U$ (con $L < 0$ y $U > 0$). Esto implica que sólo un conjunto finito de números reales pueden ser representados.Tales números se denominan números de *punto flotante* con t dígitos (o de precisión t) en la base β y rango (L, U). Denotaremos a dicho conjunto de números por $F(\beta, t, L, U)$.

a) Los números negativos menores que $-x_{max}$, región denominada desbordamiento (overflow) negativo.

b) Los números negativos mayores que $-x_{min}$, denominada desbordamiento a cero (underflow) negativo.

c) El cero.

d) Los números positivos menores que x_{min}, denominada desbordamiento a cero (underflow) positivo.

e) Los números positivos mayores que x_{max}, denominada desbordamiento (overflow) positivo.

El cardinal de $F(\beta, t, L, U)$ es $2(\beta - 1)\beta^{k-1}(U - L + 1)$.

Ejemplo: Consideremos $F(2, 3, -1, -2)$ y hallamos todos los números de punto flotante con 3 dígitos en la base 2 y rango $[-1, 2]$.

Si $x \in F(2, 3, -1, -2)$, $x = (-1)^s 0, a_1 a_2 a_3 . 2^e$, $a_1 \neq 0$ donde $s \in \{0, 1\}$ y $e \in \{-1, 0, 1, 2\}$

1.2 Errores en la representación de un número real

Sea $x \in R$. Si almacenamos k dígitos de mantisa, hay dos maneras de representar $fl(x)$.

- Por truncamiento. Es simplemente considerar los primeros k dígitos de x. En este caso,

$$fl(x) = (-1)^s 0, d_1 d_2 \ldots d_k \ldots \beta^e.$$

- Por redondeo. Donde $fl(x)$ es el número más próximo a x es decir,

$$fl(x) = \begin{cases} (-1)^s 0, d_1 d_2 \ldots d_k \ldots \beta^e & \text{si} \quad 0 \leq d_k < \frac{\beta}{2} \\ (-1)^s (0, d_1 d_2 \ldots d_3 + 0, 0 \ldots 01)\beta^e. & \text{si} \quad \frac{\beta}{2} \leq d_k \leq \beta - 1 \end{cases}.$$

Ejemplo: Si $k = 5$, $\beta = 10$, $x = 0,249911.10^{-2}$. El $fl(x) = 0,24991.10^{-2}$ usando redondeo y el truncamiento. Si $x = 0,9997673.10^{-2}$, en este caso son diferentes. Si usamos truncamiento $fl(x) = 0,99976.10^{-2}$ y si usamos redondeo $fl(x) = 0,99977.10^{-2}$.

Observación 1.1. *El error que se produce con la representación de x por punto flotante se denomina error de redondeo independientemente de si se obtuvo por redondeo o truncamiento.*

Definición 1.2. *Sea $x \in R$ y $\bar{x}$ su valor aproximado, se define el error absoluto como*

$$e_a(x) = |x - \bar{x}|.$$

Definición 1.3. *Sea $x \in R$ y $\bar{x}$ su valor aproximado, se define el error relativo como*

$$e_r(x) = \frac{|x - \bar{x}|}{|x|}.$$

Ejemplo 1.4.

1. *Sean $x = 0,0003 = 0,3.10^{-3}$ y su aproximación $\bar{x} = 0,00031 = 0,31.10^{-3}$. En este caso,*

$$e_a(x) = |0,3.10^{-3} - 0,31.10^{-3}| = 0,1.10^{-4}$$

y

$$e_r(x) = \frac{|0,3.10^{-3} - 0,31.10^{-3}|}{0,3.10^{-3}} = \frac{0,1.10^{-4}}{0,3.10^{-3}} = 0,3.10^{-1}.$$

2. *Sean $y = 3000 = 0,3.10^{4}$ y su aproximación $\bar{y} = 3100 = 0,31.10^{4}$. En este caso,*

$$e_a(x) = |0,3.10^{4} - 0,31.10^{4}| = 0,1.10^{3}$$

y

$$e_r(x) = \frac{|0,3.10^{4} - 0,31.10^{4}|}{0,3.10^{4}} = \frac{0,1.10^{3}}{0,3.10^{4}} = 0,3.10^{-1}.$$

3. *Sean $z = 3 = 0,3.10^{1}$ y $\bar{z} = 3,1 = 0,31.10^{1}$. En este caso,*

$$e_a(x) = 0,1.10^{1}$$

y

$$e_r(x) = \frac{0,1.10^{1}}{0,31.10^{1}} = 0,3.10^{-1}.$$

En los tres ejemplos los errores relativos son los mismos, sin embargo, los absolutos son muy distintos. Como medida de exactitud el error absoluto puede ser engañoso y el relativo más significativo. Porque el error relativo proporciona una idea de la magnitud del error en relación con el tamaño del número real, lo que permite una comparación más significativa del error en diferentes magnitudes.

Definición 1.5. *Sea $\bar{x}$ una aproximación de x. Decimos que $\bar{x}$ aproxima a x con t cifras significativas si t es el entero no negativo más grande para el cual*

$$e_a(x) = \frac{|x - \bar{x}|}{|x|} < 5.10^{-t}.$$

También se dice que $\bar{x}$ tiene t cifras significativas.

Ejemplo 1.6. $x = 0,397999$ *y* $\bar{x} = 039791$*, El error relativo es*

$$e_r(x) = 0,0002010 < 0,0005 = 5.10^{-4}$$

y

$$e_r(x) = 0,0002010 > 0,00005 = 5.10^{-5}.$$

En este caso decimos que $\bar{x}$ *tiene 4 cifras significativas.*

Las cifras significativas no siempre coinciden con la cantidad de dígitos.

1.3 Propagación de errores

La pérdida de cifras significativas se produce luego de realizar varias operaciones. Si al final las cifras significativas son menos, significa que el error será mayor.

Supongamos que trabajamos con s dígitos de mantisa, tomamos los números $x = 0,372147869$ e $y = 0,372023057$. Queremos realizar la operación $x - y$. supongamos que usamos redondeo, entonces

$$fl(x) = 0,37215$$

y

$$fl(y) = 0,37202.$$

$$e_r(x) = 0,00000572 < 0,00005 = 5.10^{-5}$$

$$e_r(y) = 0,00000821 < 0,00005 = 5.10^{-5}$$

ambos tienen 5 cifras significativas.

Ahora,

$$z = x - y = 0,124812.10^{-3}$$

. Pero,

$$fl(x) - fl(y) = 0,37215 - 0,37202 = 0,00013 = 0,13.10^{-3}.$$

claramente perdimos dígitos!!

$$e_r(z) = \frac{|0,124812.10^{-3} - 0,13.10^{-3}|}{0,12481.10^{-3}} = 0,041 < 0,05 = 5.10^{-2},$$

es decir, tiene solo dos cifras significativas.

Por otro lado,

$$fl(fl(x) - fl(y)) = 0,00013 < 5.10^{-4}.$$

Solo con una resta, perdí cifras significativas.

Conclusiones:

- La representación de números reales en la computadora es inexacta.
- La aritmética de la computadora es diferente a la real. por ejemplo, la no es cerrada.
- La propiedad asociativa deja de valer tanto para la suma como para el producto. (Ver ejercicio en la práctica).

Ejemplo 1.7. *Sean* $x = 0,372147869$, $y = 0,372023057$ *y* $z = 0,213475.10^{-3}$. *Realizar el calculo de* $\frac{x-y}{z}$ *y calcular cuantas cifras significativas se pierden si se utiliza redondeo con 5 dígitos.*

Ejemplo 1.8. *Evalúe* $f(x) = x^3 - 6,1x^2 + 3,2x + 1,5$ *en* $x = 4,71$ *con aritmética de 3 dígitos.*

	x	x^2	x^3	$6,1x^2$	$3,2x$
Exacto	*4,71*	*22.1841*	*104,487111*	*135,32301*	*15,072*
Tres dígitos redondeo	*4.71*	*22,2*	*105*	*135*	*15,1*

$f(x) = ((x - 6,1)x + 3,2)x + 1,5$

2 Soluciones de ecuaciones de una variable

Antes de comenzar, recordemos el Teorema de Valor intermedio.

Teorema 2.1. *Teorema de Valor intermedio. Sea* f *una función continua en un intervalo cerrado* $[a, b]$ *tal que* $f(a)f(b) < 0$. *Entonces existe* $c \in [a, b]$ *tal que* $f(c) = 0$.

2.1 Método de bisección

2.1.1 Idea Principal

La idea básica es utilizar el teorema del valor intermedio, para encontrar una solución de una ecuación, digamos $f(x) = 0$. El método divide repetidamente el intervalo en dos mitades, determinando en cuál de las dos mitades se encuentra la raíz.

2.1.2 Procedimiento

1. **Elección del Intervalo Inicial:** Elegimos un intervalo $[a_1, b_1]$ tal que la función $f(x)$ sea continua en ese intervalo y $f(a_1)f(b_1) < 0$. Por el Teorema de valor Intermedio sabemos que hay al menos una raíz en el intervalo.

2. **División del Intervalo:** Calculamos el punto medio del intervalo: $p_i = \frac{a_i+b_i}{2}$.

3. **Evaluación de la Función:** Evaluamos la función en el punto medio, $f(p_i)$.

4. **Selección del Nuevo Intervalo:**

   - Si $f(p_i) = 0$, entonces m es una raíz y el algoritmo termina.
   - Si $f(a_i).f(p_i) < 0$, hay una raíz en el intervalo $[a_i, p_i]$. Actualizamos el intervalo a $[a, m]$.
   - Si $f(p_i).f(b_i) < 0$, hay una raíz en el intervalo $[p_i, b_i]$. Actualizamos el intervalo a $[p_i, b_i]$.

5. **Iteración:** Hacemos $i = i + 1$ y repetimos los pasos 2 a 4 con el nuevo intervalo hasta que el intervalo sea lo suficientemente pequeño o hasta que la función evaluada en el punto medio sea suficientemente cercana a cero.

Observación 2.2. *Noten que* $\lim_{k\to\infty} I_k = 0$. *Ya que como* $\ldots I_3 \subset I_2 \subset I_1$,

$$long(I_1) = b - a,$$

$$long(I_2) = \frac{long(I_1)}{2},$$

$$long(I_3) = \frac{long(I_2)}{2} = \frac{long(I_1)}{2^2},$$

$$long(I_k) = \frac{long(I_k)}{2^{k-1}}$$

¿Cuándo finalizo el proceso?

Si $f(p_i) = 0$, que es ese caso encontre la raiz. O si considero que el error es suficientemente pequeño, esto es cuando la longitud del intervalo es chica. Pero nos alcanza con pedir que $|p_{k+1} - p_k| < TOL$. Por que

$$|p_{k+1} - p_k| = \frac{1}{2} long(I_{k+1}) \longrightarrow_{k\to\infty} 0.$$

Usar este criterio de parada no depende de la solución exacta (que no conocemos).

Algoritmo del Método de Bisección

Dado una función continua $f(x)$ y un intervalo inicial $[a, b]$ tal que $f(a) \cdot f(b) < 0$, el algoritmo de bisección sigue estos pasos:

1. **Entrada:** Función continua $f(x)$, intervalo $[a, b]$, tolerancia ϵ, cantidad de iteraciones N.
2. **Inicialización:** i=1. Definir $FA = f(a)$ y $FB = f(b)$. Calcular el punto medio del intervalo:
$$p = \frac{a+b}{2}$$

Paso 1 **Mientras $i < N$ realizar los pasos 1 y 3. Sino ir al paso 5.**

(a) Evaluar la función en el punto medio: $FP = f(p)$.

(b) Si $FP = 0$ o $\frac{b-a}{2} < \epsilon$ entonces
- p es la raíz aproximada.
- Terminar el algoritmo.

(c) Si $FA \cdot FP < 0$, entonces
- La raíz está en el intervalo $[a, p]$.
- Actualizar b a p.

(d) Si $FP \cdot FB < 0$, entonces
- La raíz está en el intervalo $[p, b]$.
- Actualizar a a p.

(e) Recalcular el punto medio:
$$p = \frac{a+b}{2}$$

Paso 2 Hacer $i = i + 1$ y volver al Paso 3.

Paso 3 **Salida:** La raíz aproximada p.

Paso 4 Detener el proceso. Fracaso.

Ejemplo 2.3. *Consideremos la función* $f(x) = x^3 + 4x^2 - 10$ *en el intervalo* $[1, 2]$. *Tolerancia:* 10^{-1}, *Cantidad máxima de iteraciones 10.*

Teorema 2.4. *Sea* f *una función continua en el intervalo* $[a, b]$ *tal que* $f(a)f(b) < 0$. *El método de bisección genera una sucesión* $\{p_k\}_{k>0}$ *tal que converge a un punto* p *con* $f(p) = 0$ *y verifica*

$$|p - p_k| \leq \frac{b-a}{2^k}.$$

Proof. Para cada p_k, $k > 0$, sabemos que $p_k \in I_k = [a_k, b_k]$.

$$\begin{aligned}
|p - p_k| &\leq \frac{1}{2} long(I_k) \\
&\leq \frac{1}{2}(\frac{1}{2} long(I_{k-1})) \\
&\leq \frac{1}{2}(\frac{1}{2} long(I_{k-1})) \\
&\vdots \\
&\leq (\frac{1}{2})^k long(I_1) = (\frac{1}{2})^k (b-a)
\end{aligned}$$

Por lo tanto, $|p - p_k| < \dfrac{b-a}{2^k}$.

Y como consecuencia, $\lim_{k\to\infty} p_k = p$.

Veamos que $f(p) = 0$. Por construcción sabemos que

$$f(a_k)f(b_k) < 0,$$

$$a_1 \leq a_2 \leq a_3 \ldots \leq b_1$$

y

$$a_1 \leq \ldots b_3 \leq b_2 \leq b_1.$$

La sucesión $\{a_k\}$es una sucesión monótona creciente y acotada y la sucesión $\{b_k\}$ es decreciente y acotada. Entonces ambas sucesiones convergen. Supongamos, que $\lim_{k\to\infty} a_k \bar{a}$ y $\lim_{k\to\infty} b_k \bar{b}$. Como ambos limites existen y son finitos, $lim_{k\to\infty} b_k - a_k = \bar{b} - \bar{a}$.

Por otro lado,

$$\lim_{k\to\infty} b_k - a_k = \lim_{k\to\infty} \frac{1}{2} long(I_k) = \lim_{k\to\infty} \frac{1}{2^2} long(I_{k-1}) = \frac{b-a}{2^k} = 0$$

Por lo tanto, $\bar{b} - \bar{a} = 0$. Y entonces $\bar{a} = \bar{b}$.

Además, $a_k \leq p_k \leq b_k$, entonces existe $\lim\limits_{k\to\infty} p_k = p = \bar{a} = \bar{b}$.

Nos falta ver que $f(p) = 0$. Para ello usaremos que f es continua. Entonces,

$$0 \geq \lim_{k\to\infty} f(a_k)f(b_k) = f(p)f(p) = (f(p))^2 \geq 0,$$

y por lo tanto $f(p) = 0$. $\square$

Ejemplo 2.5. *¿Cuantas iteraciones son necesarias quiero que el error sea menor que* 10^{-3}*?*

Ventajas:

- Simplicidad: El método es fácil de implementar y entender.
- Convergencia Garantizada: Siempre converge a una raíz si la función es continua y el intervalo inicial contiene una raíz.

Desventajas:

- Velocidad: La convergencia es lineal, lo que significa que puede ser más lento en comparación con otros métodos como el de Newton-Raphson o el método de la secante que veremos mas adelante.
- Requiere Conocimiento de Intervalo: Necesitas conocer un intervalo donde la función cambia de signo.

2.2 Punto fijo

El algoritmo de punto fijo es un método numérico utilizado para encontrar soluciones a ecuaciones de la forma $x = g(x)$. Este tipo de ecuaciones se llaman ecuaciones de punto fijo, y las soluciones son los puntos en los que la función $g(x)$ se intersecta con la recta $y = x$.

Definición 2.6. *Un número p es un punto fijo de una función g si $g(p) = p$.*

Antes de presentar el algoritmo, demostraremos algunos teoremas que nos ayudaran a definirlo correctamente.

Teorema 2.7. *Sea g una función continua en $[a, b]$ tal que $g(x) \in [a, b]$, $\forall x \in [a, b]$ ($g([a, b]) \subset [a, b]$). Entonces, g tiene un punto fijo en el intervalo $[a, b]$.*

Si además g es derivable en (a, b) y existe $k \in (0, 1)$ tal que $|g'(x)| < K$, $\forall x \in (a, b)$ entonces el punto fijo es único.

Proof. Si $g(a) = a$ o $g(b) = b$ ya esta demostrado. Supongamos, sin pérdida de generalidad que $g(a) > a$ y $g(b) < b$.

Definimos $h(x) = g(x) - x$, que es continua pues g lo es. Además,

$$h(a) = g(a) - a > 0 \text{ y } h(b) = g(b) - b.$$

Por el Teorema de Valor Intermedio, existe $p \in (a, b)$ tal que $h(p) = 0$ y por lo tanto $g(p) = p$.

Veamos la unicidad. Supongamos ahora que existe g' y $|g'(x)| \leq K < 1$, $\forall x \in (a, b)$. Supongamos que hay dos puntos fijos, p y q. Esto quiere decir que $g(p) = p$ y $g(q) = q$. Por el Teorema de valor medio, existe c entre p y q que

$$g(p) - g(q) = g'(c)(p - q).$$

Por lo tanto,

$$|p - q| = |g(p) - g(q)| = |g'(c)(p - q)| < |p - q|.$$

Absurdo, por lo tanto, $p = q$.

Teorema 2.8 (Teorema del Punto Fijo)**.** *Sea g una función continua en $[a,b]$ tal que $g(x) \in [a,b]$, $\forall x \in [a,b]$ y g es derivable en (a,b) tal que existe $K \in (0,1)$ tal que $|g'(x)| \leq K$, $\forall x \in (a,b)$. Entonces, para cualquier $p_0 \in [a,b]$ la solución $\{p_n\}_{n\geq 1}$ definida por $p_n = g(p_{n-1})$ converge a un único punto fijo p de g en $[a,b]$.*

Proof. Por el teorema anterior sabemos que g tiene un único punto fijo $p \in [a,b]$.

Veamos que la sucesión p_n converge a p. Como $g([a,b]) \subset [a,b]$, $p_n = g(p_{n-1}) \in [a,b]$, $\forall n \geq 1$ (Tener en cuenta que arranco por $p_0 \in [a,b]$).

Usando el TVM,

$$|p_n - p| = |g(p_{n-1}) - g(p)| = |g'(\alpha_1)||p_{n-1} - p|$$

$$\leq K|p_{n-1} - p| = K|g(p_{n-2} - g(p))| = K|g'(\alpha_2)||p_{n-2} - p| \leq K^2|p_{n-2} - p| \leq \dots$$
$$K^n|p_0 - p|$$

Como $K < 1$, $K^n \to 0$ cuando $n \to \infty$. Y por lo tanto, $p_n \to p$. □

Algoritmo de Punto Fijo.

ENTRADA : Función $g(x)$ que cumple las hipótesis del teorema, valor inicial $p_0 \in [a,b]$, una tolerancia ε y número máximo de iteraciones, N.

SALIDA: Un valor p tal que $p \approx g(p)$

Paso 1. $i = 1$

Paso 2. Mientras $i \leq N$, realizar los pasos 3 a 6.

Paso 3. $p = g(p_0)$

Paso 4. Si $|p - p_0| < \varepsilon$, ÉXITO p es la solución aproximada.

Paso 5. $i = i + 1$

Paso 6. $p_0 = p$

Paso 7. Detener el proceso, FRACASO.

Observación 2.9. *Bajo las hipótesis del Teorema del Punto Fijo, el criterio de finalización $|p_n - p_{n-1}| < \varepsilon$ es un buen criterio ya que $\lim_{n\to\infty} p_n = p$.*

Ejemplo 2.10. *Consideremos la ecuación $x^3 + 4x^2 - 10 = 0$, en el intervalo $[1,2]$. La solución es $p = 1,365230013$. Debo reacomodar la función que quede escrita de la forma $g(x) = x$, hay varias maneras de hacer esto:*

a) $g_1(x) = x^3 + 4x^2 - 10 + x = x$.

b) $g_2(x) = \left(\frac{10}{x} - 4x^2\right)^{\frac{1}{2}} = x$.

c) $g_3(x) = \sqrt{\frac{10}{x+4}}$.

No es fácil encontrar un intervalo, y no hay una única función.

Apliquemos el algoritmo a la función g_3*, con punto inicial* $p_0 = 1,5$.

Teorema 2.11. *Supongamos que* g *satisface las hipótesis del teorema de punto fijo. Entonces,*

$$|p_n - p| \leq K^n \max\{p_0 - a, b - p_0\}$$

y

$$|p_n - p| \leq \frac{K^n}{1-K}|p_1 - p_0|.$$

Proof. Sea $p_0 \in [a,b]$, $p \in [a,b]$. Por la demostración del punto fijo, sabemos que

$$|p_n - p| \leq K^n |p_0 - p| \leq K^n \max\{p_0 - a, b - p_0\}.$$

Para la otra cota, sea $n \geq 1$,

$$|p_{n+1} - p_n| = |g(p_n) - g(p_{n-1})| = |g'(\alpha)||p_n - p_{n-1}| \leq$$

$$K|p_n - p_{n-1}| \leq \ldots \leq K^n |p_1 - p_0|.$$

Para cualquier $n, m \geq 1$, $m > n$

$$|p_m - p_n| = |p_m - p_{m-1} + p_{m-1} - p_n| = |p_m - p_{m-1} + p_{m-1} - p_{m-2} + p_{m-2} + \ldots - p_{n+1} + p_{n+1} - p_n|$$

$$\begin{aligned}
&\leq |p_m - p_{m-1}| + |p_{m-1} - p_{m-2}| + |p_{m-2} - p_{m-3}| \ldots + |p_{n+1} - p_n| \\
&\leq K^{m-1}|p_1 - p_0| + K^{m-2}|p_1 - p_0| + \ldots + K^n |p_1 - p_0| \\
&= |p_1 - p_0| K^n (K^{m-1-n} + K^{m-2-n}) + \ldots + K + 1) \\
&= |p_1 - p_0| K^n \sum_{i=1}^{m-n-1} K^i < |p_1 - p_0| K^n \sum_{i=1}^{\infty} K^i =
\end{aligned}$$

Esta última es una serie geométrica (porque $K < 1$), y entonces la última es expresión es igual a

$$|p_1 - p_0| K^n \frac{1}{1-K}.$$

Por lo tanto,

$$|p_m - p_n| < |p_1 - p_0| \frac{K^n}{1-K}.$$

Tomando límite ciando $m \to \infty$,

$$|p - p_n| < |p_1 - p_0| \frac{K^n}{1-K}.$$

□

Observación 2.12. *Mientras mas chico sea* K*, mas rápido converge.*

2.3 Velocidad de convergencia

Convergencia (General)

Una sucesión $\{x_n\}$ converge a un límite L si, para cualquier $\epsilon > 0$, existe un índice N tal que para todo $n > N$, se cumple que:

$$|x_n - L| < \epsilon$$

Velocidad de Convergencia

La velocidad de convergencia describe la rapidez con la que $\{x_n\}$ se aproxima a L. Se clasifica en varios tipos:

- **Convergencia Lineal:** Una sucesión $\{x_n\}$ converge de manera lineal a L si existe una constante $0 < \rho < 1$ tal que:

  $$|x_{n+1} - L| \leq \rho |x_n - L|$$

  La constante ρ es el factor de contracción y x_{n+1} se aproxima a L con una tasa proporcional a la distancia $x_n - L$. En este caso, se considera que la velocidad de convergencia es lenta.

- **Convergencia Cuadrática:** Una sucesión $\{x_n\}$ converge de manera cuadrática a L si existe una constante $C > 0$ tal que:

  $$|x_{n+1} - L| \leq C|x_n - L|^2$$

  Esto significa que la distancia a L se reduce al cuadrado de la distancia anterior. La convergencia cuadrática es mucho más rápida que la lineal.

- **Convergencia Cúbica:** Una sucesión $\{x_n\}$ converge de manera cúbica a L si existe una constante $C > 0$ tal que:

  $$|x_{n+1} - L| \leq C|x_n - L|^3$$

  Aquí, la distancia a L se reduce al cubo de la distancia anterior, lo cual implica una convergencia aún más rápida.

- **Convergencia Superlineal:** Una sucesión $\{x_n\}$ converge de manera superlineal a L si:

  $$\lim_{n\to\infty} \frac{|x_{n+1} - L|}{|x_n - L|} = 0$$

  Esto significa que la sucesión se acerca a L más rápidamente que cualquier tasa lineal.

Ejemplo 2.13. ***Método de Punto Fijo:*** *Si $g(x)$ cumple con la condición de contracción $|g'(x)| < 1$, entonces el método de punto fijo tiene convergencia lineal.*

3 Método de Newton-Raphson

El Método de Newton, también conocido como el Método de Newton-Raphson, es una técnica iterativa utilizada para encontrar aproximaciones de las raíces (o ceros) de una función. Es un método muy eficiente y popular debido a su rapidez de convergencia bajo condiciones adecuadas.

Consideremos una función f, dos veces derivable en un intervalo $[a, b]$. Sea $\bar{x}$ una aproximación de x^* ($f(x^*) = 0$)

Si aplicamosla fórmula de Taylor al rededor de del punto $\bar{x}$ a la función f , tenemos que

$$f(x) = f(\bar{x}) + f'(\bar{x})(x - \bar{x}) + \frac{f''(c)}{2}(x - \bar{x})^2,$$

para un valor c entre x y $\bar{x}$.

Como $f(x^*) = 0$,

$$0 = f(x^*) = f(\bar{x}) + f'(\bar{x})(x^* - \bar{x}) + \frac{f''(c)}{2}(x^* - \bar{x})^2.$$

Además, $|x^* - \bar{x}|$ es "pequeño" y entonces

$$0 \approx f(\bar{x}) + f'(\bar{x})(x^* - \bar{x}).$$

Con lo cual

$$x^* \approx \bar{x} - \frac{f(\bar{x})}{f'(\bar{x})}.$$

Este método comienza desde un punto "cercano" a la solución y genera una sucesión de puntos $\{x_n\}$ definida por

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

Es interesante observar que x_n es la intersección con el eje x de la aproximación lineal x_{n-1}.

Idea general

1. **Definir la Función**: Consideremos una función $f(x) \in C^2[a, b]$ para la cual queremos hallar una raíz, es decir, un valor x^* para el cual $f(x^*) = 0$.

2. **Elegir una aproximación Inicial**: Elegimos un punto inicial $x_0 \in [a, b]$.

3. **Iterar con la fórmula de Newton**: La fórmula de iteración para el método de Newton es:

   $$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

   donde $f'(x_n)$ es la derivada de f evaluada en x_n.

4. **Repetir**: Actualiza x_n con x_{n+1} y repite el proceso hasta que la aproximación sea "suficientemente precisa".

Ejemplo 3.1. *Supongamos que queremos encontrar una raíz de la función $f(x) = x^2 - 2$.*

1. ***Función y Derivada:***

$$f(x) = x^2 - 2$$
$$f'(x) = 2x$$

2. ***Aproximación Inicial:*** *Supongamos que iniciamos en $x_0 = 1$.*

3. ***Primera Iteración:***

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)} = 1 - \frac{1^2 - 2}{2 \cdot 1} = 1 - \frac{-1}{2} = 1 + 0.5 = 1.5$$

4. ***Segunda Iteración:***

$$x_2 = x_1 - \frac{f(x_1)}{f'(x_1)} = 1.5 - \frac{(1.5)^2 - 2}{2 \cdot 1.5} = 1.5 - \frac{0.25}{3} \approx 1.4167$$

5. ***Continuar:*** *Repetimos el proceso hasta que los cambios entre iteraciones sean muy pequeños.*

GRAFICO

Teorema 3.2. *Sea $f \in C^2[a,b]$, Si $x^* \in [a,b]$ es tal $f(x^*) = 0$ y $f'(x^*) \neq 0$. entonces existe $\delta > 0$ tal que el método de Newton genera una sucesión $\{x_n\}$ que converge a x^* para cualquier punto inicial $x_0 \in [x^* - \delta, x^* + \delta]$ y*

$$|x_{n+1} - x^*| \leq C|x_n - x^*|^2.$$

Proof. La sucesión generada tiene la forma $x_n = x_{n-1} - \frac{f(x_{n-1})}{f'(x_{n-1})}$, con $f'(x_{n-1}) \neq 0$.

Definimos $g(x) = x - \frac{f(x)}{f'(x)}$, y entonces $x_n = g(x_{n-1})$. Utilizamos el Algoritmo de Punto Fijo:

Buscamos el intervalos $[x^* - \delta, x^* + \delta]$ en donde se cumplan las hipótesis del teorema de Punto Fijo para la función g. Recordemos cuales eran

1. g continua.
2. $g(x) \in [x^* - \delta, x^* + \delta]$, $\forall x \in [x^* - \delta, x^* + \delta]$.
3. $|g(x)| \leq K < 1$.

Sabemos que $f(x^*) = 0$ y que $f'(x^*) \neq 0$, entonces existe $\delta_1 > 0$ tal que $f'(x) \neq 0$ $\forall x \in [x^* - \delta_1, x^* + \delta_1] \subset [a,b]$.

Por lo tanto g está bien definida y es continua en $[x^* - \delta_1, x^* + \delta_1]$.

Como $g(x) = x - \frac{f(x)}{f'(x)}$,

$$g'(x) = 1 - \frac{f'(x)f'(x) - f(x)f''(x)}{(f'(x))} = \frac{(f'(x))^2 - (f'(x))^2 + f(x)f''(x)}{(f'(x))} = \frac{f(x)f''(x)}{(f'(x))},$$

y por lo tanto $g'(x^*) = \frac{f(x^*)f''(x^*)}{(f'(x^*))} = 0$, y es continua en el intervalo $[x^* - \delta_1, x^* + \delta_1]$. Tomo $K \in (0,1)$, entonces existe $\delta \in (0, \delta_1)$ tal que $|g'(x)| < K$, para todo $x \in [x^* - \delta, x^* + \delta]$.

Veamos que $g(x) \in [x^* - \delta, x^* + \delta]$. Esto es, $|g(x) - x^*| \leq \delta$. Para probar esto, utilizaremos que $g(x^*) = x^* - \frac{f(x^*)}{f'(x^*)} = x^*$ (ya que por hipótesis $f(x^*) = 0$) y el TVM.

$$|g(x) - x^*| = |g(x) - g(x^*)| = |g'(c)||x - x^*| \leq K|x - x^*| < |x - x^*| < \delta.$$

Por lo tanto, g cumple las hipótesis del punto fijo. Esto quiere decir que la sucesión $x_{n+1}n = g(x_n)$ converge a un único punto fijo x^* para cualquier punto inicial $x_0 \in [x^* - \delta, x^* + \delta]$.

□

Veamos la velocidad de convergencia $|x_{n+1} - x_n| < C|x_1 - x^*|^2$.

Tomemos la sucesión $l_n = x_n - x^*$, $l_{n+1} = x_{n+1} - x^*$. Y a su vez,

$$l_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} - x^* = x_n - x^* - \frac{f(x_n)}{f'(x_n)} = l_n - \frac{f(x_n)}{f'(x_n)} = \frac{l_n f'(x_n) - f(x_n)}{f'(x_n)}. \tag{1}$$

Por otro lado, usando Taylor alrededor de x_n tenemos que

$$0 = f(x^*) = f(x_n) + f'(x_n)(x^* - x_n) + \frac{f''(\alpha)}{2}(x^* - x_n)^2 = f(x_n) - f'(x_n)l_n + \frac{f''(\alpha)}{2}l_n^2.$$

Entonces,

$$l_n f'(x_n) - f(x_n) = \frac{f''(\alpha)}{2}l_n^2.$$

Volviendo a (1), tenemos que

$$l_{n+1} = \frac{1}{2}\frac{f''(\alpha)}{f'(x_n)}l_n^2$$

y

$$|l_{n+1}| = |\frac{f''(\alpha)}{2f'(x_n)}||l_n^2|.$$

Por lo tanto,

$$|x_{n+1} - x^*| = \frac{1}{2}|\frac{f''(\alpha)}{f'(x_n)}||x_n - x^*|^2 < C|x_n - x^*|^2.$$

esta última cota se obtiene porque tanto f' como f'' son acotadas en un intervalo cerrado, y $f'(x_n)$ no puede tender a cero.

Por lo tanto la velocidad de convergencia es cuadrática.

Ventajas

- **Rapidez de Convergencia**: El método puede converger muy rápidamente si la aproximación inicial está lo suficientemente cerca de la raíz y si la función cumple ciertas condiciones.
- **Simplicidad**: La fórmula es sencilla y fácil de implementar en software.

Desventajas

- **Dependencia de la Aproximación Inicial**: La elección de una buena aproximación inicial es crucial. Un valor muy alejado o mal elegido puede llevar a una convergencia lenta o a la divergencia.
- **Problemas con Derivadas**: Si la derivada $f'(x)$ es cero o muy pequeña cerca de la raíz, el método puede fallar o volverse inestable.

Algoritmo

ENTRADA : Función $f(x)$ continua en $[a, b]$. Aproximación inicial $x_0 \in [a, b]$, una tolerancia ε y número máximo de iteraciones, N.

SALIDA: Una soluciòn aproximada x^* o un mensaje de fracaso.

Paso 1. $i = 1$

Paso 2. Mientras $i \leq N$, realizar los pasos 3 a 6.

Paso 3. Si $f'(x_0) = 0 \to$ Parar, FRACASO.
Sino, hacer $x^* = x_0 - \frac{f(x_0)}{f'(x_0)}$.

Paso 4. Si $|x^* - x_0| < \varepsilon$, ÉXITO x^* es la solución aproximada.

Paso 5. $i = i + 1$

Paso 6. $x_0 = x^*$

Paso 7. Detener el proceso, FRACASO.

Observación 3.3. *Es necesario chequear en cada iteración que $f'(x_0) \neq 0$ porque pueden arrastrarse errores de redondeo.*

Ejemplo 3.4. *Consideremos la función $f(x) = x^3 + 4x^2 - 1$ en $[1, 2]$, con $x_0 = 1,5$ como aproximación inicial.*

Consideramos la función $f(x) = x^3 + 4x^2 - 10$ en el intervalo $[1, 2]$. Vamos a aplicar el método de Newton-Raphson con una tolerancia de 10^{-3}. La fórmula iterativa del método es:

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}.$$

Primero, calculamos la derivada:

$$f'(x) = 3x^2 + 8x$$

Iteraciones del Método de Newton-Raphson

n	x_n	$f(x_n)$	$f'(x_n)$	x_{n+1}
0	1.5	$f(1.5) = 2.375$	$f'(1.5) = 18.75$	1.3733
1	1.3733	$f(1.3733) \approx -0.3849$	$f'(1.3733) \approx 16.6389$	1.3964
2	1.3964	$f(1.3964) \approx 0.5312$	$f'(1.3964) \approx 17.0040$	1.3651
3	1.3651	$f(1.3651) \approx 0.0008$	$f'(1.3651) \approx 16.5123$	1.3651

El método converge a la raíz con una tolerancia de 10^{-3} después de 3 iteraciones. La estimación final de la raíz es aproximadamente $x \approx 1.3651$, con la diferencia entre x_{n+1} y x_n siendo menor que 10^{-3}.

El siguiente teorema nos garantiza la convergencia del método.

Teorema 3.5. *Sea $f \in C^2$ tal que $f'(x) > 0$ $\forall x \in \mathbf{R}$ y $f''(x) > 0$. Si f tiene un cero, es único y el de Newton converge a x^* a partir de cualquier punto inicial x_0.*

Proof.

1. Si $x_0 < x^* \to x_1 > x^*$. Supongamos que $x_0 < x^*$, por Taylor

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2}f''(\alpha)(x - x_0)^2 > f(x_0) + f'(x_0)(x - x_0),$$

   y esta es la aproximación lineal de f en x_0, $L(x_1) = 0 \to f(x_1) > 0$.

   Como es creciente y $f(x^*) = 0$, $x_1 > x^*$.

2. Veamos que $x_k > x^* \Rightarrow x^* < x_{k+1} < x_k$.

   Como f es creciente, si $x_k > x^* \Rightarrow f(x_k) > f(x^*)$.

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} < x_k.$$

   Falta ver que $x_{k+1} > x^*$.

$$f(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{f''(\beta)}{2}(x - x_k)^2 > f(x_k) + f'(x_k)(x - x_k),$$

   que es la aproximación lineal, $L(x_{k+1})$. Entonces, $f(x_{k+1}) > 0$ y por lo tanto, como f es creciente, $x_{k+1} > x^*$.

   Podemos concluir que si $x_k > x^* \Rightarrow x^* < x_{k+1} < x_k$.

Por lo tanto, la sucesión $\{x_k\}$ es monótona decreciente y acotada, por lo tanto converge. Solo nos falta ver que converge a x^*.

Supongamos que $lim_{k\to\infty} x_k = y$. Entonces,

$$y = \lim_{k\to\infty} x_{k+1} = \lim_{k\to\infty} x_k - \frac{f(x_k)}{f'(x_k)},$$

pero usando la continuidad de f y f'

$$\lim_{k\to\infty} x_k - \frac{f(x_k)}{f'(x_k)} = y - \frac{f(y)}{f'(y)}.$$

Por lo tanto,

$$y = y - \frac{f(y)}{f'(y)} \Rightarrow \frac{f(y)}{f'(y)} = 0 \Rightarrow f(y) = 0,$$

y esto implica que $x^* = y$ porque x^* es la única raíz de f.

□

Ejemplo 3.6. *En este ejemplo, se puede ver que el método de Newton falla. Consideremos* $F(x) = x^3 - x$ *en* $[-1, 1]$ *con* $x_0 = \frac{1}{\sqrt{5}}$.

Dada la función $F(x) = x^3 - x$*, aplicamos el método de Newton-Raphson con el punto inicial* $x_0 = \frac{1}{\sqrt{5}}$.

Primero, calculamos la derivada:

$$F'(x) = 3x^2 - 1$$

Cálculo de las iteraciones:
Punto inicial: $x_0 = \frac{1}{\sqrt{5}}$
Iteración 1:

- *Evalúo* $F(x_0)$*:*

$$F\left(\frac{1}{\sqrt{5}}\right) = \left(\frac{1}{\sqrt{5}}\right)^3 - \frac{1}{\sqrt{5}} = \frac{1}{5\sqrt{5}} - \frac{1}{\sqrt{5}} = \frac{1-5}{5\sqrt{5}} = -\frac{4}{5\sqrt{5}}$$

- *Evalúo* $F'(x_0)$*:*

$$F'\left(\frac{1}{\sqrt{5}}\right) = 3\left(\frac{1}{\sqrt{5}}\right)^2 - 1 = \frac{3}{5} - 1 = -\frac{2}{5}$$

- *Calculo* x_1*:*

$$x_1 = x_0 - \frac{F(x_0)}{F'(x_0)} = \frac{1}{\sqrt{5}} - \frac{-\frac{4}{5\sqrt{5}}}{-\frac{2}{5}} = \frac{1}{\sqrt{5}} - \frac{4}{2\sqrt{5}} = \frac{1}{\sqrt{5}} - \frac{2}{\sqrt{5}} = \frac{1-2}{\sqrt{5}} = -\frac{1}{\sqrt{5}}$$

Iteración 2:

- *Evalúo* $F(x_1)$*:*

$$F\left(-\frac{1}{\sqrt{5}}\right) = \left(-\frac{1}{\sqrt{5}}\right)^3 - \left(-\frac{1}{\sqrt{5}}\right) = -\frac{1}{5\sqrt{5}} + \frac{1}{\sqrt{5}} = \frac{-1+5}{5\sqrt{5}} = \frac{4}{5\sqrt{5}}$$

- *Evalúo* $F'(x_1)$*:*

$$F'\left(-\frac{1}{\sqrt{5}}\right) = 3\left(-\frac{1}{\sqrt{5}}\right)^2 - 1 = \frac{3}{5} - 1 = -\frac{2}{5}$$

- *Calculo* x_2*:*

$$x_2 = x_1 - \frac{F(x_1)}{F'(x_1)} = -\frac{1}{\sqrt{5}} - \frac{\frac{4}{5\sqrt{5}}}{-\frac{2}{5}} = -\frac{1}{\sqrt{5}} - \frac{4}{2\sqrt{5}} = -\frac{1}{\sqrt{5}} + \frac{2}{\sqrt{5}} = \frac{-1+2}{\sqrt{5}} = \frac{1}{\sqrt{5}}$$

Después de dos iteraciones, el método volvió al punto inicial $x_0 = \frac{1}{\sqrt{5}}$.

4 Normas vectoriales

En álgebra lineal y análisis matemático, una **norma** es una función que asigna a cada vector en un espacio vectorial un número no negativo, que intuitivamente representa la "longitud" o "magnitud" del vector. Una norma debe cumplir ciertas propiedades que garantizan que se comporta de manera adecuada como medida de tamaño. En este curso trabajaremos en el espacio $\mathbb{R}^n$.

Definición 4.1. *Una norma en $\mathbb{R}^n$ es una función $\|\cdot\| : \mathbb{R}^n \to \mathbb{R}$ que satisface las siguientes propiedades:*

1. ***No negatividad:***
$$\|v\| \geq 0 \quad \textit{para todo } v \in \mathbb{R}^n$$
y
$$\|v\| = 0 \textit{ si y sólo si } v = 0.$$

2. ***Homogeneidad positiva:***
$$\|\alpha v\| = |\alpha| \cdot \|v\| \quad \textit{para todo } \alpha \in \mathbb{R} \textit{ y } v \in \mathbb{R}^n.$$

3. ***Desigualdad triangular:***
$$\|u + v\| \leq \|u\| + \|v\| \quad \textit{para todo } u, v \in \mathbb{R}^n.$$

Ejemplos de Normas

Norma Euclidiana

Para $\mathbb{R}^n$, la norma euclidiana o norma 2 se define como:

$$\|\mathbf{x}\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2},$$

donde $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ es un vector en $\mathbb{R}^n$. Esta norma mide la distancia euclidiana desde el origen.

Norma 1

La norma 1 en $\mathbb{R}^n$ se define como:

$$\|\mathbf{x}\|_1 = |x_1| + |x_2| + \cdots + |x_n|,$$

y es conocida como la norma de la suma de valores absolutos. Esta norma mide la suma de las magnitudes absolutas de las componentes del vector.

Norma p

Para $\mathbb{R}^n$, la norma p se define para $1 \leq p < \infty$ como:

$$\|\mathbf{x}\|_p = \left(|x_1|^p + |x_2|^p + \cdots + |x_n|^p\right)^{1/p},$$

donde $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ es un vector en $\mathbb{R}^n$. Esta norma generaliza las normas 1 y 2 para diferentes valores de p. Para $p = 1$, obtenemos la norma 1, y para $p = 2$, obtenemos la norma euclidiana.

Para el caso $p = \infty$, la norma ℓ^∞ se define como:

$$\|\mathbf{x}\|_\infty = \max_{i=1,\ldots,n} |x_i|.$$

Esta norma mide el valor absoluto máximo de las componentes del vector.

4.1 Propiedades de las Normas

Desigualdad de Cauchy-Buniakowsky-Schwarz

Para todo $x, y \in \mathbb{R}^n$

$$x^T y = \sum_{i=1}^n x_i y_i \leq \left(\sum_{i=1}^n x_i^2\right)^{\frac{1}{2}} \left(\sum_{i=1}^n y_i^2\right)^{\frac{1}{2}} = \|x\|_2 \|y\|_2$$

Proof. Si $x = 0$ o $y = 0$ es trivial.

Supongamos que ambos son no nulos. Para cada $\lambda \in \mathbb{R}^n_+$ no nulo,

$$0 \leq \|x - \lambda y\|_2^2 = \sum_{i=1}^n (x_i - \lambda y_i)^2 = \sum_{i=1}^n x_i^2 - 2\lambda \sum_{i=1}^n x_i y_i + \sum_{i=1}^n \lambda^2 y_i^2$$

$$\Rightarrow 2\lambda \sum_{i=1}^n x_i y_i \leq \sum_{i=1}^n x_i^2 + \lambda^2 \sum_{i=1}^n y_i^2 = \|x\|_2^2 + \lambda^2 \|y\|_2^2$$

Como $y \neq 0$, puedo tomar $\lambda = \dfrac{\|x\|_2}{\|y\|_2}$

$$\Rightarrow 2\frac{\|x\|_2}{\|y\|_2} \sum_{i=1}^n x_i y_i \leq \|x\|_2^2 + \left(\frac{\|x\|_2}{\|y\|_2}\right)^2 \|y\|_2^2$$

$$\Rightarrow 2\frac{\|x\|_2}{\|y\|_2} \sum_{i=1}^n x_i y_i \leq \|x\|_2^2 + \|x\|_2^2$$

$$\Rightarrow \frac{\|x\|_2}{\|y\|_2} \sum_{i=1}^n x_i y_i \leq \|x\|_2^2$$

$$\Rightarrow \|y\|_2 \sum_{i=1}^n x_i y_i \leq \|x\|_2$$

$$\Rightarrow \sum_{i=1}^{n} x_i y_i \leq \|x\|_2 \|y\|_2$$

□

Teorema 4.2. *Para todo $x \in \mathbb{R}^n$,*

$$\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n}\|x\|_\infty$$

Proof. $\|x\|_\infty = \max_{i=1,\ldots,n} |x_i| = x_{i_0}$, para $i_0 \in \{i = 1, \ldots, n\}$. Veamos la primera desigualdad,

$$\|x\|_\infty = x_{i_0} = \sqrt{x_{i_0}^2} \leq \sqrt{x_1^2 + \ldots + x_{i_0}^2 + \ldots + x_n^2} = \|x\|_2$$

.

Para la segunda,

$$\|x\|_2 = \left(\sum_{i=1}^{n} x_i^2\right)^{\frac{1}{2}} \leq \left(\sum_{i=1}^{n} x_{i_0}^2\right)^{\frac{1}{2}} = \left(n x_{i_0}^2\right)^{\frac{1}{2}} = \sqrt{n}|x_{i_0}| = \sqrt{n}\|x\|_\infty.$$

□

En general se puede demostrar que todas las normas son equivalentes. Lo enunciamos en el siguiente Teorema.

Teorema 4.3. *Para cualquier par de normas $\|\cdot\|_a$ y $\|\cdot\|_b$, existen constantes positivas c_1 y c_2 tales que:*

$$c_1\|v\|_a \leq \|v\|_b \leq c_2\|v\|_a \quad \textit{para todo } v \in \mathbb{R}^n.$$

Definición 4.4. *Si $x, y \in \mathbb{R}^n$ y $\|\cdot\|_u$ es una norma vectorial, la distancia entre x e y se define como $d(x, y) = \|x - y\|_u$.*

Por ejemplo,

- $\|x - y\|_2 = \left(\sum_{i=1}^{n} (x_i - y_i)^2\right)^{\frac{1}{2}}$ *es la distancia que usamos habitualmente.*
- $\|x - y\|_\infty = \max_{i=1,\ldots,n} |x_i - y_i|$.

Definición 4.5. *Se dice que una sucesión $\{x^k\} \subset \mathbb{R}^n$ converge a $x \in \mathbb{R}^n$ con respecto a una norma $\|\cdot\|$ si existen $\varepsilon > 0$ y $n_o \in \mathbb{N}$ tales que*

$$\|x^k - x\| < \varepsilon, \qquad \forall n \geq n_0.$$

4.2 Normas matriciales

Las normas matriciales son herramientas fundamentales en el análisis de matrices y su comportamiento.

Definición 4.6. *Una norma en $\mathbb{R}^{n\times n}$ es una función $\|\cdot\| : \mathbb{R}^{n\times n} \to \mathbb{R}$ que cumple las siguientes propiedades para todo $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n\times n}$ y $\alpha \in \mathbb{R}$:*

1. $\|\mathbf{A}\| \geq 0$
2. $\|\mathbf{A}\| = 0$ *si y solo si* $\mathbf{A} = \mathbf{0}$.
3. $\|\alpha\mathbf{A}\| = |\alpha|\|\mathbf{A}\|$.
4. $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$.
5. $\|\mathbf{AB}\| \leq \|\mathbf{A}\|\|\mathbf{B}\|$

Observación 4.7. *Si las matrices no son cuadradas, se puede definir una norma matricial pidiendo solo las condiciones 1-4.*

Normas Matriciales Comunes

Existen varias normas utilizadas para medir matrices. Algunas de las más comunes son:

Norma 1

La norma 1 de una matriz A está definida como:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^{n} |a_{ij}|$$

donde a_{ij} son los elementos de la matriz A y n es el número de filas y columnas de A.

Consideremos la matriz

$$A = \begin{pmatrix} 1 & -2 & 3 \\ 4 & 0 & -1 \\ -2 & 5 & 1 \end{pmatrix}$$

La norma 1 de la matriz A se calcula como el máximo de las sumas de los valores absolutos de cada columna.

Primero, calculamos la suma de los valores absolutos de cada columna:

- Para la primera columna:

$$\sum_{i=1}^{3} |a_{i1}| = |1| + |4| + |-2| = 1 + 4 + 2 = 7$$

- Para la segunda columna:

$$\sum_{i=1}^{3} |a_{i2}| = |-2| + |0| + |5| = 2 + 0 + 5 = 7$$

- Para la tercera columna:

$$\sum_{i=1}^{3} |a_{i3}| = |3| + |-1| + |1| = 3 + 1 + 1 = 5$$

Ahora, tomamos el máximo de estas sumas:

$$\|A\|_1 = \max(7, 7, 5) = 7$$

Por lo tanto, la norma 1 de la matriz A es:

$$\|A\|_1 = 7$$

Norma Infinita

La norma infinita de una matriz A está dada por:

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^{n} |a_{ij}|$$

donde n es el número de filas y columnas de A.

Consideremos la matriz A:

$$A = \begin{pmatrix} 1 & -2 & 3 \\ 4 & 0 & -1 \\ -2 & 5 & 1 \end{pmatrix}$$

La norma infinito de la matriz A se calcula como el máximo de las sumas de los valores absolutos de cada fila.

Primero, calculamos la suma de los valores absolutos de cada fila:

- Para la primera fila:

$$\sum_{j=1}^{3} |a_{1j}| = |1| + |-2| + |3| = 1 + 2 + 3 = 6$$

- Para la segunda fila:

$$\sum_{j=1}^{3} |a_{2j}| = |4| + |0| + |-1| = 4 + 0 + 1 = 5$$

- Para la tercera fila:

$$\sum_{j=1}^{3} |a_{3j}| = |-2| + |5| + |1| = 2 + 5 + 1 = 8$$

Ahora, tomamos el máximo de estas sumas:

$$\|A\|_\infty = \max(6, 5, 8) = 8$$

Por lo tanto, la norma infinita de la matriz A es:

$$\|A\|_\infty = 8$$

Norma Frobenius

La norma de Frobenius se define como:

$$\|A\|_F = \sqrt{\sum_{i=1}^{n}\sum_{j=1}^{n}(a_{ij})^2}$$

Esta norma es similar a la norma Euclidiana para vectores.

Consideremos la matriz A:

$$A = \begin{pmatrix} 1 & -2 & 3 \\ 4 & 0 & -1 \\ -2 & 5 & 1 \end{pmatrix}$$

Primero, calculamos el cuadrado de los valores absolutos de cada elemento:

- $|1|^2 = 1$
- $|-2|^2 = 4$
- $|3|^2 = 9$
- $|4|^2 = 16$
- $|0|^2 = 0$
- $|-1|^2 = 1$
- $|-2|^2 = 4$
- $|5|^2 = 25$
- $|1|^2 = 1$

Ahora, sumamos todos estos valores:

$$\sum_{i=1}^{3}\sum_{j=1}^{3}(a_{ij})^2 = 1 + 4 + 9 + 16 + 0 + 1 + 4 + 25 + 1 = 61$$

Finalmente, tomamos la raíz cuadrada de la suma:

$$\|A\|_F = \sqrt{61}$$

Por lo tanto, la norma de Frobenius de la matriz A es:

$$\|A\|_F = \sqrt{61}$$

Norma Inducida

Dada una matriz $A \in \mathbb{R}^{n\times n}$ y una norma $\|\cdot\|_v$ en $\mathbb{R}^n$, la norma inducida se define como:

$$\|A\|_v = \max_{\|x\|=1} \|Ax\|_v.$$

Teorema 4.8. *La norma inducida es una norma matricial.*

- Es trivial.
- $\Rightarrow$) Si $\|A\| = 0 \Rightarrow \|A\| = \max_{\|x\|=1} \|Ax\| \Rightarrow \|Ax\| = 0 \Rightarrow Ax = 0$, pero esto vale para todo $x \in \mathbb{R}^n$ tal que $\|x\| = 1$, en particular puedo tomar el vector $e_j = (0, \ldots, 1, \ldots, 0)$ (todos ceros, salvo en el lugar j).

  $$Ae_j = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix} = \begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{pmatrix} = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}$$

  Esto lo podemos hacer para cada $j = 1, \ldots, n$. Y entonces todos elementos $a_{ij} = 0$, y por lo tanto $A = 0$.

  $\Leftarrow$) Si $A = 0$, $\Rightarrow \|A\| = \max_{\|x\|=1} \|Ax\| \max_{\|x\|=1} \|0\| = 0$.
- $\|\alpha A\| = \max_{\|x\|=1} \|\alpha Ax\| =$ usando las propiedades de las normas de vectores

  $$= \max_{\|x\|=1} |\alpha| \|Ax\| = \alpha \max_{\|x\|=1} \|Ax\| = |\alpha| \|A\|.$$
- $$\|A + B\| = \max_{\|x\|=1} \|(A + B)x\| = \max_{\|x\|=1} \|Ax + Bx\| \leq \max_{\|x\|=1} \|Ax\| + \|Bx\|$$
  $$\leq \max_{\|x\|=1} \|Ax\| + \max_{\|x\|=1} \|Bx\| = \|A\| \|B\|.$$

  Notar si $x, y\mathbb{R}$ son positivos entonces $\max x + y = \max x + \max y$.
- $$\|AB\| = \max_{\|x\|=1} \|(AB)x\| = \max_{\|x\|=1} \|A(Bx)\|.$$

  Llamemos $y = Bx$. Si $y \neq 0$,

  $$\frac{\|Ay\|}{\|y\|} = \frac{1}{\|y\|} \|Ay\|$$

  $\frac{\|Ay\|}{\|y\|} \leq \max_{\|z\|\leq 1} \{\|Az\|\} = \|A\|$.

Por lo tanto

$$\frac{1}{\|y\|}\|Ay\| \leq \|A\|$$
$$\|Ay\| \leq \|A\|\|y\|$$

Si $y = 0$

$$\|Ay\| \leq \|A\|\|y\|,$$

se cumple la igualdad.

Entones,

$$\|AB\| = \max_{\|x\|=1} \|Ay\| \leq \max_{\|x\|=1} \|y\|\|A\| = \max_{\|x\|=1} \|Bx\|\|A\| = \|A\| \max_{\|x\|=1} \|Bx\| = \|A\|\|B\|.$$

Teorema 4.9. *Dada una norma vectorial $\|\cdot\|_v$ en $\mathbb{R}^n$ y su norma matricial inducida, se verifica que*

$$\|Ax\|_v \leq \|A\|_v\|x\|_v \quad \forall x \in \mathbb{R}^n, A \in \mathbb{R}^{n\times n}.$$

Proof. Si $x = 0$ es trivial.

Si $x \neq 0$, definimos $y = \frac{x}{\|x\|}$, así $\|y\| = 1$. Entonces,

$$\|Ay\|_v \leq \max_{\|z\|=1} \|Az\|_v = \|A\|_v$$

$$\Rightarrow \|A\frac{x}{\|x\|_v}\|_v \leq \|A\|_v$$

$$\Rightarrow \|Ax\|_v \leq \|A\|_v\|x\|_v.$$

□

Teorema 4.10. *Sea $A \in \mathbb{R}^{n\times n}$.*

- $\|A\|_1 = \max_{1\leq j\leq n} \sum_{i=1}^{n} |a_{ij}|$
- $\|A\|_\infty = \max_{1\leq i\leq n} \sum_{j=1}^{n} |a_{ij}|$

Proof. $\|A\|_1 = \max_{\|x\|=1} \|Ax\|_1$.

Sea $x \in \mathbb{R}^n$ tal que $\|x\|_1 = 1 \Rightarrow \sum_{i=1}^{n} |x_1| = 1$.

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^{n} a_{1j}x_j \\ \sum_{j=1}^{n} a_{2j}x_j \\ \vdots \\ \sum_{j=1}^{n} a_{nj}x_j \end{pmatrix}$$

$$\|Ax\|_1 = \sum_{i=1}^{n}(Ax)_i = \sum_{i=1}^{n}(Ax)_i = \sum_{i=1}^{n}\left|\sum_{j=1}^{n} a_{ij}x_j\right|$$

$$\leq \sum_{i=1}^{n}\sum_{j=1}^{n}|a_{ij}||x_j| \leq \sum_{j=1}^{n}|x_j|\sum_{i=1}^{n}|a_{ij}| \leq \sum_{j=1}^{n}|x_j|\max_{j=1,\ldots,n}\sum_{i=1}^{n}|a_{ij}|$$

$$= \max_{j=1,\ldots,n}\sum_{i=1}^{n}|a_{ij}|\sum_{j=1}^{n}|x_j| = \max_{j=1,\ldots,n}\sum_{i=1}^{n}|a_{ij}|.$$

Veamos la otra desigualdad. Para eso tomamos $e_j = \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix}$

$$\left\|\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}\begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix}\right\| = \left\|\begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{pmatrix}\right\|_1 = \sum_{i=1}^{n}|a_{ij}|.$$

Por lo tanto,

$$\|A\|_1 = \max_{\|x\|_1=1}\|Ax\|_1 \geq \|Ae_j\|_1, \quad \forall j = 1,\ldots,n,$$

$$\Rightarrow \|A\|_1 \geq \max_j \|Ae_j\|_1 = \max_j \sum_{i=1}^{n}|a_{ij}|.$$

□

5 Sistemas de ecuaciones lineales

Un sistema de ecuaciones lineales consiste en un conjunto de ecuaciones lineales que comparten las mismas variables. La forma general de un sistema de m ecuaciones con n incógnitas es:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &= b_m \end{aligned}$$

Donde a_{ij} son coeficientes, x_j son las incógnitas y b_i son los términos independientes.
Las soluciones de un sistema pueden ser:

- **Única**: Cuando hay un único vector que satisface todas las ecuaciones.
- **Infinitas**: Cuando hay múltiples soluciones.
- **Ninguna**: Cuando no hay un vector que satisface todas las ecuaciones en simultaneo.

5.1 Eliminación Gaussiana*

La eliminación gaussiana es un método para resolver sistemas de ecuaciones lineales. Consiste en transformar el sistema en una forma escalonada utilizando operaciones elementales. Los sistemas de ecuaciones lineales son de la forma

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n \end{aligned}$$

Donde:

- a_{ij} son los coeficientes del sistema.
- x_j son las incógnitas que queremos encontrar.
- b_i son los términos independientes.

También se pueden escribir de manera matricial como $AX = b$, donde $A \in \mathbb{R}^{n\times n}$, $x \in \mathbb{R}^n$ y $b \in \mathbb{R}^n$.

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} & b_n \end{pmatrix}$$

Tenemos tres tipos de operaciones elementales

- Intercambiar o permutar dos filas.
- Multiplicar una fila por un escalarno nulo.
- Sumar a una fila un múltiplo de otra fila.

Sabemos que si la matriz A es no singular, el sistema tiene única solución y es equivalente por filas a una matriz triangular superior, que llamaremos U. Entonces,

$$U = \begin{pmatrix} u_{11} & u_{12} & u_{13} & \cdots & u_{1n} \\ 0 & u_{22} & u_{23} & \cdots & u_{2n} \\ 0 & 0 & u_{33} & \cdots & u_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & u_{nn} \end{pmatrix}$$

Entonces los sistemas $Ax = b$ y $Ux = \bar{b}$ tienen la misma solución (donde $\bar{b}$ es el vector que se obtiene de realizar las mismas operaciones elementales que se le realizaron a la matriz A).

Observemos ahora que el sistema $Ux = \bar{b}$ se resuelve fácilmente haciendo sustitución desde la última fila hacia arriba.

Consideremos el siguiente ejemplo,

Consideremos el siguiente sistema de ecuaciones lineales:

$$\begin{aligned} 6x_1 - 2x_2 + 2x_3 + 4x_4 &= 12 \\ 12x_1 - 8x_2 + 6x_3 + 10x_4 &= 34 \\ 3x_1 - 13x_2 + 9x_3 + 3x_4 &= 27 \\ -6x_1 + 4x_2 + x_3 - 18x_4 &= -38 \end{aligned}$$

La matriz aumentada del sistema es:

$$\left(\begin{array}{cccc|c} 6 & -2 & 2 & 4 & 12 \\ 12 & -8 & 6 & 10 & 34 \\ 3 & -13 & 9 & 3 & 27 \\ -6 & 4 & 1 & -18 & -38 \end{array}\right)$$

Usamos solo sumas de filas. Para hacer esto, primero nos enfocamos en la primera fila. Realizaremos las siguientes operaciones:

1. Fila 2: $F_2 - 2F_1$
2. Fila 3: $F_3 - \frac{1}{2}F_1$
3. Fila 4: $F_4 + F_1$

Ahora nuestra matriz aumentada se ve así:

$$\left(\begin{array}{cccc|c} 6 & -2 & 2 & 4 & 12 \\ 0 & -4 & 2 & 2 & 10 \\ 0 & -12 & 8 & 1 & 21 \\ 0 & 2 & 3 & -14 & -26 \end{array}\right)$$

Ahora usaremos la segunda fila para eliminar los elementos debajo de ella. Realizaremos:

1. Fila 3: $F_3 - 3F_2$
2. Fila 4: $F_4 + \frac{1}{2}F_2$

$$\left(\begin{array}{cccc|c} 6 & -2 & 2 & 4 & 12 \\ 0 & -4 & 2 & 2 & 10 \\ 0 & 0 & 2 & -5 & -9 \\ 0 & 4 & 4 & -12 & -21 \end{array}\right)$$

Hemos transformado el sistema a una forma escalonada sin multiplicar filas por un escalar, usando solo sumas de filas.

Ahora se puede proceder a resolver el sistema por sustitución hacia atrás.

Llamaremos *multiplicador* a la constante que utilizamos para hacer cero a un elemento debajo de un pivote. Si buscamos hacer cero el elemento a_{ij} hago

$$F_i - mF_j.$$

en ejemplo anterior, hicimos $F_2 - 2F_1$, en este maso el multiplicador $m_{21} = 2$, para hacer cero el elemento a_{21}.

$$\begin{array}{lll} m_{21} = 2 & & \\ m_{31} = 1/2 & m_{32} = 3 & \\ m_{41} = -1 & m_{42} = -1/2 & m_{43} = 2 \end{array}$$

Nos preguntamos ¿Cuándo puedo hallar o existe la matriz U?

Definición 5.1. *Dada $A \in \mathbb{R}^{n\times n}$ llamamos submatriz de A de orden k a la matriz*

$$A_k = (a_{ij})_{1\leq i,j\leq k}$$

Ejemplo 5.2. *Si considero la matriz*

$$A = \begin{pmatrix} 3 & -1 & 3 \\ 0 & 4 & 3 \\ 5 & 2 & 1 \end{pmatrix}$$

Si para todo $k = 1, \ldots, n$ la submatriz A_k es no singular, entonces A puede transformarse en una matriz U, equivalente por filas, triangular superior con operaciones del tipo 3.

Llamaremos *fase de triangulación* al procedimiento que nos permite hallar U a partir de A.

Sea $A \in \mathbb{R}^{n\times n}$ tal que A_k es no singular, la reducción se llava a cabo en $n-1$ pasos.

- Se hacen cero las entradas $(2,1), (3,1), \ldots, (n,1)$ de $A = A^0$.Se puede hacer porque A_1 es no singular, lo que significa que $a_{11} \neq 0$.

$$(A^0|b^0) \to (A^1|b^1)$$

$$A^1 = \begin{pmatrix} a^0_{11} & a^0_{12} & \cdots & a^0_{1n} \\ 0 & a^1_{22} & \cdots & a^1_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a^1_{n2} & \cdots & a^1_{nn} \end{pmatrix}$$

- Se hacen cero las entradas $(3,2), (4,2), \ldots, (n,2)$ de A^1. Necesitamos que $a^1_{22} \neq 0$. Sabemos que el la submatiz A_2 es no singular, entonces

$$0 \neq det(A_2) = det \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} = det \begin{pmatrix} a^0_{11} & a^0_{12} \\ 0 & a^1_{22} \end{pmatrix} = a^0_{11}a^1_{22}$$

  Recordemos que las operaciones elementales de tipo 3 no cambian el determinante y $a^0_{11} \neq$ entonces podemos asegurar que $a^1_{22} \neq 0$.

$$A^2 = \begin{pmatrix} a_{11}^0 & a_{12}^1 & a_{13}^0 \cdots & a_{1n}^0 & \\ 0 & a_{22}^1 & a_{31}^1 & \cdots & a_{2n}^1 \\ 0 & 0 & a_{33}^2 & \cdots & a_{3n}^2 \\ \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & a_{n3}^2 & \cdots & a_{nn}^2 \end{pmatrix}$$

- Para el siguiente paso, necesitamos que $a_{33}^2 \neq 0$. Para ver eso, analicemos el determinanate de la submatriz A_3.

$$0 \neq det(A_3) = det \begin{pmatrix} a_{11}^0 & a_{12}^0 & a_{13}^0 \\ a_{21}^0 & a_{22}^0 & a_{23}^0 \\ a_{31}^0 & a_{32}^0 & a_{33}^0 \end{pmatrix} = det \begin{pmatrix} a_{11}^0 & a_{12}^0 & a_{13}^0 \\ 0 & a_{22}^1 & a_{23}^1 \\ 0 & 0 & a_{33}^2 \end{pmatrix} = a_{11}^0 a_{22}^1 a_{33}^2.$$

  por lo tanto $a_{33}^2 \neq 0$.

- Así podriamos continuar $n-1$ veces.

Ejemplo 5.3. *Consideremos el sistema*

$$\begin{aligned} 4x_2 + x_3 &= 9 \\ x_1 + x_2 + 3x_3 &= 6 \\ 2x_1 - 2x_2 + x_3 &= -1 \end{aligned}$$

Supongamos que cada submatriz A_k es no singular, se realizaron las siguientes operaciones para cada $i = k+1, \ldots, n$

$$m_{ik} = \frac{a_{ik}^{k-1}}{a_{kk}^{k-1}}$$

$$a_{ij}^k = a_{ij}^{k-1} - m_{ik} a_{kj}^{k-1}$$

y

$$b_i^k = b_i^{k-1} - m_{ik} b_k^{k-1}$$

En el siguiente ejemplo vamos a observar que es mejor permutar filas para evitar que se produzcan errores grandes el obtener la solución del problema.

Ejemplo 5.4. *Sondideremos el sistema*

$$\begin{aligned} 0,003x_1 + 59,14x_2 &= 59,17 \\ 5,291x_1 - 6,13x_2 &= 46,78 \end{aligned}$$

La solución exacta del problema es $x^* = \begin{pmatrix} 10 \\ 1 \end{pmatrix}$

Primero resolvemos el sistema sin realizar permutaciones con una aritmética de 4 dígitos.

Para evitar lo que sucede en la primera resolución se utiliza la técnica de pivoteo máximo. La idea es elegir como pivote el máximo en valor absoluto de la columna.

6 Cotas de errores

Sea $\bar{x}$ una solución aproximada de la solución x^* del sistema $Ax = b$ definimos el *residuo* como

$$\bar{x} = b - Ax.$$

Uno podría decir que si $\|\bar{r}\|$ es cercano a cero, uno tiene una buena aproximación, pero esto no es cierto, veamoslo con el siguiente ejemplo:

Ejemplo 6.1. *Consideramos la matriz* $A = \begin{pmatrix} 1 & 2 \\ 1,0001 & 2 \end{pmatrix}$ *y* $b = \begin{pmatrix} 3 \\ 3,0001 \end{pmatrix}$. *La solución es* $x^* = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$

Definición 6.2. *Sea* $A \in \mathbb{R}^{n\times n}$ *no singular, se define el número de condición de* A *con respecto a una norma* $\|\cdot\|$ *como*

$$K(A) = \|A\|\|A^{-1}\|.$$

Observar que $K(A) \geq 1$.

Decimos que A es bien condicionada si $K(A)$ es cercano a 1.

Teorema 6.3. *Sea* $\bar{x}$ *un aproximación de la solución* x^* *del sistema* $Ax = b$, A *no singular. Entonces,*

$$\|x^* - \bar{x}\| \leq \|\bar{r}\|\|A^{-1}\|$$

y

$$\frac{\|x^* - \bar{x}\|}{\|x^*\|} \leq K(A)\frac{\|\bar{r}\|}{\|b\|}$$

para todo x^*, b *no nulos.*

Proof. □

Observación 6.4. *Si $K(A)$ es cercano a 1, la cota del error es pequeño.*

Retomamos el ejemplo anterior.

6.1 Perturbaciones en el vector b

Sea A una matriz no singular, consideramos el sistema $Ax = b$, $b \neq 0$, $x \neq 0$ tal que $Ax^* = b$.

Si el vector b, obviamente el sistema se ve perturbado, es decir

$$Ax = b + \delta b.$$

Nos peguntamos, ¿Cuál es la cota del error relativo?

Sea $\bar{x} = x * +\delta x^*$ la solución del sistema $Ax = b + \delta b$.

$$\begin{array}{rcl} A\bar{x} & = & b + \delta b \\ A(x^* + \delta x^*) & = & b + \delta b \\ Ax^* + A\delta x^*) & = & b + \delta b \\ b + A\delta x^* & = & b + \delta b \end{array}$$

Entonces

$$A\delta x^* = \delta b \Rightarrow \delta x^* = A^{-1}\delta b.$$

Por lo tanto,

$$\|\delta x^*\| = \|A^{-1}\delta b\| \leq \|A^{-1}\|\|\delta b\| \tag{2}$$

Por otro lado,

$$Ax^* = b \Rightarrow \|b\| = \|Ax^*\| \leq \|A\|\|x^*\| \Rightarrow$$

$$\frac{1}{\|x^*\|} \leq \frac{\|A\|}{\|b\|}. \tag{3}$$

De (2) y (3) tenemos que

$$\frac{\delta x^*}{x^*} \leq \|A^{-1}\|\|A\|\frac{\delta b}{b}$$

$$\frac{\bar{x} - x^*}{x^*} \leq K(A)\frac{\delta b}{b}$$

6.2 Perturbaciones en A

7 Factorización LU y Cholesky

7.1 Factorización LU

La descomposición LU es un método que permite factorizar una matriz cuadrada A en el producto de dos matrices: una matriz triangular inferior L y una matriz triangular superior U. Este método es especialmente útil para resolver sistemas de ecuaciones lineales, calcular determinantes y realizar la inversión de matrices.

Dada una matriz cuadrada $A \in \mathbb{R}^{n\times n}$, la descomposición LU consiste en encontrar matrices L y U tales que:

$$A = LU$$

donde:

- L es una matriz triangular inferior con unos en la diagonal:

$$L = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ l_{21} & 1 & 0 & \cdots & 0 \\ l_{31} & l_{32} & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & l_{n3} & \cdots & 1 \end{pmatrix}$$

- U es una matriz triangular superior:

$$U = \begin{pmatrix} u_{11} & u_{12} & u_{13} & \cdots & u_{1n} \\ 0 & u_{22} & u_{23} & \cdots & u_{2n} \\ 0 & 0 & u_{33} & \cdots & u_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & u_{nn} \end{pmatrix}$$

Veamos porque la construcción de la matriz L queda de esta forma. En el proceso de la eliminación Gausseana, para $K = 1$ hicimos las siguientes operaciones elementales:
Fila 2: $F_2 - m_{21}F_1$
Fila 3: $F_3 - m_{31}F_1$
$\vdots$
Fila n: $F_n - m_{n1}F_1$

Donde $m_{j1} = -\frac{a_j1}{a_{11}}$, Esto es lo mismo que pensar en multiplicar a la matriz A a izquierda por la matriz elemental

$$E_1 = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ -m_{21} & 1 & 0 & \cdots & 0 \\ -m_{31} & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -m_{n1} & 0 & 0 & \cdots & 1 \end{pmatrix}$$

De esta manera tengo que $A^2 = E_1A$.

En el segundo paso de la eliminación Gausseana, multiplicamos por la matriz elemental

$$E_2 = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & -m_{32} & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & -m_{n2} & 0 & \cdots & 1 \end{pmatrix}$$

De esta manera tengo que $A^3 = E_2 A^1 = E_2 E_1 A$.

En el k-ésimo paso de la eliminación Gausseana, multiplicamos por la matriz elemental

$$E_k = \begin{pmatrix} 1 & 0 & \cdots & 0 & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 & 0 \\ 0 & 0 & \cdots & 1 & 0 & 0 \\ 0 & 0 & \cdots & -m_{k+1k} & 1 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & -m_{nk} & 0 & 1 \end{pmatrix}$$

De esta manera voy a llegara a que

$$U = E_{n-1} E_{n-2} \dots E_2 E_1 A.$$

O lo que es equivalente

$$A = E_{n-1}^{-1} E_{n-2}^{-1} \dots E_2^{-1} E_1^{-1} U.$$

Pero

$$E_k^{-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 & 0 \\ 0 & 0 & \cdots & 1 & 0 & 0 \\ 0 & 0 & \cdots & m_{k+1k} & 1 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & m_{nk} & 0 & 1 \end{pmatrix}$$

Por lo tanto la matriz L que da de la forma

$$L = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ m_{21} & 1 & 0 & \cdots & 0 \\ m_{31} & m_{32} & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ m_{n1} & m_{n2} & m_{n3} & \cdots & 1 \end{pmatrix}$$

Ejemplo 7.1. *Hallar la descomposición LU de la siguiente matriz*

$$A = \begin{pmatrix} 1 & 1 & 2 \\ 1 & 2 & 1 \\ 2 & 1 & 1 \end{pmatrix}$$

Observación 7.2. *1. Resolver el sistema $Ax = b$ es equivalente a resolver $LUx = b$. Si llamamos $y = Ux$, puedo resolver el sistema $Ly = b$, hallar y y luego resolver el sistema $y = Ux$ para hallar la solución buscada, x.*

2. *Como $A = LU$, $det(A) = det(L)det(U) = det(U)$. Y U es una matriz triangular, su determinante se calcula fácilmente como el producto de los elementos de la diagonal.*

Ejemplo 7.3. *Hallar la descomposición LU de la siguiente matriz*

$$A = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 1 & 2 \\ 1 & 2 & 2 \end{pmatrix}$$

y hallar la solución del sistema $Ax = b$ para $b = \begin{pmatrix} 6 \\ 6 \\ 7 \end{pmatrix}$.

Que pasa si tengo un 0 en un pivote?

Tengo la necesidad de hacer una permutación. Por ejemplo, si queremos resolver el sistema

$$\begin{pmatrix} 0 & 4 & 1 \\ 1 & 1 & 3 \\ 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 9 \\ 6 \\ -1 \end{pmatrix}$$

El pivoteo parcial o máximo en la factorización LU tiene varias ventajas importantes:

1. Al realizar el pivoteo parcial, se reduce la posibilidad de errores de redondeo y se mejora la precisión de los cálculos, ya que se utiliza el mayor elemento absoluto de la columna como pivote.

2. Evita divisiones por cero.

3. El pivoteo ayuda a gestionar mejor situaciones en las que la matriz tiene valores muy pequeños o la presencia de números grandes, lo que puede llevar a inestabilidad en los resultados.

Teorema 7.4. *Dada $A \in \mathbb{R}^{n \times n}$ no singular, entonces existe una factorización LU de A o de alguna permutación y es única.*

Proof. Demostremos la unicidad de la factorización. Supongamos que tenemos dos factorizaciones LU de A de la forma $A = L_1U_1 = L_2U_2$, Como U_1, U_2 son matrices triangulares superiores, más aún sus inversas son igualmente triangulares superiores. De esta última igualdad obtenemos entonces $(L_2)^{-1}L_1 = U_2(U_1)^{-1}$. El lado izquierdo de esta igualdad es producto de matrices triangulares inferiores con unos en la diagonal, por lo tanto es triangular inferior y tiene unos en la diagonal principal. Igualmente, el lado derecho es una matriz triangular superior, pues es producto de matrices triangulares superiores. Entonces $(L_2)^{-1}L_1 = U_2(U_1)^{-1} = Id$, de eso sigue que $L_1 = L_2$ y por ende, $U_1 = U_2$.

□

7.2 Cholesky

El método de Cholesky es un algoritmo de factorización de matrices que permite descomponer una matriz A simétrica y definida positiva en el producto de una matriz triangular inferior R y su transpuesta:

$$A = RR^T$$

donde R^T es la transpuesta de R.

Para que se pueda aplicar el método de Cholesky, la matriz A debe cumplir con las siguientes condiciones:

- A debe ser simétrica: $A = A^T$.
- A debe ser definida positiva: $x^T Ax > 0$ para todo $x \neq 0$.

Lemma 7.5. *Si A es definida positiva, entonces es invertible.*

Proof. Por el contra recíproco. Si A no tiene inversa, entonces existe x tal que $Ax = 0$, pero entonces para ese x, $xAx = 0$, y esto no puede suceder porque A es definida positiva. □

Teorema 7.6. *Si A es simétrica y definida positiva, entonces puede factorizarse de manera única como $A = RR^T$, donde R es una matriz triangular inferior y además $r_{ii} > 0$.*

Proof. Por el lema anterioro sabemos que A es no singular, y por lo tanto existe la descomposición LU, es decir,

$$A = LU$$

, donde L es una matriz triangular inferior con $l_{ii} = 1$ y U es una matriz triangular superior.

Como $A = A^T$, porque A es simétrica,

$$LU = (LU)^T = U^T L^T$$

$$\Rightarrow U = L^{-1} U^T L^T$$

$$\Rightarrow U(L^T)^{-1} = L^{-1} U^T.$$

Observando esta igualdad vemos que la parte izquierda es una matriz triangular superior, pero la parte derecha es una matriz triangular inferior. Entonces $D = U(L^T)^{-1} = L^{-1}U^T$ es una matriz diagonal, que además es no singular ya que $det(D) = det(U(L^T)^{-1}) = det(U)det(L)^{-1} \neq 0$.

$$D = U(L^T)^{-1} \Rightarrow DL^T = U$$

$$\Rightarrow A = LU = LDL^T$$

Mostremos que D es definida positiva, esto $\forall y \in \mathbb{R}^n$ $y \neq 0$, $y^T Dy > 0$.

Como L es no singular $\exists x \neq 0$ tal que $L^T x = y$.

Entonces,

$$yDy^T = (L^T x)^T DL^T x = x^T LDL^T x = x^T Ax > 0.$$

Lo que concluye que D es definida positiva.

Si en particular tomo $Y = e_i$. Para cada i tengo que

$$e_i^T De_i = d_{ii} > 0.$$

Y entonces puedo escribir a A como

$$A = LD^{1/2}D^{1/2}L^T.$$

Como los la descomposición LU es única, R y R^T también.

$\square$

Ejemplo 7.7. *Hallar la descomposición de Cholesky de la matriz* $A = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{pmatrix}$

Teorema 7.8. *Sea $M \in \mathbb{R}^{n\times n}$, no singular. Entonces $A = MM^T$ es simétrica y definida positiva.*

Proof. Veamos primero que es simétrica.

$$A^T = (MM^T)^T = (M^T)^T M^T = MM^T = A.$$

Veamos ahora que es definida positiva. Sea $x \neq 0$,

$$x^T Ax = x^T MM^T x = yy^T = \|y\|_2^2 > 0$$

si $y = M^T x$. Observar que no puede cumplirse la igualdad porque M es no singular y $x \neq 0$.

$\square$

Proceso de Factorización

Para obtener la matriz L, se procede de la siguiente manera:

1. Se parte de la matriz A:

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix}$$

2. Se calcula L de la siguiente forma:

$$R = \begin{pmatrix} r_{11} & 0 & 0 & \dots & 0 \\ r_{21} & r_{22} & 0 & \dots & 0 \\ r_{31} & r_{32} & r_{33} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ r_{n1} & r_{n2} & r_{n3} & \dots & r_{nn} \end{pmatrix}$$

3. Se calcula cada elemento r_{ij} usando las siguientes fórmulas:

- Para $i = j$:

$$r_{ii} = \sqrt{a_{ii} - \sum_{k=1}^{i-1} r_{ik}^2}$$

- Para $i > j$:

$$r_{ij} = \frac{1}{r_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} r_{ik} r_{jk} \right)$$

Ejemplo 7.9. *Supongamos que tenemos la siguiente matriz:*

$$A = \begin{pmatrix} 4 & 12 & -16 \\ 12 & 37 & -43 \\ -16 & -43 & 98 \end{pmatrix}$$

Aplicando el método de Cholesky, calculamos R:
1. $r_{11} = \sqrt{4} = 2$
2. $r_{21} = \frac{12}{2} = 6$
3. $r_{31} = \frac{-16}{2} = -8$
4. $r_{22} = \sqrt{37 - 6^2} = 1$
5. $r_{32} = \frac{-43-(-8)(6)}{1} = -5$
6. $r_{33} = \sqrt{98 - (-8)^2 - (-5)^2} = 3$
Finalmente, la matriz R es:

$$R = \begin{pmatrix} 2 & 0 & 0 \\ 6 & 1 & 0 \\ -8 & -5 & 3 \end{pmatrix}$$

8 Técnicas iterativas en álgebra de matrices

Las técnicas iterativas son métodos utilizados para resolver sistemas de ecuaciones lineales de la forma $Ax = b$. A menudo son preferidos en comparación con métodos directos debido a su menor consumo de memoria y su capacidad para manejar grandes sistemas dispersos.

En el análisis de sistemas grandes, particularmente aquellos que presentan muchas entradas de ceros (sistemas "sparse"), los métodos iterativos como Jacobi y Gauss-Seidel son especialmente útiles. La eficiencia en términos de almacenamiento y cálculo computacional se vuelve crítica en estos casos.

Método de Jacobi

El método de Jacobi es un algoritmo iterativo que se basa en la descomposición de la matriz A en sus componentes diagonal, inferior y superior. Para un sistema $Ax = b$:

$$A = D - L - U$$

donde: - D es la matriz diagonal de A, - L es la matriz triangular inferior, - U es la matriz triangular superior.

Este método lo utilizaremos para resolver sistemas de ecuaciones lineales de forma $Ax = b$, entonces

$$(D - L - U)x = b$$

$$Dx - (L + U)x = b$$

$$Dx = b + (L + U)x$$

si pedimos que los elementos de la diagonal sean no nulos,

$$x = D^{-1}b + D^{-1}(L + U)x$$

Llamares $C = D^{-1}b$ y $T = D^{-1}(L+U)$. Dado, un punto inicial x^0 el método de Jacobi propone generar una sucesión de la forma

$$x^{k+1} = D^{-1}b + D^{-1}(L+U)x^k$$

o

$$x^{k+1} = Tx^k + C.$$

Veamos que forma tiene la matriz T,

$$D^{-1}(L+U) = \begin{pmatrix} 1/a_{11} & 0 & 0 & \cdots & 0 \\ 0 & 1/a_{22} & 0 & \cdots & 0 \\ 0 & 0 & 1/a_{33} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1/a_{nn} \end{pmatrix} \begin{pmatrix} 0 & -a_{12} & -a_{13} & \cdots & -a_{1n} \\ -a_{21} & 0 & -a_{23} & \cdots & -a_{2n} \\ -a_{31} & -a_{32} & 0 & \cdots & -a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -a_{n1} & -a_{n2} & -a_{n3} & \cdots & 0 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & -a_{12}/a_{11} & -a_{13}/a_{11} & \cdots & -a_{1n}/a_{11} \\ -a_{21}/a_{22} & 0 & -a_{23}/a_{22} & \cdots & -a_{2n}/a_{22} \\ -a_{31}/a_{33} & -a_{32}/a_{33} & 0 & \cdots & -a_{3n}/a_{33} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -a_{n1}/a_{nn} & -a_{n2}/a_{nn} & -a_{n3}/a_{nn} & \cdots & 0 \end{pmatrix}.$$

El vector C, es de la forma

$$D^{-1}b = \begin{pmatrix} 1/a_{11} & 0 & 0 & \cdots & 0 \\ 0 & 1/a_{22} & 0 & \cdots & 0 \\ 0 & 0 & 1/a_{33} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1/a_{nn} \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_n \end{pmatrix} = \begin{pmatrix} b_1/a_{11} \\ b_2/a_{22} \\ b_3/a_{33} \\ \vdots \\ b_n/a_{nn} \end{pmatrix}$$

La fórmula de actualización del método de Jacobi se da por:

$$x_i^{k+1} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^k \right)$$

donde k es el índice de la iteración.

Notar que es lo mismo que si se despeja cada incógnita del sistema $AX = b$.

Método de Gauss-Seidel

El método de Gauss-Seidel es similar al método de Jacobi, pero utiliza los valores más recientes de x en la misma iteración.

Dado un sistema de ecuaciones lineales de la forma:

$$Ax = b \tag{4}$$

donde A es una matriz cuadrada, x es el vector de incógnitas y b es el vector de constantes, el método consiste en descomponer la matriz A en su parte triangular inferior y diagonal:

$$A = L - D - U$$

al igual que con el método de Jacobi, queremos resolver el sistema $Ax = b$, entonces

$$(L - D - U)x = b$$

$$(L - D)x = b + Ux$$

$$x = (D - L)^{-1}b + (D - L)^{-1}Ux.$$

La fórmula de iteración del método se expresa como:

$$x^{k+1} = (D - L)^{-1}b + (D - L)^{-1}Ux^k$$

O en forma más compacta,

$$x^{k+1} = C + Tx^k$$

La actualización se realiza de la siguiente manera:

$$x_i^{k+1} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{k+1} - \sum_{j=i+1}^{n} a_{ij} x_j^k \right)$$

8.1 Convergencia de los métodos de Jacobi y Gauss-Seidel

Definición 8.1. *Una matriz $A \in \mathbb{R}^{n \times n}$ se dice convergente si $\lim_{k \to \infty} A^k = 0$.*

Ejemplo 8.2.

$$A = \begin{pmatrix} 1/2 & 0 \\ 1/4 & 1/2 \end{pmatrix}$$

Recodemos las definiciones de autovalor y autovector de un matriz A.

Definición 8.3. *Sea A una matriz cuadrada de orden n. Un escalar λ se llama **autovalor** de la matriz A si existe un vector no nulo $\mathbf{v}$ tal que:*

$$A\mathbf{v} = \lambda \mathbf{v}$$

*El vector $\mathbf{v}$ se denomina **autovector** correspondiente al autovalor λ.*

En otras palabras, un autovector $\mathbf{v}$ es un vector que, al ser transformado por la matriz A, solo es escalado por el factor λ y no cambia de dirección.

Definición 8.4. *Sea $A \in \mathbb{R}^{n \times n}$ y λ_i los autovalores de A. Se define el radio espectral como*

$$\rho(A) = \max_{i=,\ldots,n} \{|\lambda_i|\}$$

Teorema 8.5. *Las siguientes afirmaciones son equivalentes:*

1. *A es convergente.*
2. *$\lim_{k \to \infty} \|A^k\| = 0$ para cualquier norma inducida.*
3. *$\lim_{k \to \infty} \|A^k\| = 0$ para toda norma.*

4. $\rho(A) < 1$.

5. $\lim_{k\to\infty} A^k x = 0$.

Teorema 8.6. *Sea $T \in \mathbb{R}^{n\times n}$. Si $\rho(A) < 1$ existe $(Id - T)^{-1}$ y además $(Id - T)^{-1} = Id + T + T^2 + \ldots$*

Proof. Demostremos primero que λ es autovalor de T si y solo si $1 - \lambda$ es autovalor de $I - T$.

$$Tx = \lambda x \iff Ix - Tx = Ix - \lambda x \iff (I - T)x = (1 - \lambda)x,$$

como $\rho(T) < 1$, todos los autovalores son menores a 1, porque el radio espectral es el máximo de todos los autovalores. Por lo tanto, $(1 - \lambda) \neq 0$.

Como el determinante de una matriz es el producto de todos los autovalores, el $det(I - T) \neq 0$ y por lo tanto $I - T$ tiene inversa.

Demostraremos ahora que $\lim\limits_{n\to\infty} (I - T)S_n = I$, donde $S_n = I + T + \ldots + T^n$.

$$(I - T)S_n = IS_n - TS_n = I + T + \ldots + T^n - (T + \ldots + T^{n+1}) = I - T^{n+1}.$$

Como $\rho(T) < 1$ sii $\|T^{n+1}\| \to 0$, se tiene que $\lim\limits_{n\to\infty} (I - T)S_n = I$ □

Teorema 8.7. *Sea $x^0 \in \mathbb{R}^n$ y $\{x^k\}$ una sucesión definida por $x^k = Tx^{k-1} + C$. entonces $\{x^k\}$ converge a x^* tal que $x^* = Tx^* + C$ si y solo si $\rho(T) < 1$.*

Proof. $\Leftarrow$) Supongamos que $\rho(T) < 1$.

$$x^k = Tx^{k-1} + C = T(Tx^{k-2} + C) + C = T^2x^{k-2} + Tx + C = T^2(Tx^{k-3} + C)$$

$$T^3x^{k-3} + T^2x^{k-2} + Tx + C = \ldots = T^kx^0 + (T^{k-1} + T^{k-2+\ldots+T+I})C$$

. Por lo tanto, como $\lim_{k\to\infty} Tx^0 = 0$ porque $\rho(T) < 0$ y $T^{k-1} + T^{k-2+\ldots+T+Td}) = (I - T)^{-1}$, tenemos que la sucesión converge y

$$\lim_{k\to\infty} x^k = (I - T)^{-1}.$$

Es decir,

$$x^* = (I - T)^{-1}C \Rightarrow (I - T)x^* = C \Rightarrow Ix^* - Tx^* = C \Rightarrow x^* = Tx^* + C.$$

$\Rightarrow$) Sea $x^0 \in \mathbb{R}^n$, $z = x^* - x^0$.

$$\lim_{k\to\infty} T^kz = \lim_{k\to\infty} T^k(x^* - x^0) = \lim_{k\to\infty} T^{k-1}(Tx^* - Tx^0) = \lim_{k\to\infty} T^{k-1}(x^* - C - (x^1 - C))$$

$$= \lim_{k\to\infty} T^{k-1}(x^* - x^1) = \ldots = \lim_{k\to\infty} I(x^* - x^k) = 0.$$

Y entonces, por la proposición $\rho(T) < 1$. □

Teorema 8.8. *Si $\|T\| < 1$ para alguna norma inducida entonces la sucesión $\{x^k\}$ definida por $x^k = Tx^{k-1} + C$ converge para cualquier vector inicial $x^0 \in \mathbb{R}^n$ y $x^* = Tx^* + C$. Además,*

1. $\|x^* - x^k\| \leq \|T\|^k \|x^* - x^0\|$
2. $\|x^* - x^k\| \leq \dfrac{\|T\|^k}{1 - \|T\|} \|x^1 - x^0\|$

Proof. Sea x^* la solución tal que $x^* = Tx^* + C$ (que existe por el Teorema anterior).

1.
$$\begin{aligned}
\|x^* - x^k\| = & \|Tx^*C - (Tx^k + C)\| \\
= & \|T(x^* - x^{k-1})\| \leq \|T\|\|x^* - x^{k-1}\| \\
= & \|T\|\|(Tx^* + C - (Tx^{k-2} + C))\| \leq \|T\|^2\|(x^* - x^{k-2})\| \\
\leq & \vdots \\
\leq & \|T\|^k\|(x^* - x^0)\|
\end{aligned}$$

2.
$$\begin{aligned}
x^k - x^{k-1} & \quad Tx^{k-1} + C - (Tx^{k-2} + C) \\
= & \quad T(x^{k-1} - x^{k-2}) \\
= & \quad T(Tx^{k-2} + C - (Tx^{k-3} + C)) \\
= & \quad T^2(x^{k-2} - x^{k-3}) \\
= & \quad \vdots \\
= & \quad T^{k-1}(x^1 - x^0).
\end{aligned}$$

Por otro lado,

$$\begin{aligned}
x^* - x^k = & \quad Tx^* + C - (Tx^{k-1} + C) \\
= & \quad Tx^* - Tx^{k-1} \\
= & \quad Tx^* - Tx^k + Tx^k - Tx^{k-1} \\
= & \quad T(x^* - x^k) + T(x^k - x^{k-1}) \\
= & \quad T(x^* - x^k) + T(T^{k-1}(x^1 - x^0)) = T(x^* - x^k) + T^k(x^1 - x^0)
\end{aligned}.$$

Usando estas dos desigualdades se tiene que

$$\begin{aligned}
\|x^* - x^k\| &\leq \|T\|\|x^* - x^k\| + \|T\|\|x^1 - x^0\| \\
\|x^* - x^k\| - \|T\|\|x^* - x^k\| &\leq \|T\|\|x^1 - x^0\| \\
\|x^* - x^k &\leq \frac{\|T\|}{1 - \|T\|}\|x^1 - x^0\|\|.
\end{aligned}$$

Notar que $1 - \|T\| \neq 0$, porque $\|T\| < 1$.

□

Definición 8.9. *Sea $A \in \mathbb{R}^{n \times n}$ es estrictamente diagonal dominante si*

$$|a_{ii}| > \sum_{j=1, i \neq j}^{n} |a_{ij}|,$$

para todos $i = 1, \ldots, n$.

Teorema 8.10. *Si $A \in \mathbb{R}^{n\times n}$, es estrictamente diagonal dominante entonces A es no singular.*

Proof. Supongamos que A es singular, entonces existe $x \neq 0$ tal que el sistema $Ax = b$ tiene solución.

Sea k el índice tal que $0 < \max_j |x_j| = |x_k|$. Entonces, $(Ax)_k = 0$ (la componente k-ésima), esto es

$$\sum_{j=1}^{n} a_{kj}x_j = 0.$$

entonces,

$$a_{kk}x_k = -\sum_{k\neq j} a_{kj}x_j \Rightarrow a_{kk} = -\sum_{k\neq j} a_{kj}\frac{x_j}{x_k}$$

$$\Rightarrow |a_{kk}| = \sum_{k\neq j} |a_{kj}||\frac{x_j}{x_k}| \leq \sum_{k\neq j} a_{kj}$$

y esto es absurso porque A es estrictamente diagonal dominante. □

Teorema 8.11. *Si A es escrictamente diagonal dominante entonces para cualquier elección de x^0, los métodos de Jacobi y Gauss-Seidel convergen a la única solución del sistema $Ax = b$.*

Proof. Veamos primero que el método de Jacobi converge. La matriz de Jacobi tiene la forma

$$T_J = \begin{pmatrix} 0 & -a_{12}/a_{11} & -a_{13}/a_{11} & \cdots & -a_{1n}/a_{11} \\ -a_{21}/a_{22} & 0 & -a_{23}/a_{22} & \cdots & -a_{2n}/a_{22} \\ -a_{31}/a_{33} & -a_{32}/a_{33} & 0 & \cdots & -a_{3n}/a_{33} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -a_{n1}/a_{nn} & -a_{n2}/a_{nn} & -a_{n3}/a_{nn} & \cdots & 0 \end{pmatrix}.$$

Entonces,

$$\|T_J\|_\infty = \max i = 1, \ldots, n \sum_{j=1, i\neq j}^{n} |\frac{a_{ij}}{ii}| < 1$$

ya que A es estrictamente diagonal dominante. Por lo tanto, Jacobi converge.

Analicemos ahora el método de Gauss-Seidel. Para esto veamos que $\rho(T) < 1$, esto nos lleva a analizar los autovalores de la matriz T_{GS}.

Si λ es autovalor de T, $Tv = \lambda v$. Entonces $(D - L)^{-1}Uv = \lambda v$.

Tomamos v tal que $\|v\|_\infty = 1$. entonces

$$Uv = (D - L)\lambda v.$$

Si miramos cada una de las filas,

$$-\sum_{j=i+1}^{n} a_{ij}v_j = \lambda \sum_{j=1}^{i} a_{ij}v_j$$

$$\Rightarrow \lambda a_{ii}v_i = -\sum_{j=i+1}^{n} a_{ij}v_j - \lambda \sum_{j=1}^{i-1} a_{ij}v_j.$$

Si i_0 es el índice tal que $|v_{i_0}| = 1$

$$|\lambda||a_{i_0i_0}||v_{i_0}| = |-\sum_{j=i_0+1}^{n} a_{i_0j}v_j - \lambda\sum_{j=1}^{i_0-1} a_{i_0j}v_j|$$

$$\Rightarrow |\lambda||a_{i_0i_0}| \leq \sum_{j=i_0+1}^{n} |a_{i_0j}||v_j| + |\lambda|\sum_{j=1}^{i_0-1} |a_{i_0j}||v_j|$$

, entonces Como $\|v\| = 1$, $|v_j| \leq 1$

$$|\lambda||a_{i_0i_0}| \leq \sum_{j=i_0+1}^{n} |a_{i_0j}| + |\lambda|\sum_{j=1}^{i_0-1} |a_{i_0j}|$$

$$\Rightarrow |\lambda|\left(|a_{i_0i_0}| - |\lambda|\sum_{j=1}^{i_0-1} |a_{i_0j}|\right) \leq \sum_{j=i_0+1}^{n} |a_{i_0j}|$$

Como A es diagonal dominante $|a_{i_0i_0}| - |\lambda|\sum_{j=1}^{i_0-1} |a_{i_0j}| > 0$, y por lo tanto,

$$|\lambda \leq \frac{\sum_{j=i_0+1}^{n} |a_{i_0j}|}{|a_{i_0i_0}| - |\lambda|\sum_{j=1}^{i_0-1} |a_{i_0j}|}| < 1$$

Por lo tanto, $\rho(T) < 1$, y Se puede asegurar que el método de Gauss Seidel Converge. $\square$