TP4

Variables aleatorias

En muchísimas ocasiones de la vida cotidiana y aplicaciones de la matemática suele asociarse a cada resultado de un experimento un número real que se relaciona con el mismo. Por ejemplo, en un juego el número puede ser el premio para cada resultado (o castigo, siendo en ese caso un número negativo). Pero mejor damos la sencilla definición y después los ejemplos.

Definición. *Dado un espacio de probabilidad cualquiera* (Ω, P)*, una variable aleatoria* X *es una función*

$$X : \Omega \to \mathbb{R}.$$

Por una tradición de siglos se usan las letras $X, Y, Z, \ldots$ para las variables aleatorias. Tanto la notación como el nombre de "variables" vienen de una época en que no existía el concepto de función (ni de conjunto).

Ejemplos

a) De un bolillero, con bolillas numeradas de 1 a 100, se saca una bolilla. Si el número de la bolilla tiene un solo dígito hay un premio de \$50, si es de dos dígitos hay un castigo de \$1 y si es el 100, hay un premio de \$5000. Esto podría plantearse así:

$$\Omega = I_{100} \qquad \text{(equiprobable)}$$

$$X : \Omega \to \mathbb{R}, \qquad X(\omega) = \begin{cases} 50, & \omega < 10, \\ -1, & 10 \leq \omega \leq 99, \\ 5000, & \omega = 100. \end{cases}$$

Siguiendo la tradición de siglos suele usarse este lenguaje, que ustedes encontrarán en los ejercicios: "Sea X el premio", o en este caso "Sea X la ganancia o pérdida", donde se sobreentiende el carácter de función de X.

b) En esa línea de lenguaje tenemos el siguiente enunciado: "Se elige al azar un punto de un cuadrado de lado 2. Sea X la distancia del punto elegido a la esquina inferior izquierda del cuadrado".

La manera de plantear formalmente este enunciado puede ser: sea

$$\Omega = [0, 2] \times [0, 2]$$

con la probabilidad

$$P(A) = \frac{\text{area}(A)}{4}, \qquad \forall A \subset \Omega,$$

y sea $X : \Omega \to \mathbb{R}$ definida para cada $\omega = (u, v) \in \Omega$ por

$$X(\omega) = X((u, v)) = \sqrt{u^2 + v^2}.$$

Dado un (Ω, P), siendo las variables aleatorias funciones reales con dominio en Ω, les caben las operaciones entre funciones. De modo que si X e Y son variables aleatorias con dominio en Ω podemos hablar de otras como $X + Y$, $X \cdot Y$, X^2, $2X$, etc.

Notaciones y abreviaturas

Usaremos "v.a." para abreviar "variable aleatoria". Como en teoría de conjuntos, anotaremos $X(\Omega)$ a la imagen de X:

$$X(\Omega) = \{X(\omega)/\omega \in \Omega\} \subseteq \mathbb{R}.$$

En el caso *a*) del bolillero,

$$X(\Omega) = \{-1, 50, 5000\}.$$

En el caso del cuadrado b),

$$X(\Omega) = [0, 2\sqrt{2}].$$

Ahora vamos a dar una forma de anotar que es típica de la teoría de Probabilidades, aunque con un sencillo equivalente en la teoría de conjuntos. Supongamos que queremos referirnos a

$$B = \{\omega / X(\omega) \in [1, 4)\}$$

(donde X es una v.a. cualquiera y $[1, 4)$ podría ser cualquier otro subconjunto de $\mathbb{R}$). En teoría de conjuntos esto se anotaría

$$B = X^{-1}([1, 4)),$$

pero en nuestro curso anotaremos

$$B = [X \in [1, 4)]$$

y también será equivalente con nuestras notaciones

$$B = [1 \leq X < 4].$$

De modo que nos encontraremos muy seguido con expresiones como

$$[X \in A], \qquad [X > 8], \qquad [X = -3],$$

que significan respectivamente

$$\{\omega / X(\omega) \in A\}, \qquad \{\omega / X(\omega) > 8\}, \qquad \{\omega / X(\omega) = -3\}.$$

Usando estas notaciones propongo un ejercicio muy sencillo.

Ejercicio Para el ejemplo a) del bolillero, probar:

$$P([X = 5000]) = \frac{1}{100}, \qquad P([X < 0]) = \frac{9}{10},$$

$$P([X < -2]) = 0, \qquad P([X \in \{-1, 50\}]) = \frac{99}{100}, \qquad P([X \geq 1000]) = \frac{1}{100}.$$

Para el ejemplo b) del cuadrado:

$$P([X > 3]) = 0, \qquad P([X = 1]) = 0,$$
$$P([X \leq 1]) = \frac{\pi}{16}, \qquad P([X \leq 3]) = 1.$$

Variables aleatorias discretas y variables aleatorias "continuas"

Vamos a presentar los tipos de variables aleatorias que usaremos en este curso. No cubren todo el espectro de posibilidades pero son los tipos más usuales de v.a. y es importante aprender a trabajar con ellas.

Definición. *Diremos que una v.a. X con dominio en un Ω (donde (Ω, P) es un espacio de probabilidad) es discreta cuando $X(\Omega)$ es numerable (finito o infinito).*

En nuestro curso, ya sea en el caso finito o infinito, $X(\Omega)$ será un conjunto formado la mayoría de las veces por puntos aislados. Cuando $X(\Omega)$ es finito eso siempre pasa. Cuando $X(\Omega)$ es infinito eso sucede por ejemplo en el caso de $X(\Omega) = \mathbb{Z}$, pero no sucede en el caso $X(\Omega) = \mathbb{Q}$; este último caso no se producirá casi nunca.

Un detalle importante es que si Ω es numerable, $X : \Omega \to \mathbb{R}$ siempre es discreta. Pero si Ω no es numerable, X podría ser discreta. Por ejemplo si X es constante, siempre es discreta, cualquiera sea el dominio.

Cuando X es discreta con imagen finita tendremos

$$X(\Omega) = \{x_1, x_2, \ldots, x_m\} \subset \mathbb{R}$$

y en general podemos escribir

$$X(\Omega) = \{x_1, x_2, \ldots\},$$

siendo la lista infinita para $X(\Omega)$ infinito y teniendo un final (que no indicamos) para $X(\Omega)$ finito. Esta última manera de anotar la usaremos muchas veces cuando hagamos cálculos que queremos que cubran ambas situaciones.

Cuando una v.a. X es discreta y

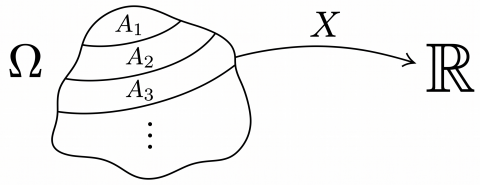
$$X(\Omega) = \{x_1, x_2, \ldots\} \qquad \text{(claramente } x_i \neq x_j \text{ cuando } i \neq j)$$

se pueden considerar los conjuntos

$$A_k = [X = x_k], \qquad k = 1, 2, \ldots$$

(recordando que $[X = x_k] = \{\omega / X(\omega) = x_k\}$.) Entonces Ω queda "partido" en una cantidad numerable (finita o infinita) de eventos mutuamente excluyentes

$$\Omega = \bigcup_{k=1}^{\infty} A_k.$$



Se tiene entonces

$$\sum_k P(A_k) = \sum_k P[X = x_k] = 1.$$

(Aquí $\sum_k$ significa $\sum_{k=1}^{m}$ en el caso finito y $\sum_{k=1}^{\infty}$ en el caso infinito numerable.)

En esta etapa de nuestro curso incursionaremos en este tipo de v.a. El otro tipo de v.a., que será protagonista de la segunda mitad del curso, son las v.a. "continuas". Las comillas, que pongo por ser la primera presentación, van porque no se refiere a que son funciones continuas en el sentido del Análisis matemático. Esto sería imposible porque normalmente Ω no tiene estructura topológica. O dicho más fácil, no tiene sentido decir que dos elementos de Ω son cercanos, o que una sucesión de elementos se acerca a un límite.

Definición. *Una v.a X es <u>continua</u> si para todo $t \in \mathbb{R}$*

$$P[X = t] = 0.$$

Antes de ver ejemplos, observamos que si una v.a. es discreta, como

$$\sum_k P[X = x_k] = 1,$$

necesariamente para algún $t \in \mathbb{R}$ (alguno de los x_k) es $P[X = t] > 0$. Así que no hay v.a. que puedan pertenecer a ambos tipos. Además, si X es "continua", necesariamente $X(\Omega)$ debe ser no numerable (en nuestro curso será en general un intervalo real, acotado o no).

<u>Ejemplos</u>

Vamos a considerar el conocido $\Omega = [0, 1]$ que corresponde al experimento de elegir un número real al azar en $[0, 1]$, con

$$P(A) = \text{long}(A), \qquad \forall A \subset [0, 1].$$

Vamos a definir variables aleatorias de distinto tipo en este espacio.

a) $X : \Omega \to \mathbb{R}$.

X = "menor dígito que puede usarse como 1ra cifra decimal del número elegido".

X es una v.a. discreta,

$$X(\Omega) = \{0, 1, \ldots, 9\} = I_9 \cup \{0\},$$

$X(\Omega)$ es finito.

b) $Y : \Omega \to \mathbb{R}$.

Y = "el mayor entero positivo m tal que el número elegido es menor o igual a $1/m$".

Y es una v.a. discreta, $Y(\Omega)$ es infinito numerable,

$$Y(\Omega) = \{1, 2, \ldots\} = \mathbb{Z}^+.$$

c) $Z : \Omega \to \mathbb{R}$.

$Z =$ "distancia entre el número elegido y 1/2".

Veamos que Z es "continua". Claramente

$$Z(\Omega) = [0, 1/2].$$

Falta ver que $\forall t \in [0, 1/2]$, $P[Z = t] = 0$ (obviamente si $t \notin [0, 1/2]$ esta igualdad vale porque $[Z = t] = \varnothing$). Sea entonces $t \in [0, 1/2]$ fijo.

Si $t = 0$ tenemos

$$[Z = 0] = \{1/2\}, \qquad \text{long}(\{1/2\}) = 0.$$

Si $t \in (0, 1/2]$,

$$[Z = t] = \left\{\frac{1}{2} - t, \frac{1}{2} + t\right\},$$

también de longitud nula.

Proponemos como ejercicios los siguientes cálculos, referidos a las v.a. anteriormente definidas:

Ejercicio Calcular

$$P[X > 2], \qquad P[|X - 3| \leq 1],$$
$$P[Y > 11], \qquad P[Y^2 < 20], \qquad P[Y \in \{3, 5\}],$$
$$P\left[\frac{1}{4} \leq Z \leq \frac{1}{3}\right], \qquad P\left[Z \in \left(-\frac{1}{3}, \frac{1}{5}\right)\right].$$

En todo lo que sigue trabajaremos con v.a discretas, a menos que explícitamente digamos otra cosa.

Esperanza de v.a. discretas

Empecemos con un ejemplo sencillo. En una bolsa hay dos fichas rojas, una ficha amarilla y tres fichas verdes. Se extrae una ficha al azar. Si la ficha es roja recibimos un premio de \$10, si es amarilla debemos pagar \$15 y si es verde hay un premio de \$7.

Hay varias preguntas que se pueden hacer. Una muy simple es si este es un juego conveniente. Esta pregunta se puede "refinar" y puede agregarse las cuestiones: ¿es muy conveniente? o ¿es levemente inconveniente? etc.

Si un jugador quiere responder "experimentalmente" a preguntas como estas, puede hacer lo siguiente: jugar una vez y ve cómo le va. Pero si pierde, podría ser culpa de que se dio en ese juego algún resultado poco probable. Lo mismo si gana. Parecería más razonable jugar muchas veces y hacer un balance de su dinero. Por ejemplo, juega 100 veces y anota cada vez su ganancia o pérdida. Su planilla puede tener este aspecto:

JUGADA	1	2	3	4	5	6	7	ETC
COLOR	R	A	R	V	V	V	A	ETC
DINERO	10	-15	10	7	7	7	-15	ETC

La suma de los montos de la tercera fila es el balance del dinero del jugador. Si dividimos esa suma (positiva, negativa o nula) por la cantidad de veces que jugó, obtendremos el balance promedio por juego. Si por ejemplo después de N juegos (N "grande") el promedio da un valor μ_N, tenemos la percepción de que a medida que N crece ese valor se va estabilizando en un valor μ. O dicho más académicamente, sería un valor μ tal que

$$\lim_{N \to \infty} \mu_N = \mu.$$

Sería muy bueno poder definir ese valor μ sin necesidad de experimentar.

Vamos a motivar la definición de una fórmula para obtener ese valor μ. Desde el lenguaje de nuestra teoría tenemos un espacio muestral

$$\Omega = \{R, A, V\}$$

y una probabilidad P,

$$P(\{R\}) = \frac{2}{6} = \frac{1}{3}, \qquad P(\{A\}) = \frac{1}{6}, \qquad P(\{V\}) = \frac{3}{6} = \frac{1}{2},$$

y una v.a. $X : \Omega \to \mathbb{R}$,

$$X(R) = 10, \qquad X(A) = -15, \qquad X(V) = 7.$$

De modo que $X(\Omega) = \{10, -15, 7\}$,

$$P[X = 10] = \frac{1}{3}, \qquad P[X = -15] = \frac{1}{6}, \qquad P[X = 7] = \frac{1}{2}.$$

Supongamos, por comodidad, que jugamos una cantidad de veces que es múltiplo de 6, por ejemplo 600 veces. El sentido común nos dice que lo "esperable" (ojo, no lo real) sería que cada 6 juegos "obtengamos" 2 veces \$10, una vez $-$\$15 y 3 veces \$7. Eso sería mucha casualidad si solamente jugara 6 veces, pero si juego 600 veces ya parece más lógico (siendo $600 = 6 \cdot 100$) que haya obtenido \$10 aproximadamente

$$\left(\frac{2}{6}\right) 600 = 200 \text{ veces},$$

que haya "obtenido" $-$\$15

$$\left(\frac{1}{6}\right) 600 = 100 \text{ veces}$$

y

$$\left(\frac{3}{6}\right) 600 = 300 \text{ veces}.$$

En ese caso el balance total sería

$$\$(200 \cdot 10 + 100 \cdot (-15) + 300 \cdot 7) = \$(2000 - 1500 + 2100) = \$2600$$

y por juego

$$\frac{\$2600}{600} = \$\frac{13}{3} = \$4,33\ldots$$

Estamos deduciendo que el juego es favorable, pero además que el balance por juego es \$4,33... (ojo, es un promedio). Parecería lógico darle a ese número el nombre de "valor esperado de X", o "media de X", o (como vamos a usar más habitualmente) "Esperanza de X".

Esto que hicimos se generaliza fácilmente. Empecemos por el caso en que $X(\Omega)$ es finito,

$$X(\Omega) = \{x_1, \ldots, x_m\},$$

y que conocemos

$$\alpha_1 := P[X = x_1], \quad \ldots, \quad \alpha_m := P[X = x_m].$$

Si hacemos el experimento N veces (pensando en N grande) es "esperable" obtener x_1 aproximadamente $\alpha_1 N$ veces, ..., x_m aproximadamente $\alpha_m N$ veces. El valor esperado de X parece lógico que sea definido como

$$\frac{(x_1\alpha_1 N) + \cdots + (x_m\alpha_m N)}{N} = \sum_{k=1}^{m} x_k \alpha_k.$$

Esto motiva la siguiente definición:

Definición. *Sea X una variable aleatoria con imagen finita, $X(\Omega) = \{x_1, \ldots, x_m\}$. La esperanza de X es*

$$\boxed{E(X) := \sum_{k=1}^{m} x_k \, P[X = x_k].}$$

Cuando $X(\Omega)$ es infinito numerable, hay un pequeño detalle técnico porque se necesita convergencia absoluta. En este caso la presentación es así:

Definición. *Sea X una variable aleatoria con imagen infinito numerable, $X(\Omega) = \{x_k : k \in \mathbb{Z}^+\} = \{x_1, x_2, \ldots\}$. Se dice que X tiene esperanza cuando*

$$\sum_{k=1}^{\infty} |x_k| \, P[X = x_k] < +\infty \, .$$

En ese caso se define

$$E(X) := \sum_{k=1}^{\infty} x_k \, P[X = x_k].$$

Parecería que los valores $P[X = x_k]$ son muy importantes (recordemos que estamos en el caso en que X es discreta). Entonces

Definición. *La función*

$$f_X : X(\Omega) \to [0, 1], \qquad f_X(t) = P[X = t].$$

recibe los siguientes nombres (según los textos va cambiando, así que damos todos y usamos cualquiera que nos guste): "función de probabilidad de X", "función de densidad discreta de X", "función de frecuencia de X".

No es casual que aparezca la palabra "frecuencia" ya que en nuestra motivación estamos usando la percepción de que $f_X(x_k)$, para cada k, mide cuán frecuentemente se obtiene la "ganancia" x_k al repetir muchas veces el experimento. Muchos textos, y nosotros también cuando sea necesario, extienden el dominio de f_X a $\mathbb{R}$, ya que cuando $t \notin X(\Omega)$ es

$$f_X(t) = P[X = t] = 0.$$

Otra manera de presentar la definición de esperanza sería:

Definición. *Una v.a discreta X tiene esperanza cuando*

$$\sum_{t \in X(\Omega)} |t|\, f_X(t) < +\infty,$$

y en ese caso el valor de la esperanza es

$$E(X) = \sum_{t \in X(\Omega)} t\, f_X(t).$$

Recordamos que siendo $X(\Omega)$ numerable, las expresiones usadas son coherentes y no dependen del orden en que se suma debido a la convergencia absoluta.

Primeros ejemplos y propiedades

El caso más simple de v.a. discreta es el constante: $X(\omega) = c$ para todo ω (también se anota $X = c$ o $X \equiv c$). Aquí, como parece lógico,

$$E(X) = c\, P[X = c] = c\, f_X(c) = c \cdot 1 = c.$$

Proposición. *La esperanza es lineal, es decir,*

a) Si X es v.a discreta con esperanza y $c \in \mathbb{R}$, entonces $Y = cX$ es v.a discreta con esperanza y

$$E(Y) = c\, E(X).$$

b) Si X e Y son v.a. discretas con esperanza, $X + Y$ es discreta con esperanza y

$$E(X + Y) = E(X) + E(Y).$$

Demostración. *a*) Hay un caso inmediato que es $c = 0$ (ejercicio). Si $c \neq 0$ entonces, si

$$X(\Omega) = \{x_1, x_2, \ldots\},$$

es

$$Y(\Omega) = \{cx_1, cx_2, \ldots\}$$

(notar que los cx_k son todos diferentes). Si anotamos $y_k = c\, x_k$,

$$f_Y(y_k) = P[Y = y_k] = P[cX = c\, x_k] = P[X = x_k] = f_X(x_k).$$

Entonces

$$\sum_k |y_k| f_Y(y_k) = |c| \sum_k |x_k| f_X(x_k) < +\infty$$

y

$$E(Y) = \sum_k y_k\, f_Y(y_k) = c \sum_k x_k\, f_X(x_k) = c\, E(X).$$

La propiedad *b*) la probaremos más adelante, cuando desarrollemos herramientas adecuadas. Dejamos como ejercicio un caso particular sencillo que puede resolverse ahora: el caso en que Y es constante, $Y = c$. Suele escribirse $E(X + c) = E(X) + c$, ya que se identifica la constante c con la v.a. Y.

□

Antes de seguir, observemos que la función f_X contiene información esencial para el cálculo y que esa información no tiene que ver con la naturaleza del experimento. Cualquier experimento que toma ciertos valores $\{x_1, x_2, \ldots\}$ con la misma probabilidad da origen a la misma f_X. Suele hablarse de la distribución de X.

Distribución uniforme

Sea

$$X(\Omega) = \{x_1, \ldots, x_m\}$$

y todos los valores $x_1, \ldots, x_m$ cumplen

$$f_X(x_1) = f_X(x_2) = \cdots = f_X(x_m).$$

En este caso, suele decirse que X tiene una distribución uniforme en $\{x_1, \ldots, x_m\}$ (que abreviamos $U\{x_1, \ldots, x_m\}$). Como

$$\sum_{k=1}^{m} f_X(x_k) = \sum_{k=1}^{m} P[X = x_k] = 1,$$

entonces

$$f_X(x_k) = \frac{1}{m} \qquad \forall k.$$

$$E(X) = \sum_{k=1}^{m} \frac{1}{m} x_k = \frac{1}{m} \sum_{k=1}^{m} x_k.$$

Como era de suponer, en este caso la esperanza es el promedio de los valores.

Distribución Binomial

Supongamos que n es un entero positivo fijo y $0 < p < 1$. Se arroja n veces una moneda con probabilidad p de cara y se define

$$X = \text{“cantidad obtenida de caras”}.$$

Antes de calcular f_X y la esperanza de X, vamos a observar que los cálculos serían los mismos si el experimento fuera cualquiera de estos:

- Se les da a n pacientes un medicamento que tiene probabilidad p de curar. Sea $X =$“cantidad de pacientes que se curan.”
- La probabilidad de que una lámpara que se compra en una ferretería sea defectuosa es p. Compro n lámparas. Sea $X =$“cantidad de lámparas defectuosas entre las n compradas.”

Todas estas situaciones dan origen a la misma f_X y, por lo tanto, al mismo resultado (que pronto calcularemos) de $E(X)$. Se dice que X tiene una distribución binomial con parámetros n y p (se abrevia $B(n, p)$). Por eso hablaremos en el futuro de “esperanza de la binomial”, para referirnos a la esperanza de cualquier v.a. que tenga esa distribución, es decir esa función de probabilidad.

La intuición permite anticipar el resultado. Por ejemplo si $p = \frac{1}{2}$ y $n = 10$, lo que se espera es obtener 5 caras:

$$5 = \frac{1}{2} \cdot 10.$$

En general, para cualquier n, p parece ser que $E(X) = np$ será la respuesta. No hay ningún problema en que np no sea entero. Si arrojo 3 veces la moneda con $p = \frac{1}{2}$ será $E(X) = \frac{3}{2}$. Quiere decir que si hago muchas veces el experimento y promedio los resultados, el resultado “promedio” es similar a $3/2$.

Vamos a calcular $E(X)$ usando la definición. En breve, usando propiedades, confirmaremos el resultado por un camino sencillísimo y más elegante. De acuerdo a un cálculo de la Teoría 3, tenemos

$$X(\Omega) = \{0, 1, \ldots, n\}$$

y para cada $k \in X(\Omega)$

$$P[X = k] = f_X(k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

Entonces

$$E(X) = \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k}.$$

Podemos eliminar el sumando que corresponde a $k = 0$. Para $k > 0$ observamos:

$$k\binom{n}{k} = k\frac{n!}{k!(n-k)!} = \frac{n!}{(k-1)!(n-k)!} = n\frac{(n-1)!}{(k-1)!((n-1)-(k-1))!} = n\binom{n-1}{k-1}.$$

Nuestra idea es usar la fórmula de Newton para $n - 1$. Por eso, el otro cambio es escribir ($k > 0$)

$$p^k (1-p)^{n-k} = p\, p^{k-1} (1-p)^{(n-1)-(k-1)}.$$

Volviendo a la fórmula de $E(X)$ escribimos

$$E(X) = np \sum_{k=1}^{n} \binom{n-1}{k-1} p^{k-1} (1-p)^{(n-1)-(k-1)}.$$

Ahora observamos que si usamos como índice $j = k - 1$ nos queda

$$E(X) = np \sum_{j=0}^{n-1} \binom{n-1}{j} p^{j} (1-p)^{(n-1)-j}.$$

El sumando desarrolla el binomio

$$(p + (1-p))^{n-1} = 1.$$

Finalmente

$$\boxed{E(X) = np}.$$

Distribución geométrica

Consideremos una vez más el experimento de arrojar sucesivamente una moneda con probabilidad p de cara hasta obtener cara. En el tipo de lenguaje que nos permitimos sea

$$X = \text{“cantidad de tiradas del experimento”}.$$

Excluimos directamente el caso de infinitas tiradas, lo cual no cambia nada.

$$X(\Omega) = \{1, 2, \ldots\} = \mathbb{Z}^+.$$

Ya sabemos por la Teoría 3 que

$$f_X(k) = (1-p)^{k-1} p.$$

En caso de que la serie

$$\sum_{k=1}^{\infty} k(1-p)^{k-1} p < +\infty\,,$$

su suma será la esperanza de X. Como $0 < p < 1$, si llamamos $x = 1 - p$, resulta $|x| < 1$ y

$$E(X) = p \sum_{k=1}^{\infty} k\, x^{k-1}.$$

Recordando A.M.I tenemos que si

$$g(x) = \sum_{k=0}^{\infty} x^k = \frac{1}{1-x}, \qquad |x| < 1,$$

se puede derivar término a término esta serie de potencias y

$$g'(x) = \frac{1}{(1-x)^2} = \sum_{k=1}^{\infty} k\, x^{k-1}.$$

Entonces

$$E(X) = \frac{p}{(1-x)^2} = \frac{p}{p^2} = \boxed{\frac{1}{p}}.$$

Por ejemplo, si la moneda es equilibrada: $p = \frac{1}{2}$ y $E(X) = 2$. No es obvio a priori este resultado. Sí está claro que a medida que p es menor $E(X)$ debe crecer. En el futuro diremos que X tiene distribución $Geom(p)$.

Distribución hipergeométrica

Vamos a hacer una presentación breve porque el objetivo de nuestro curso es transmitir procedimientos e ideas generales y no hacer un “inventario” de casos particulares.

Supongamos que se tiene una población “grande” de N individuos (por ejemplo $N = 10^6$), de los cuales M (por ejemplo la mitad) pertenecen a un cierto grupo. Supongamos que se toma una pequeña muestra de n individuos (por ejemplo $n = 100$). Nos interesa la distribución de la v.a.

$$X = \text{“número de individuos del grupo entre los } n \text{ elegidos”}.$$

Si la proporción n/N es muy pequeña, es de esperar que la distribución de X sea muy similar a una binomial $B(n,p)$, con $p = M/N$. Pero igual habrá una pequeña diferencia, de la que enseguida vamos a hablar.

Una de las maneras de plantearlo es así: la población se puede identificar con $I_N = \{1, 2, \ldots, N\}$. Al grupo de M individuos llamémoslo B. Entonces

$$\Omega = \{T/T \subset I_N,\ \#(T) = n\} \qquad \text{(equiprobable)},$$

$$X : \Omega \to \{0, 1, \ldots, n\}, \qquad X(T) = \#(T \cap B).$$

Entonces, para cada $j = 0, \ldots, n$,

$$[X = j] = \{T \in \Omega /\ \#(T \cap B) = j\}.$$

Obtenemos

$$P[X = j] = f_X(j) = \frac{\binom{M}{j}\binom{N-M}{n-j}}{\binom{N}{n}}.$$

Vamos ahora al tema de su parecido con la distribución binomial:

Proposición. *Sean $0 < p < 1$, $n \in \mathbb{N}$ fijos. Supongamos que g es una función tal que para cada N, $g(N) \in \{0, 1, \ldots, N\}$. Además supongamos*

$$\lim_{N\to\infty} \frac{g(N)}{N} = p\,.$$

Entonces, si para cada $N \geq n$, X_N es una v.a. con distribución hipergeométrica con parámetros N, $g(N)$ y n,

$$\lim_{N\to\infty} P[X_N = j] = p^j (1-p)^{n-j} \binom{n}{j}$$

para todo j tal que $0 \leq j \leq n$.

Demostración. Ejercicio. □

Pueden verse otras propiedades en el libro de Ross (pág. 460). Allí se demuestra con bastante trabajo que

$$E(X) = n\frac{M}{N}\,,$$

como era de esperar.

Composición de una función real con una variable aleatoria

Supongamos que X es una v.a. cualquiera (discreta o no) y g es una función

$$g : X(\Omega) \to \mathbb{R}$$

(en muchos casos se podrá extender $g : \mathbb{R} \to \mathbb{R}$; pedimos lo mínimo). La situación es

$$\Omega \xrightarrow{X} X(\Omega) \xrightarrow{g} \mathbb{R}.$$

Como tantas tradiciones de notación en Teoría de Probabilidades, se anota $g(X)$ para indicar $g \circ X$. Por ejemplo, anotaremos $Y = X^2$ cuando $Y = g(X)$ y $g(t) = t^2$.

En esta parte del curso nos interesa el caso en que X es discreta. En ese caso $Y = g(X)$ es también discreta porque $Y(\Omega) = g(X(\Omega))$ y como $X(\Omega)$ es numerable, lo es su imagen por una función cualquiera. Podría suceder que $X(\Omega)$ sea infinito y $Y(\Omega)$ finito. Por ejemplo cuando g es constante.

El siguiente resultado, en caso de que $g(X)$ tenga esperanza, permite plantear un cálculo sin usar su función de densidad, y usando la de X.

Proposición. *Sean (Ω, P) un espacio de probabilidad, y $X : \Omega \to \mathbb{R}$ una v.a. discreta. Sea $g : X(\Omega) \to \mathbb{R}$ una función. Si*

$$\sum_{t\in X(\Omega)} |g(t)| f_X(t) < \infty\,,$$

entonces $Y = g(X)$ tiene esperanza y

$$E(Y) = \sum_{t\in X(\Omega)} g(t) f_X(t).$$

Demostración. Aceptamos que la hipótesis garantiza que $Y = g(X)$ tiene esperanza y que las series que aparecen a continuación son absolutamente convergentes (comprobarlo como ejercicio; si son sumas finitas no hay nada que hacer), para concentrarnos en la fórmula para la esperanza.

Supongamos que

$$Y(\Omega) = g(X(\Omega)) = \{y_1, y_2, \ldots\}, \qquad X(\Omega) = \{x_1, x_2, \ldots\}.$$

Vamos a partir a $X(\Omega)$ en conjuntos disjuntos dos a dos $D_1, D_2, \ldots$. Sea, para cada k,

$$D_k = g^{-1}(\{y_k\}) = \{x_i : g(x_i) = y_k\}.$$

Entonces

$$E(Y) = E(g(X)) = \sum_k y_k \, P[Y = y_k] = \sum_k y_k \left[\sum_{x_i \in D_k} P[X = x_i] \right].$$

Pero como para todo $x_i \in D_k$, $g(x_i) = y_k$, resulta

$$E(Y) = \sum_k \left[\sum_{x_i \in D_k} g(x_i) f_X(x_i) \right] = \sum_i g(x_i) f_X(x_i).$$

□

Ejemplo. *Se arroja 3 veces consecutivas una moneda equilibrada y hay un premio de \$2, \$7, \$10 respectivamente según la cantidad de caras sea 1, 2 o 3. En caso de no obtener ninguna cara debemos pagar \$20. Si Z es el "premio", calcular $E(Z)$.*

Solución Si Y es "número de caras" tenemos

$$Y(\Omega) = \{0, 1, 2, 3\}.$$

Sea $g : Y(\Omega) \to \mathbb{R}$, $Z = g(Y)$, con

$$g(0) = -20, \qquad g(1) = 2, \qquad g(2) = 7, \qquad g(3) = 10.$$

Entonces

$$\begin{aligned} E(Z) = E(g(Y)) &= \sum_{k=0}^{3} P[Y = k] g(k) \\ &= \binom{3}{0} \frac{1}{2^3} g(0) + \binom{3}{1} \frac{1}{2^3} g(1) + \binom{3}{2} \frac{1}{2^3} g(2) + \binom{3}{3} \frac{1}{2^3} g(3) \\ &= \frac{1}{8}[-20 + 3 \cdot 2 + 3 \cdot 7 + 10] = \frac{17}{8} = 2{,}125. \end{aligned}$$

Otro ejemplo:

Ejemplo. *Se elige un número entero al azar entre 1 y m (m fijo, $m > 1$). Calcular el valor esperado del cuadrado del número elegido.*

Solución Aunque no es necesario, una vez más planteamos con cierto detalle:

$$\Omega = I_m = \{1, 2, \ldots, m\}.$$

Si $X(\omega) = \omega$, nos piden calcular $E(X^2)$. Tenemos que

$$f_X(k) = P[X = k] = \frac{1}{m}$$

(es un caso particular donde $X(\Omega)$ coincide con Ω). Entonces

$$E(X^2) = \sum_{k=1}^{m} \frac{k^2}{m} = \frac{1}{m} \sum_{k=1}^{m} k^2.$$

Y por una conocida fórmula:

$$E(X^2) = \frac{1}{m} \frac{m(m+1)(2m+1)}{6} = \frac{(m+1)(2m+1)}{6}.$$

Por ejemplo, si $m = 11$ tenemos $E(X^2) = 46$. En este caso, notemos que $E(X^2) > E(X)^2$, ya que

$$E(X) = \frac{\sum_{k=1}^{m} k}{m} = \frac{m(m+1)}{2m} = \frac{m+1}{2};$$

si $m = 11$, $(E(X))^2 = 36$.

En general se cumple

$$E(X^2) \geq E(X)^2,$$

desigualdad que se prueba en forma sencilla pero que postergamos unas páginas porque será muy natural en otro contexto.

Sean ahora X e Y dos v.a. discretas. Dada una función $g : X(\Omega) \times Y(\Omega) \to \mathbb{R}$, se usa la notación $Z = g(X, Y)$ para indicar la variable aleatoria

$$Z(\omega) = g(X(\omega), Y(\omega)).$$

Z es discreta porque

$$Z(\Omega) \subset g(X(\Omega) \times Y(\Omega))$$

y $X(\Omega) \times Y(\Omega)$ es numerable. Generalmente en las aplicaciones, g es la restricción de una función $\mathbb{R}^2 \to \mathbb{R}$, por ejemplo $g(u, v) = u^2 v$.

Proposición. *Sean X, Y dos variables aleatorias discretas, en un espacio de probabilidad (Ω, P). Supongamos que*

$$X(\Omega) = \{x_1, x_2, \ldots\}, \qquad Y(\Omega) = \{y_1, y_2, \ldots\},$$

y sea $g : X(\Omega) \times Y(\Omega) \to \mathbb{R}$ una función tal que

$$\sum_i \sum_j |g(x_i, y_j)| \, P[(X = x_i) \cap (Y = y_j)] < \infty.$$

Entonces $Z = g(X, Y)$ tiene esperanza y

$$E(g(X, Y)) = \sum_i \sum_j g(x_i, y_j) \, P[(X = x_i) \cap (Y = y_j)].$$

Demostración. Ejercicio. □

Con ayuda de la proposición anterior llegaremos por fin a probar que

$$E(X + Y) = E(X) + E(Y).$$

Demostración de $E(X + Y) = E(X) + E(Y)$. Sean X, Y dos variables aleatorias discretas, en un espacio de probabilidad (Ω, P). Como de costumbre suponemos

$$X(\Omega) = \{x_1, x_2, \ldots\}, \qquad Y(\Omega) = \{y_1, y_2, \ldots\}.$$

Supongamos además que X e Y tienen esperanza. Si bien es sencillo, no damos los detalles técnicos de la existencia de $E(X+Y)$, y pasamos directamente al cálculo. Considerando $g(u, v) = u+v$ resulta $X+Y = g(X, Y)$ y entonces aplicando la proposición anterior:

$$\begin{aligned}
E(X + Y) &= \sum_i \sum_j (x_i + y_j) P[(X = x_i) \cap (Y = y_j)] \\
&= \sum_i \sum_j x_i P[(X = x_i) \cap (Y = y_j)] + \sum_i \sum_j y_j P[(X = x_i) \cap (Y = y_j)] \\
&= \sum_i x_i \left[\sum_j P[(X = x_i) \cap (Y = y_j)] \right] + \sum_j y_j \left[\sum_i P[(X = x_i) \cap (Y = y_j)] \right] \\
&= \sum_i x_i \, P(X = x_i) + \sum_j y_j \, P(Y = y_j) \\
&= E(X) + E(Y).
\end{aligned}$$

□

Naturalmente, usando inducción se extiende a sumas de finitas v.a. discretas con esperanza:

$$E\left(\sum_{j=1}^{m} X_j\right) = \sum_{j=1}^{m} E(X_j),$$

donde todas las X_j están definidas en el mismo espacio de probabilidad. Como en breve veremos, esta fórmula permite resolver la esperanza de v.a. complicadas si se logra descomponerla en suma de varias sencillas.

Indicadoras

Las indicadoras (también llamadas funciones características) son v.a. discretas sencillísimas y muy útiles. Sea (Ω, P) un espacio de probabilidad y $A \subset \Omega$ un suceso fijo. La indicadora de A es la v.a. definida como

$$I_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

La primera observación es que si una v.a. discreta $X : \Omega \to \mathbb{R}$ cumple $X(\Omega) \subseteq \{0, 1\}$ es siempre una indicadora:

$$X = I_A \qquad \text{donde } A = [X = 1].$$

(Notar que vale esto aun cuando $A = \varnothing$, ya que $I_\varnothing \equiv 0$, o si $A = \Omega$, $I_\Omega \equiv 1$.)
Las indicadoras tienen varias propiedades útiles, que proponemos como ejercicio:

Ejercicio. *a)* $I_{A^c} = 1 - I_A$ *(1 puede verse como una v.a constante).*

b) $I_{A_1 \cap \cdots \cap A_m} = I_{A_1} I_{A_2} \cdots I_{A_m}$.

c) Si $(A_j)_{j=1}^m$ *son mutuamente excluyentes:* $I_{A_1 \cup \cdots \cup A_m} = I_{A_1} + \cdots + I_{A_m}$.

d) $I_A = (I_A)^2$.

e) $E(I_A) = P(A)$.

Las propiedades de la *a)* a la *d)* son "conjuntistas", es decir que no tienen que ver con la teoría de probabilidades.

Algunos comentarios sobre la propiedad $E(I_A) = P(A)$

Recordemos la motivación "frecuencial" de la esperanza. De acuerdo a ese punto de vista podemos pensar a $E(I_A)$ como la ganancia promedio en el juego que consiste en elegir un $\omega \in \Omega$ al "azar" (con comillas porque podemos decir "de acuerdo a la probabilidad P") y ganar \$1 cuando $\omega \in A$, pero sin ganar ni perder nada cuando $\omega \notin A$.

Cuando se participa en N juegos consecutivos (pensar N grande...) el sentido común indica que la cantidad de juegos con ganancia de \$1 debería parecerse a $N \cdot P(A)$, y entonces la ganancia promedio por juego se debe parecer mucho a $P(A)$.

Una preocupación que ya tuvieron matemáticos como G. Cardano (Italia, siglo XVI) y J. Bernoulli (Suiza, siglo XVII), era cómo darle un marco matemático a este razonamiento. Este será un tema de los tramos finales de nuestro curso, pero vamos a hablar un poco de él de todos modos.

Supongamos que N es un número natural "grande". Hemos aprendido a construir un espacio de probabilidad, que llamaremos $(\widetilde{\Omega}, \widetilde{P})$, tal que

$$\widetilde{\Omega} = \underbrace{\Omega \times \cdots \times \Omega}_{N \text{ veces}},$$

y donde se matematiza la idea de realizar N experimentos sucesivos iguales e independientes. Para cada "tira" $(\omega_1, \ldots, \omega_N)$ de resultados, nos interesa definir la cantidad de "éxitos" (cantidad de coordenadas que pertenecen a A). Una manera formal de hacerlo es definir variables aleatorias $X_1, X_2, \ldots, X_N$ del siguiente modo. Para cada k,

$$X_k(\omega_1, \ldots, \omega_N) = \begin{cases} 1, & \omega_k \in A, \\ 0, & \omega_k \notin A. \end{cases}$$

La "cantidad de éxitos" es la v.a. $X_1 + \cdots + X_N$; la ganancia media es

$$\frac{X_1 + \cdots + X_N}{N}.$$

Más precisamente, si $\alpha = (\omega_1, \ldots, \omega_N)$ tenemos la percepción de que

$$\frac{X_1(\alpha) + \cdots + X_N(\alpha)}{N}$$

tendría que acercarse a $P(A)$. Esto no es fácil de decir matemáticamente porque puede haber muchos α donde eso no suceda. El primer aporte en este sentido fue de J. Bernoulli. Una idea más audaz (soñada en el siglo XIX) es darle legalidad matemática al experimento (irrealizable en la práctica) de hacer infinitas veces el experimento. Esto fue conseguido en el siglo XX a través de las teorías de Lebesgue y Kolmogorov de las que ya hablamos alguna vez. Todos estos resultados pertenecen a un capítulo de la Teoría de Probabilidades que se conoce como "Leyes de los grandes números". De hecho, Bernoulli demostró la primera ley de ese tipo y Kolmogorov otra ley más fuerte que incluye a la anterior (300 añitos después...) para una cantidad infinita numerable de pruebas.

Indicadoras y la distribución binomial

Consideremos una v.a. con distribución binomial $B(n,p)$ (n, p fijos). Podemos asociarla con el experimento de arrojar n veces una moneda con probabilidad p de cara y la v.a. $X : \Omega \to \mathbb{R}$, $X =$ "número de caras". Ya hemos calculado (con cierto esfuerzo) el valor $E(X) = np$. Vamos a dar un camino mucho más sencillo.

Para cada $k = 1, \ldots, n$ se define la indicadora

$$X_k = \begin{cases} 1, & \text{si la } k\text{-ésima es cara,} \\ 0, & \text{si no.} \end{cases}$$

Notamos que para cada k es $X_k = I_{A_k}$, donde $A_k =$ "la k-ésima tirada es cara". Claramente

$$X = X_1 + \cdots + X_n.$$

Luego

$$E(X) = E(X_1) + \cdots + E(X_n) = P(A_1) + \cdots + P(A_n) = \underbrace{p + \cdots + p}_{n \text{ veces}} = np.$$

Fórmula de inclusión-exclusión: demostración con indicadoras

Consideremos un espacio de probabilidad (Ω, P) y m sucesos $A_1, \ldots, A_m \subset \Omega$. Calcularemos $P(A_1 \cup \cdots \cup A_m)$.

$$P\left(\bigcup_{k=1}^{m} A_k\right) = E\left(I_{\cup_{k=1}^m A_k}\right) = 1 - E\left(I_{(\cup_{k=1}^m A_k)^c}\right) = 1 - E\left(I_{\cap_{k=1}^m A_k^c}\right) = 1 - E\left(\prod_{k=1}^{m} I_{A_k^c}\right)$$
$$= 1 - E\left((1 - I_{A_1}) \cdots (1 - I_{A_m})\right).$$

Este es el punto crucial: si desarrollamos el producto de funciones

$$(1 - I_{A_1}) \cdots (1 - I_{A_m}),$$

al distribuir podemos elegir 1 en todos los factores, con lo que resulta $1 \cdots 1 = 1$; elegir 1 en $(m-1)$ factores con lo que obtenemos

$$-\sum_{k=1}^{m} I_{A_k};$$

elegir 1 en $(m-2)$ factores con lo que obtenemos

$$\sum_{1 \le k_1 < k_2 \le m} I_{A_{k_1}} I_{A_{k_2}},$$

y así sucesivamente. Entonces, si recorremos con el índice j la cantidad de productos de indicadores, resulta

$$\prod_{k=1}^{m} (1 - I_{A_k}) = 1 + \sum_{j=1}^{m} (-1)^j \sum_{1 \le k_1 < \cdots < k_j \le m} \left(\prod_{i=1}^{j} I_{A_{k_i}}\right).$$

Retomando el cálculo principal,

$$\begin{aligned}
P\left(\bigcup_{k=1}^{m} A_k\right) &= 1 - E\left(\prod_{k=1}^{m}(1 - I_{A_k})\right) \\
&= -E\left(\sum_{j=1}^{m}(-1)^j \sum_{1\le k_1<\cdots<k_j\le m}\left(\prod_{i=1}^{j} I_{A_{k_i}}\right)\right) \\
&= \sum_{j=1}^{m}(-1)^{j+1} \sum_{1\le k_1<\cdots<k_j\le m} E\left(\prod_{i=1}^{j} I_{A_{k_i}}\right) \\
&= \sum_{j=1}^{m}(-1)^{j+1} \sum_{1\le k_1<\cdots<k_j\le m} E(I_{A_{k_1}\cap\cdots\cap A_{k_j}}) \\
&= \sum_{j=1}^{m}(-1)^{j+1} \sum_{1\le k_1<\cdots<k_j\le m} P(A_{k_1}\cap\cdots\cap A_{k_j}).
\end{aligned}$$

Varianza de variables aleatorias discretas

Si de una v.a. discreta X solo conocemos su esperanza, estamos muy lejos de tener una idea de ella. En la interpretación frecuencial, si se sabe por ejemplo que $E(X) = 0$, puede suceder que en casi todas las pruebas el resultado es muy cercano a 0 (en un caso extremo todas), o bien que ese valor sea consecuencia de una compensación entre muchos resultados positivos y grandes con otros tantos negativos de gran valor absoluto. Un caso extremo de este último comportamiento podría ser una v.a. X tal que

$$X(\Omega) = \{-1000, 1000\}, \qquad P[X = 1000] = P[X = -1000] = \frac{1}{2}.$$

Sería interesante, para las v.a. con esperanza, encontrar una medida de la "dispersión" de los valores de X respecto de la media. Si $\mu = E(X)$, un primer intento es el siguiente. Para cada $\omega \in \Omega$ se considera

$$Z(\omega) = |X(\omega) - \mu|.$$

Podría llamarse "desvío de X respecto de μ". Entonces podría definirse el "desvío medio" $E(Z)$ como una medida de dispersión. Esta es una medida razonable, pero tal como se discute en el libro de Ross (pág. 132) es de complicado manejo matemático. En el futuro se usarán herramientas de análisis matemático para las que el valor absoluto es poco amigable.

Entonces en teoría de probabilidades se usa otra medida que resulta tener similar significado y es más manejable. Naturalmente, como en todos los desarrollos matemáticos, las definiciones "buenas" resultan de años de uso donde se ve si reflejan lo que se desea, si son útiles para las aplicaciones, etc.

Definición. *Sea X una v.a. discreta con $E(X) = \mu$. Consideremos*

$$Y = (X - \mu)^2,$$

es decir $Y(\omega) = (X(\omega) - \mu)^2$ para todo ω. Y mide lo que podría llamarse el "desvío cuadrático" de los valores de X. Cuando Y tiene esperanza, llamaremos a ese valor <u>varianza</u> de X y lo anotaremos $\mathrm{Var}(X)$*. De modo que*

$$\mathrm{Var}(X) := E((X - \mu)^2).$$

Para el cálculo concreto, observamos que $\mathrm{Var}(X) = E(g(X))$ con $g(X) = (X - \mu)^2$, de modo que si $X(\Omega) = \{x_1, x_2, \ldots\}$,

$$\mathrm{Var}(X) = \sum_k f_X(x_k)(x_k - \mu)^2.$$

Cuando $X(\Omega)$ es finito, hay siempre esperanza y varianza. Cuando $X(\Omega)$ es infinito numerable, puede pasar que haya esperanza y que, sin embargo, la serie

$$\sum_k f_X(x_k)(x_k - \mu)^2$$

diverja. En este caso es una serie de términos no negativos (así que, si diverge, las sumas parciales se acercan a $+\infty$). Entonces nos vamos a dar permiso de anotar $\mathrm{Var}(X) = +\infty$.

Cuando comparamos $E(|X - \mu|)$ con $E((X - \mu)^2)$ aparecen problemas de "orden de magnitud", porque si $|X(\omega) - \mu| = 100$ (por ejemplo), $|X(\omega) - \mu|^2 = 10000$. Surge la definición siguiente.

Definición. *Si X es una v.a con varianza finita, se define el desvío (o desvío estándar) de X como su raíz cuadrada:*

$$D(X) := \sqrt{\mathrm{Var}(X)}.$$

Hay una vieja tradición de anotar $E(X)$ con la letra μ, y $D(X)$ con σ. El desvío así definido tiene similar orden de magnitud que $E(|X-\mu|)$ y apuntan a medir lo mismo.

Veamos algunas propiedades de la varianza (y en consecuencia del desvío), aunque las principales necesitan otras herramientas que serán desarrolladas en apuntes próximos.

Proposición. *a)* $\mathrm{Var}(X) \geq 0$.

b) $\mathrm{Var}(X) = 0 \iff \exists c : P[X = c] = 1$.
(Esto significa que si X toma más valores aparte de c, la probabilidad de hacerlo es 0; es decir si $d \neq c$, $P[X = d] = 0$. Puede pensarse $X \equiv c$ ya que otros valores no influyen en ningún cálculo).

c) Si X es una v.a. discreta con esperanza, entonces tiene varianza finita si y solo si X^2 tiene esperanza, y se cumple

$$\mathrm{Var}(X) = E(X^2) - (E(X))^2.$$

d) Si X tiene varianza finita y $c \in \mathbb{R}$,

$$\mathrm{Var}(X + c) = \mathrm{Var}(X) \qquad y \qquad D(X + c) = D(X).$$

(Este resultado es muy natural porque la dispersión de los valores $x_1, x_2, \ldots$ con respecto a la esperanza $\mu = E(X)$ es la misma que la de los valores $x_1 + c, x_2 + c, \ldots$ respecto de $\mu + c = E(X + c)$.
***NO** es cierto en general $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$. Es un tema importante del apunte teórico siguiente).*

e) Si X tiene varianza finita y $c \in \mathbb{R}$,

$$\mathrm{Var}(cX) = c^2 \,\mathrm{Var}(X) \qquad y \qquad D(cX) = |c| D(X).$$

Demostración. a) y *b)*: Ejercicio.

c): Los cálculos que siguen son muy simples cuando $X(\Omega)$ es finito. Hacemos entonces el caso infinito: $X(\Omega) = \{x_1, x_2, \ldots\}$.

$$(X - \mu)^2 = X^2 - 2\mu X + \mu^2 \,.$$

Acá μ y μ^2 pueden tratarse, según nos convenga, como valores reales o como v.a constantes. Tenemos por un lado la serie que define la varianza

$$\sum_k (x_k - \mu)^2 f_X(x_k),$$

que es igual a la serie

$$\sum_k (x_k^2 - 2\mu\, x_k + \mu^2) f_X(x_k).$$

Esta última da origen a tres series

$$\sum_k x_k^2 \, f_X(x_k), \qquad \sum_k -2\mu\, x_k \, f_X(x_k), \qquad \sum_k f_X(x_k)\, \mu^2.$$

Como las dos últimas son convergentes (a $-2\mu^2$ y μ^2 respectivamente), resulta que las series

$$\sum_k (x_k - \mu)^2 f_X(x_k), \qquad \sum_k x_k^2 \, f_X(x_k)$$

convergen ambas o divergen ambas. En caso de convergencia (las sumas son $\mathrm{Var}(X)$ y $E(X^2)$), dejamos como ejercicio la igualdad

$$\mathrm{Var}(X) = E(X^2) - (E(X))^2.$$

d): Ejercicio.

e):

$$\mathrm{Var}(cX) = E((cX)^2) - (E(cX))^2 = E(c^2X^2) - c^2(E(X))^2 = c^2(E(X^2) - (E(X))^2) = c^2 \,\mathrm{Var}(X).$$

□

Algunos ejemplos

I) Varianza de una indicadora. Si $X = I_A$ entonces

$$\mathrm{Var}(X) = E(I_A^2) - (E(I_A))^2.$$

Pero como $I_A^2 = I_A$, entonces

$$\mathrm{Var}(X) = E(I_A) - (E(I_A))^2 = P(A) - (P(A))^2 = P(A)(1 - P(A)).$$

II) Varianza de $B(n,p)$. Nótese que, como la esperanza, la varianza solo depende de f_X, lo cual justifica el lenguaje que estamos usando. Antes de hacer el cálculo, que será un poco engorroso, vamos a comentar que en el siguiente apunte teórico aparecerá un método rapidísimo, tal como sucedió con la esperanza de $B(n,p)$.
Ahora sí, los cálculos. Recordamos que X tiene distribución $B(n,p)$ cuando

$$X(\Omega) = \{0, 1, 2, \ldots, n\}$$

y

$$f_X(k) = \binom{n}{k} p^k (1-p)^{n-k}$$

para todo $k \in X(\Omega)$. En primer lugar calculamos $E(X^2)$:

$$\begin{aligned} E(X^2) &= \sum_{k=0}^{n} k^2 \binom{n}{k} p^k (1-p)^{n-k} \\ &= \sum_{k=1}^{n} k^2 \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \\ &= np \sum_{j=0}^{n-1} (j+1) \binom{n-1}{j} p^j (1-p)^{(n-1)-j} \\ &= np \left(\sum_{j=0}^{n-1} j \binom{n-1}{j} p^j (1-p)^{(n-1)-j} + \sum_{j=0}^{n-1} \binom{n-1}{j} p^j (1-p)^{(n-1)-j} \right). \end{aligned}$$

Si Y es una v.a. cualquiera con distribución $B(n-1,p)$ hemos obtenido

$$E(X^2) = np \left[E(Y) + \sum_{j=0}^{n-1} f_Y(j) \right] = np[(n-1)p + 1].$$

Entonces

$$\mathrm{Var}(X) = E(X^2) - (E(X))^2 = np[(n-1)p + 1] - (np)^2 = np(1-p).$$

III) Varianza de la geométrica. Si X tiene esta distribución con parámetro p (Geom(p)):

$$E(X^2) = \sum_{k=1}^{\infty} k^2 f_X(k) = \sum_{k=1}^{\infty} k^2 (1-p)^{k-1} p.$$

Para poder usar ahora propiedades de series de potencias (derivación término a término) vamos a escribir

$$k^2 = k(k-1) + k.$$

Entonces

$$E(X^2) = p \left[\sum_{k=1}^{\infty} k(k-1)(1-p)^{k-1} + \sum_{k=1}^{\infty} k(1-p)^{k-1} \right].$$

La primera suma nos conducirá a la derivada segunda y la segunda suma a la derivada de $g(x) = 1/(1-x)$:

$$E(X^2) = (1-x) \left[\sum_{k=2}^{\infty} k(k-1) x\, x^{k-2} + \sum_{k=1}^{\infty} k x^{k-1} \right] = x(1-x) g''(x) + (1-x) g'(x),$$

donde

$$g(x) = \sum_{k=0}^{\infty} x^k = \frac{1}{1-x}.$$

Entonces

$$E(X^2) = \frac{2x}{(1-x)^2} + \frac{1}{1-x} = \frac{1+x}{(1-x)^2}.$$

Como $E(X) = 1/(1-x)$ resulta

$$\mathrm{Var}(X) = E(X^2) - (E(X))^2 = \frac{1+x}{(1-x)^2} - \frac{1}{(1-x)^2} = \frac{x}{(1-x)^2} = \frac{1-p}{p^2} = \frac{1}{p^2} - \frac{1}{p}.$$

IV) Varianza de la hipergeométrica. Ver en Ross, página 460, que esta varianza tiene una leve diferencia con lo esperable. Las razones serán un tema futuro.

Finalizamos este apunte con una fórmula que muchas veces será útil.

Una fórmula útil para la esperanza

Proposición. *Consideremos una v.a. X tal que*

$$X(\Omega) \subset \{0, 1, 2, \ldots\}$$

(puede extenderse $f_X : \{0, 1, 2, \ldots\} \to [0, 1]$ definiendo $f_X(k) = 0$ cuando $k \notin X(\Omega)$). Para este tipo de variables vale la siguiente fórmula:

$$E(X) = \sum_{k=0}^{\infty} P[X > k]$$

(si la serie diverge, X no tiene esperanza).

Demostración. En lo que sigue nos centraremos en la idea. Respecto a la justificación técnica solo diremos que, como todos los términos involucrados son no negativos, se pueden reordenar incluso si la suma vale $+\infty$.
Consideremos las siguientes igualdades en "fila":

$$1 \cdot f_X(1) = P[X = 1]$$

$$2 \cdot f_X(2) = P[X = 2] + P[X = 2]$$

$$3 \cdot f_X(3) = P[X = 3] + P[X = 3] + P[X = 3]$$

y así sucesivamente. Si observamos, la suma de las filas da $E(X)$. Si hacemos la misma suma por columnas, la clave está en que la 1ra columna da como suma $P[X > 0]$, la 2da $P[X > 1]$, y así sucesivamente. □

Ejemplo. *Se arroja 4 veces consecutivas un dado equilibrado. Sea $Z =$ "mejor resultado de los 4". Calcular $E(Z)$.*

Solución Para $k = 0$ tenemos

$$P[Z > 0] = 1.$$

Si $k > 0$ definamos

$$A_k = \text{"todas las tiradas fueron menores o iguales a } k\text{"}.$$

Se tiene

$$[Z > k] = A_k^c,$$

$$P[Z > k] = 1 - P(A_k) = 1 - \left(\frac{k}{6}\right)^4 \qquad (\text{¿por qué?}).$$

Entonces, como $P[Z > k] = 0$ para $k \geq 6$, el resultado es

$$E(Z) = \sum_{k=0}^{5} P[Z > k] = \sum_{k=0}^{5} \left(1 - \left(\frac{k}{6}\right)^4\right) \simeq 4,25.$$