TP5

Vectores aleatorios

Supongamos que $X_1, \ldots, X_m$ son variables aleatorias con dominio en Ω, siendo (Ω, P) un cierto espacio de probabilidad. En principio no pedimos que las v.a. sean de ningún tipo determinado.

Llamaremos vector aleatorio $(X_1, \ldots, X_m)$ a la función

$$(X_1, \ldots, X_m) : \Omega \longrightarrow \mathbb{R}^m$$

definida como

$$(X_1, \ldots, X_m)(\omega) = (X_1(\omega), \ldots, X_m(\omega)).$$

Para entender mejor el uso de este y otros conceptos, vamos a tratar el caso $m = 2$. Aquí tenemos dos variables aleatorias X e Y (que corresponden a X_1 y X_2) y $(X, Y)(\omega) = (X(\omega), Y(\omega))$.

Son usuales las notaciones siguientes. Si $A, B \subset \mathbb{R}$,

$$[X \in A] \cap [Y \in B]$$

se escribirá

$$[(X, Y) \in A \times B] \quad \text{o} \quad [X \in A, Y \in B].$$

Otro caso habitual es

$$[X = a] \cap [Y = b],$$

que, siguiendo esa lógica, será anotado como

$$[(X, Y) = (a, b)] \quad \text{o} \quad [X = a, Y = b].$$

Para conjuntos arbitrarios $T \subset \mathbb{R}^2$ anotaremos

$$[(X, Y) \in T]$$

para indicar el conjunto $\{\omega / (X(\omega), Y(\omega)) \in T\}$.

Función de probabilidad conjunta de variables aleatorias discretas

Se dice que el vector aleatorio (X, Y) es discreto cuando

$$(X, Y)(\Omega) = \{(X(\omega), Y(\omega)) / \omega \in \Omega\}$$

es numerable (finito o infinito).

Si X e Y son discretas, el vector aleatorio (X, Y) es discreto ya que

$$(X, Y)(\Omega) \subset X(\Omega) \times Y(\Omega)$$

y el producto cartesiano de numerables es numerable. Recíprocamente, si el vector aleatorio es discreto, las v.a. lo son. Por ejemplo, para probar que $X(\Omega)$ es numerable consideramos

$$H : (X, Y)(\Omega) \longrightarrow X(\Omega), \qquad H(u, v) = u.$$

$X(\Omega)$ es la imagen por H del conjunto numerable $(X, Y)(\Omega)$. Análogamente $Y(\Omega)$ es numerable.

Definición. *Dadas X e Y v.a. discretas en (Ω, P), se define la función de probabilidad conjunta (o densidad discreta conjunta) de X e Y*

$$f_{X,Y} : X(\Omega) \times Y(\Omega) \longrightarrow [0, 1]$$

por

$$f_{X,Y}(a, b) = P[X = a, Y = b].$$

Notemos que puede ocurrir que $(a,b) \in X(\Omega) \times Y(\Omega)$, pero $(a,b) \notin (X,Y)(\Omega)$: en ese caso $f_{X,Y}(a,b) = 0$.
Si es necesario, puede extenderse el dominio de $f_{X,Y}$ a $\mathbb{R}^2$, ya que si $(a,b) \notin X(\Omega) \times Y(\Omega)$, $P[X = a, Y = b] = 0$.

Ejemplo. *Se elige al azar un número entero entre 100 y 999. Sean*

$$X = \text{“último dígito del n° elegido”}, \qquad Y = \text{“cantidad de dígitos iguales a 7 del n° elegido”}.$$

Se tiene

$$X(\Omega) = \{0, \ldots, 9\}, \qquad Y(\Omega) = \{0, 1, 2, 3\},$$

y

$$\forall A \subset \Omega : \qquad P(A) = \frac{\#(A)}{\#(\Omega)} = \frac{\#(A)}{900} \qquad (\textit{equiprobable}).$$

Se tienen casos como estos:

$$f_{X,Y}(4,1) = P[X = 4, Y = 1] = \frac{19}{900} \quad (\textit{ejercicio}),$$

$$f_{X,Y}(5,2) = P[X = 5, Y = 2] = \frac{1}{900}.$$

Propiedades de la función de probabilidad conjunta

Seguimos con el caso de un vector aleatorio discreto $(X,Y) : \Omega \to \mathbb{R}^2$. Supongamos

$$X(\Omega) = \{x_1, x_2, \ldots\}, \qquad Y(\Omega) = \{y_1, y_2, \ldots\}.$$

Proposición. *a) Para todo $A \subset \mathbb{R}^2$,*

$$P((X,Y) \in A) = \sum_{(x_i,y_j) \in A} f_{X,Y}(x_i, y_j)$$

(acá aclaramos que en cualquier caso, el conjunto de sumandos no nulos es numerable y son todos no negativos, por lo que se puede sumar de cualquier modo). En particular,

$$P[(X,Y) \in \mathbb{R}^2] = \sum_{i,j} f_{X,Y}(x_i, y_j) = \sum_i \left[\sum_j f_{X,Y}(x_i, y_j) \right] = 1\,.$$

b) Para cada i fijo,

$$f_X(x_i) = \sum_j f_{X,Y}(x_i, y_j).$$

c) Para cada j fijo,

$$f_Y(y_j) = \sum_i f_{X,Y}(x_i, y_j).$$

Demostración. a) Ejercicio.
b) Para cada i:

$$f_X(x_i) = P[X = x_i] = P[X = x_i, Y \in \mathbb{R}] = P\left(\bigcup_j [X = x_i, Y = y_j] \right) = \sum_j P[X = x_i, Y = y_j] = \sum_j f_{X,Y}(x_i, y_j).$$

c) Es análogo a *b)*. □

Las identidades de *b)* y *c)* son el motivo por el cual f_X y f_Y se suelen llamar funciones de probabilidad marginales de $f_{X,Y}$.

Con las mismas ideas con que hemos desarrollado la función de probabilidad conjunta de dos v.a. discretas se puede trabajar en los vectores aleatorios discretos $(X_1, \ldots, X_m)$. Como en todos los temas de este curso vamos a evitar desarrollos muy técnicos que no suman ideas nuevas. Aquí tendremos

$$f_{X_1,\ldots,X_m} : X_1(\Omega) \times \cdots \times X_m(\Omega) \longrightarrow [0,1],$$

$$f_{X_1,\ldots,X_m}(a_1, \ldots, a_m) = P[X_1 = a_1, \ldots, X_m = a_m],$$

donde

$$[X_1 = a_1, \ldots, X_m = a_m] = \bigcap_{k=1}^{m} [X_k = a_k].$$

Independencia de variables aleatorias

La idea que queremos expresar matemáticamente es la siguiente:

Se tienen $X_1, \dots, X_m$ variables aleatorias (en principio de cualquier tipo) en un espacio de probabilidad (Ω, P). La independencia querrá decir que si se tienen sucesos $A_1, \dots, A_m$ tales que, para cada k, A_k está "vinculado" a X_k, entonces $A_1, \dots, A_m$ deben ser independientes. Esto es bastante impreciso por el momento, ya que no está claro qué significa "vinculado". Antes de aclarar, un ejemplo:

Ejemplo. Se arroja m veces una moneda sucesivamente y $X_1, \dots, X_m$ son premios que solamente dependen, para cada índice k, de la tirada k-ésima. Un caso:

$$X_k = \begin{cases} 2 & \text{si la tirada } k \text{ es cara,} \\ 0 & \text{si no.} \end{cases}$$

Entonces el valor de X_k no sufre influencia de lo que puedan valer los X_j con $j \neq k$. Sucesos vinculados a las X_k podrían ser (entre muchos otros)

$$A_k = [X_k = 2], \qquad k = 1, \dots, m,$$

o

$$A_k = [X_k > k], \qquad k = 1, \dots, m.$$

En ambos casos, $A_1, \dots, A_m$ son independientes. La "vinculación" entre A_k y X_k se manifiesta en que A_k puede ser definido a través de X_k.

Vamos hacia la definición matemática de "suceso vinculado a una v.a.". Si (Ω, P) es un espacio de probabilidad y $X : \Omega \to \mathbb{R}$ una v.a. cualquiera, ejemplos de sucesos vinculados a X son:

$$[X > 1], \qquad [X = 3], \qquad [X \in (0, 1]], \ \dots \text{ etc.}$$

Lo que tienen de común es que en todos los casos pueden escribirse como

$$[X \in T]$$

para algún $T \subset \mathbb{R}$. Por ejemplo,

$$[X > 1] = [X \in (1, +\infty)], \qquad [X = 3] = [X \in \{3\}].$$

Esa será nuestra interpretación matemática de la "vinculación". Todo esto conduce a:

Definición. *Sea (Ω, P) un espacio de probabilidad. Dadas $X_1, \dots, X_m$ v.a. cualesquiera con dominio en Ω, decimos que son independientes cuando: para toda elección de conjuntos $T_1, \dots, T_m \subset \mathbb{R}$, los sucesos*

$$[X_k \in T_k], \qquad k = 1, \dots, m$$

son independientes.

Cuando se estudiaba la independencia de sucesos $A_1, \dots, A_m$ era necesario pedir

$$P\left(\bigcap_{k \in L} A_k\right) = \prod_{k \in L} P(A_k)$$

para cualquier subconjunto $L \subset \{1, \dots, m\}$. No alcanzaba la condición

$$P\left(\bigcap_{k=1}^{m} A_k\right) = \prod_{k=1}^{m} P(A_k).$$

Pero para la independencia de variables aleatorias sí podremos reducirnos al caso de todos los índices. Más precisamente:

Proposición. *Sea (Ω, P) un espacio de probabilidad y $(X_1, \dots, X_m)$ un vector aleatorio con dominio en Ω. Entonces $X_1, \dots, X_m$ son independientes si y solo si para toda elección de $T_1, \dots, T_m \subset \mathbb{R}$,*

$$P\left(\bigcap_{k=1}^{m} [X_k \in T_k]\right) = \prod_{k=1}^{m} P([X_k \in T_k]).$$

Demostración. Obviamente la condición con los T_k es necesaria. Para ver que es suficiente: sea $L \subset \{1, \ldots, m\}$ y sean $\tilde{T_k}$, para cada $k \in L$, subconjuntos de $\mathbb{R}$. Definamos

$$T_k = \begin{cases} \tilde{T_k}, & \text{si } k \in L, \\ \mathbb{R}, & \text{si no.} \end{cases}$$

Entonces para $k \notin L$,

$$[X_k \in T_k] = \Omega.$$

Luego

$$P\left[\bigcap_{k\in L}[X_k \in \tilde{T_k}]\right] = P\left[\bigcap_{k=1}^{m}[X_k \in T_k]\right] = \prod_{k=1}^{m} P[X_k \in T_k] = \prod_{k\in L} P[X_k \in \tilde{T_k}]\,,$$

es decir, $X_1, \ldots, X_m$ son independientes. □

En la práctica se decide la independencia de variables aleatorias por observación, o intuición probabilística. No será necesario un enfoque demasiado técnico para reconocerlas. Volviendo al razonamiento del ejemplo de la moneda, un caso muy común será el de un Ω armado a base de pruebas independientes y variables aleatorias que se refieren, cada una, a una prueba diferente.

A partir de ahora vamos a trabajar con v.a. discretas y tratar primero en detalle el caso $m = 2$.

Proposición. *Sea (Ω, P) un espacio de probabilidad y sean X e Y dos v.a. discretas con dominio en Ω (como sabemos esto es lo mismo que pedir que (X, Y) sea un vector aleatorio discreto). Supongamos que*

$$X(\Omega) = \{x_1, x_2, \ldots\}, \qquad Y(\Omega) = \{y_1, y_2, \ldots\}.$$

Entonces

$$X \text{ e } Y \text{ son independientes} \iff \forall(i,j) \quad f_{X,Y}(x_i, y_j) = f_X(x_i)\, f_Y(y_j).$$

Demostración. ($\Rightarrow$) Esta es la más simple y esperable porque, dados i y j fijos,

$$f_{X,Y}(x_i, y_j) = P[X = x_i, Y = y_j] = P[X \in \{x_i\}]\, P[Y \in \{y_j\}] = P[X = x_i]\, P[Y = y_j] = f_X(x_i)\, f_Y(y_j).$$

($\Leftarrow$) Sean $T_1, T_2 \subset \mathbb{R}$ y anotemos

$$I = \{i / x_i \in T_1\}, \qquad J = \{j / y_j \in T_2\}.$$

Entonces

$$P[X \in T_1, Y \in T_2] = P[(X,Y) \in T_1 \times T_2] = \sum_{i\in I}\sum_{j\in J} P[(X,Y) = (x_i, y_j)] = \sum_{i\in I}\sum_{j\in J} P[X = x_i, Y = y_j]$$

y esto es igual a

$$\sum_{i\in I}\sum_{j\in J} f_{X,Y}(x_i, y_j) = \sum_{i\in I}\sum_{j\in J} f_X(x_i) f_Y(y_j) = \left[\sum_{i\in I} f_X(x_i)\right]\left[\sum_{j\in J} f_Y(y_j)\right] = P[X \in T_1]\, P[Y \in T_2].$$

□

La implicación importante de la proposición anterior es ($\Leftarrow$) porque da un criterio para simplificar el reconocimiento de independencia.

Proposición. *Supongamos que $X, Y : \Omega \to \mathbb{R}$ son v.a. discretas independientes y que*

$$g_1 : X(\Omega) \to \mathbb{R}, \qquad g_2 : Y(\Omega) \to \mathbb{R}$$

son dos funciones. Entonces $g_1(X)$ y $g_2(Y)$ son independientes.

Demostración. Ya sabemos que $g_1(X)$ y $g_2(Y)$ son discretas. Si $T_1, T_2 \subset \mathbb{R}$,

$$\begin{aligned} P[g_1(X) \in T_1, g_2(Y) \in T_2] &= P[X \in g_1^{-1}(T_1), Y \in g_2^{-1}(T_2)] = P[X \in g_1^{-1}(T_1)]\, P[Y \in g_2^{-1}(T_2)] \\ &= P[g_1(X) \in T_1]\, P[g_2(Y) \in T_2]. \end{aligned}$$

□

Otra proposición muy importante:

Proposición. *Sea (Ω, P) un espacio de probabilidad y sean X, Y dos v.a. discretas, independientes y con esperanza finita. Entonces XY tiene esperanza finita y*

$$E(XY) = E(X)\,E(Y).$$

Demostración. Sean

$$X(\Omega) = \{x_1, x_2, \ldots\}, \qquad Y(\Omega) = \{y_1, y_2, \ldots\}.$$

Comprobar como ejercicio que

$$\sum_i \sum_j |x_i\, y_j| f_{X,Y}(x_i, y_j) < \infty\,.$$

Entonces por una proposición que vimos en el apunte anterior, $g(X,Y) = XY$ tiene esperanza, y la fórmula para su esperanza es

$$E(XY) = \sum_i \sum_j x_i\, y_j f_{X,Y}(x_i, y_j) = \sum_i \sum_j x_i\, y_j f_X(x_i) f_Y(y_j) = \left(\sum_i x_i f_X(x_i)\right)\left(\sum_j y_j f_Y(y_j)\right) = E(X)E(Y).$$

□

Observación. Puede cumplirse

$$E(XY) = E(X)E(Y)$$

sin que las v.a. sean independientes. Iremos viendo en este curso que cuando se cumple la igualdad, si bien puede no haber independencia, puede presentarse una dependencia "leve". A ese tema apunta la siguiente definición.

Definición. *Si existen $E(X)$, $E(Y)$, $E(XY)$ llamaremos covarianza de X e Y a*

$$\mathrm{Cov}(X,Y) := E(XY) - E(X)E(Y).$$

Notamos que

$$X, Y \text{ indep.} \Longrightarrow \mathrm{Cov}(X,Y) = 0.$$

Si bien no es un comentario muy matemático, la idea es que cuando el valor absoluto de $\mathrm{Cov}(X,Y)$ es "pequeño", la dependencia es "leve".

Proposición. *Tenemos las siguientes propiedades.*

a) $\mathrm{Cov}(X,Y) = \mathrm{Cov}(Y,X)$.

b) Para todo $a \in \mathbb{R}$: $\mathrm{Cov}(aX,Y) = \mathrm{Cov}(X,aY) = a\ \mathrm{Cov}(X,Y)$.

c) $\mathrm{Cov}(X_1 + X_2, Y) = \mathrm{Cov}(X_1,Y) + \mathrm{Cov}(X_2,Y)$.

$(a), b)$ y c) se resumen diciendo que la covarianza es "bilineal").

d) Si X tiene varianza finita

$$\mathrm{Var}(X) = \mathrm{Cov}(X,X).$$

e) Si X tiene esperanza e $Y \equiv c$,

$$\mathrm{Cov}(X,Y) = 0.$$

f) Si $a, b \in \mathbb{R}$,

$$\mathrm{Cov}(X + a, Y + b) = \mathrm{Cov}(X,Y).$$

g) Si $X, Y : \Omega \to \mathbb{R}$ tienen varianza finita, también la tiene $X + Y$ y vale:

$$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X,Y).$$

h) Si $X, Y : \Omega \to \mathbb{R}$ son v.a. discretas, independientes y con varianza finita, entonces

$$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y).$$

Demostración. $a) - f)$: ejercicio.

$g)$ Recordemos que la existencia de varianza necesita de la de esperanza y que $\mathrm{Var}(X) < +\infty$ equivale, como hemos probado en la teoría anterior, a $E(X^2) < \infty$, y lo mismo para Y:

$$\mathrm{Var}(X+Y) = E((X+Y)^2) - (E(X+Y))^2 = E(X^2) + E(Y^2) + 2E(XY) - (E(X))^2 - (E(Y))^2 - 2E(X)E(Y)$$

$$= \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X,Y).$$

$h)$: ejercicio. □

Caso de m variables

La mayoría de los resultados se obtienen con técnicas parecidas al caso de dos variables. Otros requieren mayores recursos matemáticos de los que tenemos. Vamos a priorizar la presentación y el manejo práctico, sin desarrollos técnicos que, por otra parte, se basan en las mismas ideas del caso $m = 2$.

Proposición. *Sea (Ω, P) un espacio de probabilidad, y sean $X_1, \ldots, X_m$ variables aleatorias discretas con dominio en Ω. Valen las siguientes:*

a) $X_1, \ldots, X_m$ son independientes si y solo si

$$f_{X_1,\ldots,X_m}(t_1, \ldots, t_m) = f_{X_1}(t_1) \cdots f_{X_m}(t_m)$$

para cualesquiera

$$(t_1, \ldots, t_m) \in X_1(\Omega) \times \cdots \times X_m(\Omega)\,.$$

b) Bajo hipótesis similares al caso de dos variables, si

$$g : X_1(\Omega) \times \cdots \times X_m(\Omega) \longrightarrow \mathbb{R},$$

cuando existe, se tiene

$$E(g(X_1, \ldots, X_m)) = \sum_{t_1} \cdots \sum_{t_m} g(t_1, \ldots, t_m)\, f_{X_1,\ldots,X_m}(t_1, \ldots, t_m).$$

c) Si $X_1, \ldots, X_m$ son independientes y $E(X_1), \ldots, E(X_m)$ existen, entonces

$$E(X_1 X_2 \cdots X_m) = E(X_1) \cdots E(X_m).$$

d) Bajo condiciones similares al caso de dos variables,

$$\mathrm{Var}\left(\sum_{i=1}^{m} X_i\right) = \sum_{i=1}^{m} \mathrm{Var}(X_i) + 2 \sum_{i<j} \mathrm{Cov}(X_i, X_j).$$

También puede escribirse

$$\mathrm{Var}\left(\sum_{i=1}^{m} X_i\right) = \sum_{i=1}^{m} \sum_{j=1}^{m} \mathrm{Cov}(X_i, X_j).$$

e) Si las variables son dos a dos independientes,

$$\mathrm{Var}\left(\sum_{i=1}^{m} X_i\right) = \sum_{i=1}^{m} \mathrm{Var}(X_i).$$

Veamos que aplicando e) se obtiene rápidamente la "varianza de la binomial":

Varianza de la binomial

Si X tiene distribución binomial $B(n, p)$, tal como hicimos para el cálculo de la esperanza, descomponemos

$$X = X_1 + \cdots + X_n,$$

donde cada X_i es una indicadora tal que $E(X_i) = p$. Las X_i son independientes. Probabilísticamente se ve esto claramente, pero tampoco es difícil una demostración. En ese sentido proponemos el siguiente ejercicio:

Ejercicio. Si se tiene (Ω, P) y $A_1, \ldots, A_n \subset \Omega$, $I_{A_1}, \ldots, I_{A_n}$ son independientes si y solo si $A_1, \ldots, A_n$ son independientes.

Finalmente, recordemos que en la teoría anterior, probamos que

$$\mathrm{Var}(I_A) = P(A)\big(1 - P(A)\big).$$

Aplicando a los X_i resulta (para todo i):

$$\mathrm{Var}(X_i) = p(1 - p),$$

y por la independencia

$$\mathrm{Var}(X) = \mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i) = np(1 - p).$$

Funciones de variables independientes

La propiedad [X, Y independientes $\Rightarrow g_1(X), g_2(Y)$ independientes] tiene un enunciado mucho más complejo en m variables, que lo veremos, pero lo importante no es el enunciado teórico sino su aplicación, que es sumamente sencilla.

Proposición. *Si*

$$X_1, \ldots, X_m$$

son v.a discretas independientes y se tienen k conjuntos de índices (entre 1 y m) disjuntos 2 a 2:

$$L_1 = \{i_1^{(1)}, \ldots, i_{r_1}^{(1)}\}, \ldots, L_k = \{i_1^{(k)}, \ldots, i_{r_k}^{(k)}\},$$

y $g_1, \ldots, g_k$ son funciones a valores reales, de $r_1, \ldots, r_k$ variables respectivamente; entonces las v.a.

$$g_1\left(X_{i_1^{(1)}}, \ldots, X_{i_{r_1}^{(1)}}\right), \ldots, g_k\left(X_{i_1^{(k)}}, \ldots, X_{i_{r_k}^{(k)}}\right)$$

son independientes.

Por ejemplo, si X_1, X_2, X_3, X_4 son independientes y se tienen dos funciones g_1, g_2, ambas de dos variables, las nuevas variables

$$g_1(X_1, X_4), \qquad g_2(X_2, X_3)$$

son independientes. También lo son, por ejemplo, las 3 variables

$$X_1^2,\ X_2,\ X_4 - X_3\,,$$

y las dos variables

$$X_2^3,\ 5 - X_1\,,$$

etcétera.

En las aplicaciones es muy sencillo. Vamos a resolver un ejercicio.

Ejercicio. Se arroja 10 veces una moneda equilibrada. Hay un premio en tantos \$ como caras se obtengan en las 6 primeras tiradas y un premio adicional de \$20 si las 4 últimas tiradas son todas cara. Hallar el premio esperado y el desvío.

Solución. Para cada k, sea, como de costumbre,

$$X_k = I_{A_k}, \qquad A_k = \text{“la tirada } k \text{ fue cara”}.$$

Llamamos Z al premio. Z se descompone en $Z = Z_1 + Z_2$, donde

$$Z_1 = \sum_{k=1}^{6} X_k$$

y

$$Z_2 = \begin{cases} 20, & \text{si } \displaystyle\sum_{k=7}^{10} X_k = 4, \\ 0, & \text{si no.} \end{cases}$$

Z_1 y Z_2 dependen de conjuntos disjuntos de tiradas y entonces son independientes. Usando las propiedades ya conocidas:

$$E(Z_1) = \sum_{k=1}^{6} E(X_k) = 6 \cdot \frac{1}{2} = 3,$$

$$\mathrm{Var}(Z_1) = \sum_{k=1}^{6} \mathrm{Var}(X_k) = 6 \cdot \frac{1}{2}\left(1 - \frac{1}{2}\right) = \frac{3}{2}.$$

Para Z_2 hacemos así:

$$Z_2 = I_B \cdot 20,$$

donde B es el suceso “las 4 últimas tiradas son cara”. Entonces

$$E(Z_2) = 20E(I_B) = 20P(B) = 20\left(\frac{1}{2}\right)^4 = \frac{5}{4}.$$

Además

$$\mathrm{Var}(Z_2) = 20^2\,\mathrm{Var}(I_B) = 400\,P(B)(1-P(B)) = 400\cdot\frac{1}{16}\cdot\frac{15}{16} = \frac{375}{16}.$$

Finalmente,

$$E(Z) = E(Z_1) + E(Z_2) = 3 + \frac{5}{4} = \frac{17}{4},$$

$$\mathrm{Var}(Z) = \mathrm{Var}(Z_1) + \mathrm{Var}(Z_2) = \frac{3}{2} + \frac{375}{16} = \frac{399}{16}.$$

Por lo tanto

$$D(Z) = \sqrt{\frac{399}{16}} \simeq 5.$$

Variante del ejercicio anterior donde hay dependencia

Supongamos que en el ejercicio anterior se cambia el premio adicional de \$20 si las últimas 4 tiradas son caras y se pide ahora que las 6 últimas sean caras. En ese caso Z_1 y Z_2 no son independientes. El motivo de esto es que las tiradas quinta y sexta influyen en ambas v.a. Una manera formal de ver que no son independientes es encontrar un $i \in Z_1(\Omega)$ y un $j \in Z_2(\Omega)$ tales que

$$P[Z_1 = i, Z_2 = j] \neq P[Z_1 = i]P[Z_2 = j].$$

Tomemos $i = 2$, $j = 20$. El suceso

$$[Z_1 = 2, Z_2 = 20]$$

es equivalente a decir: "las cuatro primeras tiradas son ceca y las restantes son cara". Entonces

$$P[Z_1 = 2, Z_2 = 20] = \frac{1}{2^{10}}.$$

Por otra parte

$$P[Z_1 = 2] = \frac{\binom{6}{2}}{2^6} = \frac{15}{2^6}, \qquad P[Z_2 = 20] = \frac{1}{2^6},$$

y

$$P[Z_1 = 2]P[Z_2 = 20] = \frac{15}{2^{12}} \neq \frac{1}{2^{10}}.$$

Comprobado esto, pasamos al cálculo:

$$E(Z_1) = 3, \qquad \mathrm{Var}(Z_1) = \frac{3}{2},$$

ya fueron calculados en el ejercicio original.

$$E(Z_2) = E(20I_F),$$

donde F es el suceso "las últimas seis tiradas son caras". De modo que

$$E(Z_2) = 20P(F) = \frac{20}{2^6} = \frac{5}{16}.$$

Además

$$\mathrm{Var}(Z_2) = 400\cdot\frac{1}{2^6}\left(1 - \frac{1}{2^6}\right) = 400\cdot\frac{1}{2^6}\cdot\frac{63}{2^6} = \frac{25\cdot 63}{256} = \frac{1575}{256}.$$

$$E(Z) = E(Z_1) + E(Z_2) = 3 + \frac{5}{16} = \frac{53}{16}.$$

Para $\mathrm{Var}(Z)$, como no hay independencia entre Z_1 y Z_2, usamos

$$\mathrm{Var}(Z) = \mathrm{Var}(Z_1) + \mathrm{Var}(Z_2) + 2\,\mathrm{Cov}(Z_1, Z_2).$$

Una manera rápida de calcular $\mathrm{Cov}(Z_1, Z_2)$ es la siguiente (aprovechando varias propiedades teóricas): si X_k, $k = 1, \ldots, 10$ son las indicadoras usadas en el ejercicio original,

$$Z_1 = \sum_{k=1}^{6} X_k,$$

usando bilinealidad

$$\mathrm{Cov}(Z_1, Z_2) = \sum_{k=1}^{6} \mathrm{Cov}(X_k, Z_2).$$

Como Z_2 solamente depende de X_k para $k \geq 5$, es independiente con las primeras cuatro X_k y queda

$$\mathrm{Cov}(Z_1, Z_2) = \mathrm{Cov}(X_5, Z_2) + \mathrm{Cov}(X_6, Z_2).$$

Ya que X_5 es un indicadora y Z_2 es una indicadora multiplicada por 20, sería bueno tener el cálculo de $\mathrm{Cov}(I_A, I_D)$ cuando A, D son sucesos cualesquiera:

$$\mathrm{Cov}(I_A, I_D) = E(I_A I_D) - E(I_A)E(I_D) = P(A \cap D) - P(A)P(D).$$

En nuestro caso,

$$\mathrm{Cov}(X_5, Z_2) = \mathrm{Cov}(I_{A_5}, 20I_F) = 20\,\mathrm{Cov}(I_{A_5}, I_F) = 20\{P(A_5 \cap F) - P(A_5)P(F)\} = 20\left(\frac{1}{2^6} - \frac{1}{2}\frac{1}{2^6}\right) = \frac{5}{32}.$$

En forma similar

$$\mathrm{Cov}(X_6, Z_2) = \frac{5}{32}.$$

Volviendo a la fórmula,

$$\mathrm{Cov}(Z_1, Z_2) = \frac{5}{32} + \frac{5}{32} = \frac{5}{16}.$$

Y finalmente:

$$\mathrm{Var}(Z) = \frac{3}{2} + \frac{1575}{256} + 2\frac{5}{16} = \frac{2119}{256},$$

y

$$D(Z) \simeq 2{,}877.$$

Normalización de variables aleatorias discretas. Coeficiente de correlación

Como sabemos, los conceptos de "grande" y "pequeño" no significan mucho en matemática. Lo que es grande en un contexto puede ser diminuto en otro. Una v.a. que tiene esperanza igual a 1000 y que toma valores del orden de 990 tendrá un desvío del orden de 10, a todas luces "pequeño". Pero si su esperanza es 20, un desvío de 10 es "grande".

Para poder comparar variables aleatorias de diferentes órdenes de magnitud en sus valores, se suele hacer lo siguiente:

Supongamos que (Ω, P) es un espacio de probabilidad y $X : \Omega \to \mathbb{R}$ es una v.a. discreta con esperanza μ y varianza $\sigma^2 > 0$. La variable X se "normaliza" llevándola a la v.a.

$$Z = \frac{X - \mu}{\sigma}.$$

Esta variable aleatoria Z, como fácilmente puede comprobarse, cumple

$$E(Z) = 0, \qquad \mathrm{Var}(Z) = D(Z) = 1.$$

Parece entonces tener sentido la comparación de X_1 y X_2 (dos v.a. dadas) pasando ambas a sus versiones "normalizadas" Z_1 y Z_2.

Una primera aplicación de esta idea es la definición de un coeficiente para medir el grado de dependencia entre variables aleatorias. Como recordarán, dadas X_1 y X_2, el valor $\mathrm{Cov}(X_1, X_2)$ "pequeño" significa "poco dependientes", pero ¿qué es "pequeño"?. Para poner las cosas en su lugar puede normalizarse y definirse:

Definición. *Sean X_1, X_2 dos variables aleatorias con $\mathrm{Var}(X_i) = \sigma_i^2 > 0$, $i = 1, 2$. Llamemos $E(X_1) = \mu_1$, $E(X_2) = \mu_2$. Si*

$$Z_1 = \frac{X_1 - \mu_1}{\sigma_1}, \qquad Z_2 = \frac{X_2 - \mu_2}{\sigma_2},$$

se define el coeficiente de correlación entre X_1 y X_2, que se anota $\rho(X_1, X_2)$ o ρ_{X_1, X_2}, como

$$\rho(X_1, X_2) = \mathrm{Cov}(Z_1, Z_2) = \frac{\mathrm{Cov}(X_1, X_2)}{\sigma_1 \sigma_2}.$$

Una propiedad importante es que

$$|\rho(X_1, X_2)| \leq 1,$$

de la que enseguida hablaremos. De esta propiedad surgirá que el valor absoluto de la correlación (que es la propiedad que mide ρ) es máximo cuando $|\rho(X_1, X_2)| = 1$, y, mínimo, cuando $\rho(X_1, X_2) = 0$, que equivale a $\mathrm{Cov}(X_1, X_2) = 0$.

Volvamos a las propiedades de ρ, y en particular a un breve desarrollo sin detalles para justificar $|\rho(X_1, X_2)| \leq 1$. Una de las razones por las que es tan importante el álgebra lineal es la posibilidad de aplicarla en áreas diversas. En este caso se puede considerar las v.a. discretas con dominio en Ω y darles una estructura de espacio vectorial con las operaciones naturales

$$(X_1 + X_2)(\omega) = X_1(\omega) + X_2(\omega), \qquad (cX)(\omega) = cX(\omega).$$

Seguidamente se considera el subespacio H formado por las v.a. que tienen esperanza y varianza finita. Si en H definimos

$$\langle X_1, X_2 \rangle = E(X_1 X_2),$$

esta operación tiene todas las propiedades de un producto interno, excepto que $\langle X, X \rangle = 0$ no implica $X \equiv 0$. Eso puede arreglarse definiendo un espacio cociente adecuado pero no lo haremos porque nos alejaría del espíritu de nuestro curso. Permitámonos suponer que H ya cumple las condiciones para que la operación definida sea un producto interno. Consideremos las variables centradas

$$U = X_1 - E(X_1) \qquad V = X_2 - E(X_2)\,.$$

Entonces

$$\langle U, V \rangle = \mathrm{Cov}(X_1, X_2)\,, \;\; \|U\|^2 = \mathrm{Var}(X_1)\,, \;\; \|V\|^2 = \mathrm{Var}(X_2)\,.$$

Aplicando la desigualdad de Cauchy-Schwarz:

$$|\langle U, V \rangle| \leq \|U\|\,\|V\|,$$

y cuando $\|U\|, \|V\| > 0$,

$$\left| \frac{\langle U, V \rangle}{\|U\|\,\|V\|} \right| \leq 1,$$

es decir

$$|\rho(X_1, X_2)| \leq 1.$$

El coeficiente de correlación es también llamado coeficiente de correlación lineal. Uno de los motivos es que si se tiene una v.a. X y se toma una dependencia lineal de la otra, por ejemplo

$$Y = aX + b, \qquad a \neq 0,$$

entonces

$$\rho(X, Y) = \frac{\mathrm{Cov}(X, aX + b)}{\sqrt{\mathrm{Var}(X)}\sqrt{\mathrm{Var}(aX + b)}} = \frac{\mathrm{Cov}(X, aX)}{\sqrt{\mathrm{Var}(X)}\sqrt{\mathrm{Var}(aX)}} = \frac{a\,\mathrm{Cov}(X, X)}{|a|\,\mathrm{Var}(X)} = \frac{a}{|a|}.$$

De modo que si $a > 0$ se tiene $\rho(X, Y) = 1$ (correlación positiva) y si $a < 0$, $\rho(X, Y) = -1$ (correlación negativa). En ambos casos el módulo de $\rho(X, Y)$ es el máximo posible.

Esperanza condicional. Fórmula de esperanza total

Sabemos que si (Ω, P) es un espacio de probabilidad y $B \subset \Omega$ con $P(B) > 0$, se origina el espacio (Ω, P_B), tal que $\forall A \subset \Omega$

$$P_B(A) = P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$

Si $X : \Omega \to \mathbb{R}$ es una v.a. discreta, obviamente lo es para cualquiera de los dos espacios, de modo que tiene sentido la pregunta de la existencia de $E(X)$ en el espacio (Ω, P_B). A esta esperanza, cuando exista, la llamaremos $E(X \mid B)$ o $E_B(X)$. Su interpretación es sencilla: es el valor esperado de X sabiendo que B sucedió.

Si existe $E(X)$ en (Ω, P), también existe $E(X \mid B)$ para cualquier B con $P(B) > 0$, ya que si $X(\Omega) = \{x_1, x_2, \ldots\}$, entonces

$$\sum_k |x_k| P_B([X = x_k]) = \sum_k |x_k| \frac{P([X = x_k] \cap B)}{P(B)} \leq \frac{1}{P(B)} \sum_k |x_k| P[X = x_k] < +\infty.$$

Cuando existe $E(X \mid B)$, su fórmula es

$$E(X \mid B) = \sum_k x_k \, P_B[X = x_k] = \sum_k x_k \, P([X = x_k] \mid B).$$

Ejemplo. Se elige un número real al azar en $[0, 1]$. Sea X el menor dígito que puede usarse como primer decimal del número elegido. Hallar el valor esperado de X sabiendo que se ha elegido un número mayor que $1/2$.

Solución. Se tiene

$$X(\Omega) = \{0, 1, 2, \ldots, 9\}.$$

Si $B =$ "el real elegido es mayor que $1/2$", entonces

$$P_B[X = k] = 0, \qquad k < 5.$$

$$P_B[X = k] = \frac{P([X = k] \cap B)}{P(B)} = \frac{P\left(\left[\frac{k}{10}, \frac{k+1}{10}\right)\right)}{1/2} = \frac{1/10}{1/2} = \frac{1}{5}, \qquad k \geq 5.$$

Entonces

$$E(X \mid B) = \sum_{k=5}^{9} k \frac{1}{5} = 7.$$

La siguiente proposición ("fórmula de esperanza total"), va en línea con nuestra conocida fórmula de "probabilidad total". Del mismo modo, nos permitirá resolver problemas complicados a través de descomposiciones adecuadas.

Proposición (Fórmula de esperanza total)**.** *Sea (Ω, P) un espacio de probabilidad y $X : \Omega \to \mathbb{R}$ una v.a. discreta con esperanza, con*

$$X(\Omega) = \{x_1, x_2, \ldots\}.$$

Supongamos que Ω se puede partir en una cantidad numerable de sucesos de probabilidad positiva:

$$\Omega = \bigcup_k B_k, \qquad P(B_k) > 0 \quad \forall k,$$

y

$$B_i \cap B_j = \varnothing \qquad \text{para } i \neq j.$$

Entonces

$$\boxed{E(X) = \sum_k E(X \mid B_k) P(B_k)}$$

Demostración. Notemos que

$$E(X) = \sum_j P[X = x_j] \, x_j = \sum_j \sum_k P([X = x_j] \cap B_k) \, x_j.$$

Cambiando el orden de las sumatorias:

$$E(X) = \sum_k \left[\sum_j P([X = x_j] \cap B_k) \, x_j \right].$$

Multiplicando y dividiendo por $P(B_k)$, para cada k:

$$E(X) = \sum_k P(B_k) \left[\sum_j P([X = x_j] \mid B_k) \, x_j \right] = \boxed{\sum_k P(B_k) E(X \mid B_k)}.$$

□

A continuación presentaremos algunos ejemplos. En los mismos usaremos propiedades sencillas. Algunas, como por ejemplo,

- $E(X_1 + X_2 \mid B) = E(X_1 \mid B) + E(X_2 \mid B)$
- $E(cX \mid B) = c \, E(X \mid B)$

no necesitan demostración porque la esperanza condicional es la esperanza en el espacio (Ω, P_B). Otras son muy simples y las dejamos como ejercicio. Un caso es: si $X \equiv c$ entonces

$$E(X \mid B) = c.$$

En este primer ejemplo no plantearemos el problema con rigor. Con toda intención queremos mostrar que prima la interpretación probabilística.

Ejemplo. *Se arroja un dado equilibrado. Si sale mayor que* 4*, se arroja 7 veces una moneda equilibrada. Si sale menor o igual que* 4*, se arroja 7 veces una moneda con* $p = 1/5$*. Calcular el número esperado de caras de este experimento.*

Si lo desean, pueden plantear Ω como un "arbolito", aquí no lo haremos.

Solución. Anotamos:

$$X = \text{"número de caras"}.$$

Sean

$$B_1 = \text{"el dado sale mayor a 4"},$$

$$B_2 = \text{"el dado sale menor o igual a 4"}.$$

Obviamente B_1, B_2 son una partición de Ω. Tenemos

$$E(X \mid B_1) = \frac{7}{2}, \qquad E(X \mid B_2) = \frac{7}{5}.$$

Entonces, por la Fórmula de esperanza total:

$$E(X) = E(X \mid B_1)P(B_1) + E(X \mid B_2)P(B_2) = \frac{7}{2} \cdot \frac{2}{6} + \frac{7}{5} \cdot \frac{4}{6} = \frac{7}{6} + \frac{14}{15} = \frac{21}{10} = 2{,}1.$$

Otro ejemplo: Esperanza de la geométrica

Acá usaremos una técnica que apareció en la teoría 3. Vale la pena recordar que el cálculo por el que alguna vez obtuvimos el valor $1/p$ para la esperanza de una v.a. con distribución geométrica fue usando la técnica de serie de potencias. Acá será bastante más rápido.

Podemos pensar que se arroja una moneda con probabilidad p de cara, $0 < p < 1$:

$$X = \text{"número de tiradas hasta que sale cara"}.$$

Como siempre descartamos la posibilidad de que nunca salga cara. Vamos a partir Ω en dos sucesos mutuamente excluyentes:

$$B_1 = \text{"la primera tirada es cara"},$$

$$B_2 = \text{"la primera tirada es ceca"}.$$

Claramente

$$E(X \mid B_1) = 1, \qquad P(B_1) = p, \qquad P(B_2) = 1 - p.$$

Para $E(X \mid B_2)$ usamos un "truco" que ya conocemos. Si ya se produjo B_2, es como si se hiciera el experimento nuevamente, pero con una tirada en contra. Quiere decir que

$$E(X \mid B_2) = 1 + E(X).$$

La fórmula de esperanza total nos dice:

$$E(X) = E(X \mid B_1)P(B_1) + E(X \mid B_2)P(B_2) = 1 \cdot p + (1 + E(X))(1 - p).$$

Hemos escrito una ecuación con una incógnita $E(X)$: despejando se obtiene

$$\boxed{E(X) = \frac{1}{p}}.$$

El siguiente es un ejemplo más complicado, muy interesante. Generalmente es presentado al final de una clase y planteado como desafío para la clase siguiente. Los invito a tomarlo así. En apuntes venideros será resuelto con un método totalmente diferente.

Ejemplo. *Se arroja un dado equilibrado hasta obtener dos* 6 *consecutivos.*

a) Probar que puede deshecharse la posibilidad de que esto no suceda. Esto es, si F = "nunca se llega al objetivo", se cumple

$$P(F) = 0.$$

b) Sea

$$X = \text{"cantidad de tiradas del experimento"}.$$

Calcular $E(X)$.

Solución.

a) Vamos a hacer un razonamiento probabilístico sin desarrollar totalmente la justificación técnica, que no es demasiado díficil, pero priorizaremos la idea.

Supongamos que se hace otro experimento que consiste en arrojar dos veces consecutivas el dado, después otras dos veces, etc, hasta que las dos tiradas salgan ambas 6. La probabilidad de éxito en esta prueba es claramente menor que la de éxito en la prueba original. Si llamamos Z a la v.a. asociada al nuevo experimento:

$$Z = \text{"cantidad de pares de tiradas hasta llegar un éxito"},$$

Z tiene una distribución Geom(1/36), por lo tanto hay probabilidad 1 de éxito.

b) Vamos a introducir dos incógnitas:

$$\alpha = E(X), \qquad \beta = E(X \mid B_1),$$

donde B_1 es el suceso "la primera tirada es un 6". Sea B_2 el suceso "la primera tirada es distinta de 6". La fórmula de esperanza total nos permite escribir:

$$E(X) = E(X \mid B_1)P(B_1) + E(X \mid B_2)P(B_2).$$

Es decir

$$\alpha = \beta \cdot \frac{1}{6} + E(X \mid B_2)\frac{5}{6}.$$

Como si nuevamente comenzara el experimento,

$$E(X \mid B_2) = 1 + E(X) = 1 + \alpha.$$

Tenemos entonces

$$\alpha = \frac{1}{6}\beta + \frac{5}{6}(1 + \alpha).$$

De aquí:

$$\boxed{\alpha - \beta = 5}.$$

Acá hay una primera ecuación que relaciona α con β. Ahora encontraremos otra. Consideramos:

$$C_1 = \text{"la segunda tirada es un 6"},$$

$$C_2 = \text{"la segunda tirada es distinta de 6"}.$$

Entonces

$$E(X \mid C_2) = \alpha + 2,$$
$$E(X \mid C_1 \cap B_1) = 2,$$
$$E(X \mid C_1 \cap B_2) = \beta + 1.$$

Entonces

$$E(X) = E(X \mid C_2)P(C_2) + E(X \mid C_1 \cap B_1)P(C_1 \cap B_1) + E(X \mid C_1 \cap B_2)P(C_1 \cap B_2).$$

Es decir,

$$\alpha = (\alpha + 2)\frac{5}{6} + 2\frac{1}{6}\frac{1}{6} + (\beta + 1)\frac{5}{6}\frac{1}{6},$$

que conduce a

$$\frac{\alpha}{6} - \frac{5}{36}\beta = \frac{67}{36}.$$

Esto, junto con la primera ecuación, lleva al sistema

$$\begin{cases} \alpha - \beta = 5, \\ 6\alpha - 5\beta = 67. \end{cases}$$

Al resolver resulta

$$\alpha = 42, \qquad \beta = 37.$$

En particular

$$\boxed{E(X) = 42}.$$

Funciones de probabilidad condicionales

Consideremos un espacio de probabilidad (Ω, P) y dos variables aleatorias discretas

$$X, Y : \Omega \to \mathbb{R}.$$

En lo que sigue supondremos que

$$X(\Omega) = \{x_1, x_2, \ldots\}, \qquad Y(\Omega) = \{y_1, y_2, \ldots\},$$

y además que

$$f_X(x_i) > 0 \quad \forall i, \qquad f_Y(y_j) > 0 \quad \forall j.$$

Para cada j fijo, consideremos la v.a. X vista desde el espacio (Ω, P_{B_j}), donde

$$B_j = [Y = y_j].$$

Si por un momento anotamos como f_{B_j} a esa densidad, tendremos

$$f_{B_j}(x_i) = P[X = x_i \mid Y = y_j].$$

El nombre que tradicionalmente se anota este valor es

$$f_{X|Y}(x_i \mid y_j).$$

Es una notación, nada más.

Análogamente, para cada i fijo la densidad de Y condicionada al suceso $A_i = [X = x_i]$ da origen a la notación

$$f_{Y|X}(y_j \mid x_i).$$

Por las propiedades y definiciones de la distribución conjunta se tiene

$$f_{X|Y}(x_i \mid y_j) = \frac{P[X = x_i, Y = y_j]}{P[Y = y_j]} = \frac{f_{X,Y}(x_i, y_j)}{f_Y(y_j)},$$

y análogamente

$$f_{Y|X}(y_j \mid x_i) = \frac{P[X = x_i, Y = y_j]}{P[X = x_i]} = \frac{f_{X,Y}(x_i, y_j)}{f_X(x_i)}.$$

De acuerdo a las definiciones y propiedades de esperanza condicional, tenemos para cada j:

$$E(X \mid Y = y_j) = \sum_i x_i \, f_{X|Y}(x_i \mid y_j),$$

y para cada i:

$$E(Y \mid X = x_i) = \sum_j y_j \, f_{Y|X}(y_j \mid x_i).$$

Pregunta: ¿Qué pasa si X e Y son independientes?

Variable aleatoria esperada

Supongamos que (Ω, P) es un espacio de probabilidad y que (X, Y) es un vector aleatorio discreto. En la relación que pueden tener X e Y hay dos casos extremos:

- dependencia determinista de X e Y, es decir $Y = h(X)$;
- X e Y son independientes.

Entre estos casos hay una enorme gama de posibilidades.

Suele suceder a veces que la observación práctica muestra una dependencia clara pero no tan explícita como algo de la forma $Y = h(X)$. Por ejemplo,

$$Y(\omega) \simeq 2X(\omega),$$

es decir,

$$Y(\omega) = 2X(\omega) + \varepsilon(\omega),$$

donde $\varepsilon(\omega)$ varía tomando valores pequeños respecto de $|X(\omega)|$. Sería bueno tener una herramienta que contemplara esta situación. Esto es, que nos diga que

$$Z = 2X$$

es lo que uno esperaría de Y, cuando X es conocida y no se tiene una fórmula precisa para Y, solamente la comprobación de que para muchos ω hay una "igualdad de este tipo". Una tal Z merecería llamarse $E(Y \mid X)$. La definición precisa es:

Definición. *Supongamos que $X : \Omega \to \mathbb{R}$ es una v.a discreta. Sea Y otra v.a discreta. Entonces se define la variable aleatoria*

$$E(Y \mid X) : \Omega \to \mathbb{R}$$

como

$$E(Y \mid X)(\omega) := E[Y \mid X = X(\omega)]\,.$$

Esto es lo mismo que decir que si tomamos $g : X(\Omega) \to \mathbb{R}$, dada por

$$g(x_k) := E[Y \mid X = x_k]\,,$$

entonces $E(Y \mid X) = g(X)$. Algunas propiedades son inmediatas y las dejamos como ejercicio:

$$E(Y_1 + Y_2 \mid X) = E(Y_1 \mid X) + E(Y_2 \mid X),$$

$$E(cY \mid X) = c\,E(Y \mid X).$$

Pregunta: ¿Qué pasa con $E(Y \mid X)$ cuando X e Y son independientes?.
Una propiedad interesante es la siguiente:

Proposición. *Se tiene que*

$$E(E(Y \mid X)) = E(Y).$$

El significado de esto es: la variable aleatoria $E(Y \mid X)$, que puede verse como una aproximación (o estimación) de Y, tiene igual esperanza que Y.

Demostración. Sea

$$g(x_k) = E[Y \mid X = x_k]$$

para cada k. Entonces

$$E(E(Y \mid X)) = E(g(X)) = \sum_k g(x_k) f_X(x_k) = \sum_k E[Y \mid X = x_k] f_X(x_k) = \sum_k E[Y \mid X = x_k] P(X = x_k) = E(Y)$$

por la fórmula de esperanza total. □

Proponemos el siguiente ejercicio, de interpretación muy intuitiva:

Ejercicio. Se arroja 10 veces una moneda con probabilidad $p = 1/3$. Sean

$$X := \text{“cantidad total de caras”},$$

$$Y := \text{“cantidad de caras en las 9 primeras tiradas”}.$$

Probar que

$$E(X \mid Y) = Y + \frac{1}{3}.$$

Caminata aleatoria simétrica

Supongamos que n es un entero positivo fijo. Un caminante dará un paseo de n pasos moviéndose sobre $\mathbb{Z}$ con las siguientes reglas:

a) Su posición inicial es el cero.

b) Antes de dar un paso arroja una moneda equilibrada: si sale cara pasa al entero que está a su derecha; si sale ceca, al entero que está a su izquierda.

Por ejemplo, si $n = 3$ y la primera tirada es cara irá al 1. Si la próxima tirada es ceca vuelve al 0 y si la próxima tirada es ceca termina la caminata en -1.
Notemos que sería equivalente hacer primero los n sorteos y luego caminar. Un espacio muestral coherente es

$$\Omega = \{c, s\}^n,$$

que ya conocemos muy bien por tratarse del producto cartesiano originado por n pruebas independientes. Siendo la moneda equilibrada, Ω resulta equiprobable con

$$P(\{\omega\}) = \frac{1}{2^n}.$$

Para cada $k = 1, \ldots, n$ definamos

$$X_k = \begin{cases} 1, & \text{si el paso } k\text{-ésimo fue a derecha,} \\ -1, & \text{si el paso } k\text{-ésimo fue a izquierda.} \end{cases}$$

Claramente las X_k son independientes. Una manera "técnica" de justificarlo sería tomando las v.a.

$$Y_k = \begin{cases} 1, & \text{si la } k\text{-ésima tirada es cara,} \\ 0, & \text{si la } k\text{-ésima tirada es ceca,} \end{cases}$$

que son indicadoras, que ya sabemos independientes. Observando que

$$X_k = 2Y_k - 1$$

y aplicando las propiedades de la independencia, las X_k resultan independientes. Claramente

$$P(X_k = 1) = P(X_k = -1) = 1/2.$$

Llamemos

$$S_k = X_1 + \cdots + X_k.$$

S_k es la posición del caminante al cabo de k pasos. Una vez cumplidos los k, las posiciones más lejanas posibles del cero son los enteros k y $-k$. Sin embargo, $S_k(\Omega)$ no contiene a todos los enteros intermedios, como veremos enseguida.

Consideramos una caminata aleatoria con n pasos. Vamos a estudiar la distribución de la v.a. S_n (n fijo). Una rápida inspección nos permite distinguir dos situaciones de acuerdo a la paridad:
Si n es par, $X_1 + \cdots + X_n$ debe ser par. Y si n es impar, $X_1 + \ldots + X_n$ debe serlo. Por ejemplo

$$S_2(\Omega) = \{-2, 0, 2\}$$

en el caso $n = 2$. Haremos todo el trabajo para n par y queda como ejercicio el caso n impar.

Sea $n = 2m$. En $2m$ pasos el caminante ha hecho j pasos hacia la derecha y k hacia la izquierda, con

$$k + j = 2m\,,$$

y la posición del caminante es entonces $j - k$. Supongamos que esa posición es el entero i. Tenemos

$$\begin{cases} k + j = 2m, \\ -k + j = i. \end{cases}$$

Sumando ambas ecuaciones

$$2j = 2m + i$$

$$j = \frac{2m + i}{2} = m + \frac{i}{2},$$

que obliga a que i sea par (más precisamente $i = 2r$, con r entero, $-m \leq r \leq m$). Se tiene

$$\begin{cases} j = m + r, \\ k = m - r, \end{cases}$$

con lo cual r (y por lo tanto i) determinan j y k. Entonces

$$S_{2m}(\Omega) = \{2r / r \in \mathbb{Z},\ -m \leq r \leq m\}.$$

Nos falta determinar, para cada r,

$$P[S_{2m} = 2r].$$

Lo que sigue no es sorprendente, ya que las X_n tienen clara hermandad con las Y_n, cuya suma tiene distribución binomial: si el caminante en $2m$ pasos llegó a $2r$, quiere decir por lo que analizamos, que dio $m+r$ pasos hacia la derecha y $m-r$ hacia la izquierda (ojo, puede ser $r<0$). Esto se puede hacer de

$$\binom{2m}{m+r} = \binom{2m}{m-r}$$

maneras diferentes. Entonces

$$P[S_{2m}=2r] = \frac{1}{2^{2m}}\binom{2m}{m+r},$$

para todo

$$r \in \mathbb{Z} \cap [-m, m].$$

Dejamos las siguientes propiedades como ejercicio:

$$E(S_{2m}) = 0,$$

$$\mathrm{Var}(S_{2m}) = 2m.$$

Las caminatas aleatorias son una herramienta muy usual en las aplicaciones a la física (fenómenos de difusión). El "terreno" sobre el que se mueve el caminante puede ser muy complicado. En nuestro caso se trata de $\mathbb{Z}$. Aún siendo $\mathbb{Z}$ muy sencillo, hay problemas de difícil solución. Ahora resolveremos un par de problemas sencillos:

Problema. Un caminante aleatorio sale del cero y da 20 pasos. ¿Cuál es la probabilidad de que al final de la caminata vuelva al sitio inicial?

Solución. Para volver al cero, debe dar 10 pasos hacia la derecha y 10 pasos hacia la izquierda. Por lo calculado anteriormente ($m=10$, $r=0$):

$$P[S_{20}=0] = \binom{20}{10}\frac{1}{2^{20}}.$$

Problema. Un caminante aleatorio sobre $\mathbb{Z}$ parte, como de costumbre, del cero. Da 10 pasos. Si se sabe que el primer paso fue hacia la izquierda:

a) Hallar la posición esperada al final de la caminata.

b) Calcular la probabilidad de que la caminata termine con el caminante en la posición del número cuatro.

Solución. En estos casos lo mejor es pensar que la condición

$$B = \text{"el primer paso es hacia la izquierda"}$$

o más académicamente

$$[X_1 = -1]$$

da origen a una caminata de un paso menos en la cual el punto inicial se ha corrido un lugar a la izquierda. Entonces:

a):

$$E[S_{10} \mid X_1 = -1] = -1 + E[S_9] = -1 + 0 = \boxed{-1}.$$

b):

$$P[S_{10} = 4 \mid X_1 = -1] = P[S_9 = 5].$$

Como no hemos desarrollado el caso m impar, trabajamos un poquito más:

$$S_9 = 5$$

significa que hubo 7 pasos hacia la derecha y 2 hacia la izquierda. Entonces

$$P[S_9=5] = \binom{9}{7}\frac{1}{2^9} = \frac{9\cdot 8}{2}\frac{1}{512} = \boxed{\frac{9}{128}}.$$